

匿名候选人

联系方式：可在面试阶段提供

教育经历

硕士在读 本科	某港校 某 985 高校	集成电路与系统 电子/计算机相关专业
获得荣誉：校级学业奖学金（前 20%）及竞赛创新奖学金		

实习经历

近期	某量化机构 AI 研究院	大模型与高性能计算实习生
• 百亿级 MoE 基座模型开发与优化：参与训练、推理与 RL rollout 基础设施开发，围绕训练算子、推理算子和训推一致性完成性能优化、稳定性排障与多卡验证。 • 训练算子支持 1. FA3 deterministic SWA backward：定位长序列变长滑动 Attention deterministic backward 回退的 dQ 依赖链，并在原 fused kernel 内完成 ticket 与 scheduler 对齐；代表 shape 完整 backward 由 6.755 ms 降至 1.699 ms (3.98×)，3601/3601 回归和 1000 次逐位重复通过。 2. Sink FC1 GEMM 与通信竞争控核：构建 4×H200 双 stream 代理，以 NCCL CTA 预算和 DeepGEMM SM budget 控制通信、计算资源，完成 121 组粗扫和 89 组细扫；AllGatherV 代理中联合 span 降低 12.80%，其中控核独立贡献 7.58%。 • 推理算子支持 1. CUDA Graph 确定性 MoE Router GEMM：在推理引擎中接入多后端选择、capture 前 preflight、cache/fallback 与 workspace 生命周期；48 层 Router GEMM 中位耗时降低 73.39%，135/135 kernel 和 20/20 模型场景逐位一致。 2. OE 异步状态算子：将历史 token 构造保留在 GPU，并修复 prefill/decode/mixed batch/恢复/slot reuse/reorder 的跨 step 状态；TP1 28/28 case 通过、吞吐+4.99%，TP2/TP4 均 84/84、0 mismatch。 • RL 训推一致性与 Rollout 稳定性 1. Router Replay 与多卡可观测性：打通路由采集、传输、训练侧回放与指标闭环；代表性 MoE 模型 20-step 对照中，route mismatch 由 17%-19%降至 0，fr²/KL 分别降低 36-145×/4-7×，并扩展至 128 卡监控运行。 2. CUDA Graph hang 排查与修复：以两卡最小复现和 TP/Graph/fused 控制变量定位 FTZ 导致的 Lamport sentinel 误判，采用 0x80000000 位级判断修复；模型级 Graph on/off 回归中未再出现 hang 或 timeout。		
此前	某 GPU 厂商	算子与编译器优化实习生
• TensorFlow 设备后端、图优化与稳定性：完成 GELU 接入、融合修复与热点路径优化，推动整网 11 个 GELU 融合、真实 shape 耗时降低 36.6%；重构 HostMemory 路径使 1000 轮成功率达到 100%，并完成长跑验证。		

开源贡献

近年

外部开源贡献

- 已合入多个外部项目 PR：涉及存储持久化、RDMA 端口恢复、内存注销生命周期、队列失败传播及算子边界条件修复。

项目与科研

近期

高性能大模型量化推理 Runtime

- 量化 Runtime 部署与 TP 扩展：完成多精度后端、Attention 与多卡构建适配，定位并修复量化 GEMV 尾组越界；实现 TP=2 切分与 all-reduce，代表性双卡模型显存显著降低、输出吞吐提升 76.8%。

近期

关键 Token 加权 CoT 蒸馏研究

- 训练与评测：负责训练、调优与多卡评测，将 token 重要性用于加权监督；7B 模型在两个数学推理基准上分别达到 94.01%/94.00%，较最强基线提升 5.51/10.10 个百分点。

综合素质

- 技术方向：GPU 高性能算子开发与大模型训练/推理系统优化。
- 开发与性能工程：C/C++、Python、CUDA、Triton、PyTorch Extension；熟悉 Nsys、NCU 与 Compute Sanitizer。
- 语言：IELTS 6.5、CET-6，具备英文技术文档阅读与跨仓源码分析能力。

小红书小冯别放弃