

F 同学

教育经历

2025.09-2027.06(预计)	港中文 xx 校区	硕士
2021.09-2025.06	末 9 (985)	本科
获得荣誉 (本科) : 学业奖学金 (前 20%) 特长奖学金 (竞赛创新)		

实习经历

2026.04-至今	某量化机构 - AI 研究院	大模型与高性能计算实习生
• FlashInfer CUDA Graph 稳定性修复: 针对 H200 上 vLLM TP=2 FULL CUDA Graph 的 rollout 卡死问题, 构建两卡最小复现并将根因收敛到 fused AllReduce + RMSNorm 的通信轮询逻辑: 原实现通过浮点比较识别 Lamport -0.0 sentinel, FTZ 会将合法 FP32 负次正规数误判为负零, 导致轮询无法退出、GPU Kernel 不结束并最终触发 rollout timeout。在现用 FlashInfer 版本中将 sentinel 判断改为 0x80000000 位级精确比较后, 两卡最小复现及模型级 Graph on/off 回归全部通过, 重复 Graph replay 未再出现 timeout 或 hang。 • R3 Router Replay: 复现公开论文方案, 针对 vLLM rollout 与 Megatron 训练侧 MoE 路由不一致问题, 打通 [token, MoE-layer, top-k] route 采集、传输与回放链路, 并建立 response-mask 对齐及异常检测, 覆盖 18 项 CPU 测试; 在 8×H200、Qwen3-30B-A3B BF16 的 20-step 实验中, 将 route mismatch 由 17%–19% 降至 0, $F_{\text{tau}2}$ 降低 36–145×、KL 降低 4–7×; 最终扩展至 百卡规模集群, 使用内部大模型完成竞赛题单轮 200-step 运行并接入 SwanLab 监控, 结果与 8 卡情况对齐, 将改动合并进开发仓。 • H200 确定性 Router GEMM 优化: 针对 vLLM Batch-Invariant 模式下 fixed 128×128×64 persistent tile 在 decode 小 M 场景的大量无效计算, 完成 Triton full-K 与 DeepGEMM SM90 BF16 两条确定性路径的设计、接入及 Kernel—CUDA Graph—整模型分层验证; 在 BF16 [M,2048]×[2048,128]、M=1/2/4/8/12 上, Triton full-K 较 current BI 加速 1.99–2.15×, DeepGEMM Graph p50 由 13.79–14.94μs 降至 4.74–4.86μs, 加速 2.84–3.15×; 目标模型 20 个场景中, 48 层 Router GEMM 中位耗时由 789.23 降至 210.01μs/step (-73.39%), 整步 GPU busy 中位降低 6.16%, kernel 135/135、全模型 20/20 逐位一致; 最终收敛为 DeepGEMM 主路径 → Triton full-K 低依赖 fallback → persistent 全覆盖 fallback 的三级后端方案, 其中 M>2048 及未覆盖配置回退 persistent。 • OE 异步算子开发: 将 recent-token history 与 oe_input_ids 构造保留在 GPU, 使用 Triton fused-hash 减少 GPU → CPU 同步等待及 CPU → GPU 回传, 并修复 prefill、decode、mixed batch、请求恢复、slot reuse 与 reorder 景下的跨 step 状态更新问题; 三类执行阶段均通过正确性验证。TP1 下严格 28-case 矩阵全部通过, 吞吐较 sync 提升 4.99%、较 async-unfused 提升 1.94%; TP2/TP4 采用 async-unfused + batch-invariant 安全路径, 确定性通过率分别由 41/84、63/84 提升至 84/84, 均为 0 mismatch, decode 吞吐分别提升约 4.6%/3.0%。		
2026.01-2026.04	某国产 GPU 公司	算子与编译器优化实习生
• TensorFlow XXXX Extension 开发: 负责 TensorFlow on XXXX 的算子支持、插件集成、测试验证及图优化; 完成 xxDNN GELU 接入、GELU fusion 链路修复与 benchmark 建设, 解决大图场景下部分 GELU 未融合问题, 推动整网 11 个 GELU 全部融合, 真实 shape testcase 测试耗时降低约 36.6%。		

- **解决 OOM / 随机崩溃**：在整网长跑情况下，独立定位 shape tensor 在 StridedSlice<int32> / Pack<int32> 链路中错误进入 device path 的根因，重构 HostMemory 路径并完成修复；将 inference 500 轮成功率从约 30% 提升至 1000 轮成功率 100%，并通过 4 万 / 40 万 / 80 万轮长跑验证，结果均稳定。

科研与论文

2026.01-至今

关键 Token 思维链蒸馏研究

- **边缘设备小模型构建与部署**：面向语义通信的边缘设备小模型构建与部署，我负责模型训练与调优，参与构建“结构恢复-关键 Token 加权 SFT-偏好优化”流程：从打乱/遮蔽步骤恢复四段式推理，再从学生生成构造偏好对，强化答案正确性和结构完整性。
- **关键 Token 与实验闭环**：逐 Token 扰动教师推理，以参考答案 log-likelihood 下降量度量答案敏感性，驱动加权 SFT 与高重要性辅助损失；完成 LoRA/DPO、有限值检查及 vLLM TP=4 全量评测。Qwen2.5-7B 在 GSM8K/SVAMP 的 pass@1 为 70.05%/67.67%，pass@5 为 94.01%/94.00%；论文在撰，计划投稿 AI 顶会。

项目经历

2025.12-至今

基于 PyTorch Extension 的高性能 LLM 量化推理 Runtime 开发

- **量化 Runtime 与后端适配**：在支持 W4A16 AWQ、W8A8 SmoothQuant 与 FP8 的 PyTorch Extension Runtime 中，完成 FlashAttention-2/4 可配置接入，补齐 GQA 的 KV heads 展开、softcap mask 及 SDPA Torch 回退：将 CUDA arch、cache 与模型路径改动态/可选配置，使工程可在本地 GPU (5060) 与 H200 环境构建部署。
- **H200 Kernel 与 Tensor Parallel**：在 2×H200 (SM90/CUDA 13.0) 环境完成 AWQ Runtime 迁移；使用 NVIDIA Compute Sanitizer 将 decode 非法访存定位到 gemv_kernel_g128：当 K/group_size=7 时 warp 仍按 8 组读取，导致末尾 lane 越界访问 scale/zero：增加 group 边界保护、current-stream launch 与错误检查后，代表 shape memcheck/initcheck/synccheck/racecheck 均为 0 error/0 hazard：进一步实现 Qwen2 packed-AWQ TP=2，完成 Q/K/V、gate/up 列切分及 O/down 行切分与 NCCL all-reduce。
- **32B 量化部署与验证**：基于 128x512 本地代码校准完成 Qwen2.5-Coder-32B W4A16 量化与双卡交付；在同模型、prompt、64-token、3 次重复的公平对照下，checkpoint 由 61.04 GiB 降至 18.02 GiB (-70.5%)，E2E output 吞吐 (含 prefill、首 token 与 decode) 由 2.53 提升至 4.47 tok/s (+76.8%)，运行期峰值显存由 32.02 降至 10.63 GiB/rank (-66.8%)；通过 10 组 CUDA/PyTorch 数值对照 (最大绝对误差 0.007812)、跨 rank token 一致性 & 中文交互验收。

技术能力与综合素质

- **技术方向与语言能力：**聚焦 RL Infra、GPU 算子与性能优化、大模型训练/推理/蒸馏及边缘设备部署；英语 IELTS 6.5、CET-6，持有华为 HCIA-AI 认证。
- **开发与工程能力：**熟练使用 C/C++、Python、CUDA、Triton、PyTorch Extension；具备 vLLM、veRL、Megatron-LM、FlashInfer、CUTLASS、NCCL 工程实践。
- **工程方法与工具：**具备跨仓源码分析、最小复现、控制变量实验、自动化测试、Benchmark 与技术文档能力；使用 Nsys、NCU、Compute Sanitizer 进行性能分析、故障定位与多卡正确性验证。