

冯浩然

电话: (+86)15024999885 邮箱: 225010160@link.cuhk.edu.cn 个人网站: xfgd.github.io

教育经历

2025.09-2027.06(预计)	香港中文大学 (深圳)	集成电路与系统 硕士
2021.09-2025.06	山东大学 (985)	电子科学与技术/计算机科学与技术 本科

获得荣誉: 山东大学学业奖学金 (前 20%) 山东大学特长奖学金 (竞赛创新)

实习经历

2026.04-至今	九坤投资-AI 研究院	大模型与高性能计算实习生
------------	-------------	--------------

• **300B 级 MoE 基座模型推理与 Rollout 优化:** 参与内部 300B 级 MoE 基座模型推理、RL rollout 与训练基础设施开发, 重点解决 CUDA Graph 确定性、Router GEMM 选核、异步状态管理、量化 Runtime 与多卡稳定性问题。

• 推理算子优化 (重点)

1. **CUDA Graph 下的确定性 MoE Router GEMM:** 在 vLLM 接入 DeepGEMM/Triton Full-K/persistent 三级后端, 完成 selector、capture 前 preflight、cache/fallback、workspace 与路径回归, replay 固化后端。48 层 Router GEMM 中位耗时下降 73.39%, 135/135 kernel、20/20 模型场景逐位一致, prefix-cache hit 下 TP1/TP2 整请求性能提升 3.81%/4.36%。
2. **OE 异步状态算子:** 将 recent-token history 与 oe_input_ids 构造保留在 GPU, 以 Triton fused-hash 消除同步与回传, 并修复 prefill/decode/mixed batch/恢复/slot reuse/reorder 的跨 step 状态; TP1 28/28 case 通过、吞吐较 sync +4.99%, TP2/TP4 均 84/84、0 mismatch, decode 吞吐+4.6%/+3.0%。

• RL 训推一致性与 Rollout 稳定性

1. **R3 Router Replay 与多卡可观测性:** 打通 rollout 路由采集、传输、训练侧回放与 response-mask/mismatch/fr²/KL 闭环; 8×H200、20-step 对照中 route mismatch 由 17%-19%降至 0, fr²/KL 降低 36-145×/4-7×, 并扩展至 128 卡内部 300B 级模型的 200-step 监控运行。
2. **FlashInfer CUDA Graph hang 排查与修复:** 以 H200 两卡最小复现和 TP/Graph/fused 控制变量定位 fused AllReduce + RMSNorm 中 Lamport -0.0 sentinel 的 FTZ 误判; 采用 0x80000000 位级判断修复后, 模型级 Graph on/off 重复回归未再出现 hang 或 timeout。

• 训练算子优化经验

1. **FA3 deterministic SWA backward:** 定位 dQ semaphore 依赖链占确定性增量 99.67%, 在原 fused kernel 内完成 contributor-relative ticket 与 reverse scheduler 对齐; 代表 shape 完整 backward 由 6.755 ms 降至 1.699 ms (3.98×), 3601/3601 回归和 1000 次 bitwise 重复通过。
2. **Sink FC1 GEMM 与通信竞争控核:** 在 4×H200 双 stream 代理中以 NCCL CTA 预算与 DeepGEMM SM budget 控核, 完成 121 组粗扫和 89 组细扫; AllGatherV 联合 span 降低 12.80%, 其中控核独立贡献 7.58%。

2026.01-2026.04	摩尔线程	算子与编译器优化实习生
-----------------	------	-------------

• **TensorFlow MUSA Extension 算子、图优化与稳定性:** 负责 muDNN GELU 接入、GELU fusion 链路修复、benchmark 和热点算子优化, 推动整网 11 个 GELU 全部融合, 真实 shape 耗时降低 36.6%; 独立定位 shape tensor 误入 device path 并重构 HostMemory, 使 inference 500 轮成功率约 30%提升至 1000 轮 100%, 4 万/40 万/80 万轮长跑稳定; Logical_Or 由 21.2 μ s 降至 10.7 μ s, 整网吞吐 8187.48 提升至 8284.65。

开源贡献

2026.08-09

AI Infra 上游开源贡献

- GitHub 已合入 5 个外部项目 PR (XFDG)：Mooncake [#3601/#3604/#3660/#3726](#) (Merged)，覆盖存储持久化、RDMA 端口恢复、内存注销生命周期与队列失败传播；Mirage [#755](#) (Merged) 修复 argmax 中 padding rows 错误取值。

项目与科研

2025.12-至今

基于 PyTorch Extension 的高性能 LLM 量化推理 Runtime 开发

- H200 量化 Runtime 部署与 TP2 扩展：为在 H200 双卡交付 32B 量化模型推理，负责 W4A16/W8A8/FP8 后端适配、FlashAttention-2/4 与 GQA/softcap/SDPA 链路接入，并以 Compute Sanitizer 定位 gemv_kernel_g128 尾组越界、补充边界保护；进一步实现 Qwen2 packed-AWQ TP=2 列/行切分与 NCCL all-reduce。代表 shape 四类 Sanitizer 检查均为 0 error/0 hazard；Qwen2.5-Coder-32B W4A16 使 checkpoint/峰值显存降低 70.5%/66.8%，端到端输出吞吐提升 76.8%。

2026.01-至今

关键 Token 加权的思维链蒸馏 | AAI 2027 已投稿

- 关键 Token 加权 CoT 蒸馏：负责训练、超参调优与 vLLM TP=4 评测，以教师推理 token 扰动后的参考答案似然下降量估计重要性，并用于加权 SFT 与辅助损失；Qwen2.5-7B-Instruct 在 GSM8K/SVAMP 达到 94.01%/94.00%，较最强基线提升 5.51/10.10 个百分点。

综合素质

- 技术方向：聚焦 GPU 推理算子与大模型 Serving/Rollout 优化，具备 CUDA Graph、MoE Router GEMM、异步状态管理、量化 Runtime、Tensor Parallel 和多卡确定性验证经验。
- 开发与性能工程：熟练使用 C/C++、Python、CUDA、Triton、PyTorch Extension；能够使用 Nsys、NCU、Compute Sanitizer 完成算子性能分析与正确性验证。
- 语言与证书：IELTS 6.5、CET-6，持有华为 HCIA-AI 认证；具备英文技术文档阅读、检索与跨仓源码分析能力。