

冯浩然

电话: 15024999885 | 邮箱: 225010160@link.cuhk.edu.cn | 个人网站 | GitHub: XFDDG

教育经历

- 香港中文大学（深圳） | 集成电路与系统 硕士 2025.09-2027.06（预计）
- 山东大学（985） | 电子科学与技术 / 计算机科学与技术 本科 2021.09-2025.06
- 获得荣誉: 山东大学学业奖学金（前 20%）、特长奖学金（竞赛创新）。

实习经历

-  九坤投资-至知创新研究院 | 大模型与高性能计算实习生 2026.04-至今

IQuest-Q1 (320B-A15B) MoE 模型推理内核与 Runtime 优化: 面向已发布模型的 serving 与 RL rollout 执行链路, 负责形状感知选核、CUDA Graph 确定性、跨 step 状态管理与 Tensor Parallel 验证, 推进性能优化、稳定性排障及多卡交付。

推理内核与 Runtime 优化

- **确定性 MoE Router GEMM:** 针对小 M decode 无效计算与 CUDA Graph 确定性约束, 在 vLLM 接入 DeepGEMM/Triton Full-K/persistent 三级后端, 设计选核、Graph preflight、cache/fallback; 48 层 Router GEMM 中位耗时下降 73.39%, 135/135 kernel、20/20 模型场景逐位一致, async OE + prefix-cache hit 下 TP1/TP2 整请求吞吐提升 3.81%/4.36%。
- **OE 异步状态算子:** 针对历史 token 构造的同步与回传开销, 将状态保留在 GPU, 以 Triton fused-hash 优化计算, 并修复请求恢复、slot 复用等跨 step 状态; TP1 通过 28/28 case, 吞吐较同步路径提升 4.99%; TP2/TP4 安全路径均通过 84/84 case、0 mismatch, decode 吞吐提升 4.6%/3.0%。

Rollout 一致性与稳定性

- **R3 Router Replay:** 针对 vLLM rollout 与 Megatron 训练侧路由偏差, 打通路由采集、传输与回放, 建立 response-mask 对齐及 mismatch/fr²/KL 监控; 8×H200、Qwen3-30B-A3B 的 20-step 对照中, 执行路由不一致率从 17%-19% 降至 0, fr²/KL 降低 36-145×/4-7×; 扩展至 128 卡, 在 300B 级模型研发阶段完成 200-step rollout。
- **FlashInfer CUDA Graph hang:** 针对 H200 TP=2 rollout 卡死, 构建两卡最小复现, 通过 eager/Graph、fused/unfused 对照定位 Lamport sentinel 的 FTZ 误判; 回移上游位级判断修复并完成模型级回归, 重复 Graph replay 未再出现 hang 或 timeout。

-  摩尔线程 | 算子与编译器优化实习生 2026.01-2026.04

TensorFlow 国产 GPU 后端适配与优化: 参与 TensorFlow MUSA Extension 开发, 负责 MUSA 算子及优化器适配、GELU 图融合、性能分析工具与长跑稳定性修复。

- **算子与图优化:** 针对 GELU 融合缺失及热点算子开销, 接入 muDNN 并修复融合链路, 实现整网 11 个 GELU 全部融合、真实 shape 耗时降低 36.6%; Logical_Or 从 21.2 μs 降至 10.7 μs, 补充 Adam/AdaMax/GradientDescent 算子实现或修复及测试。
- **长跑稳定性:** 针对推理随机崩溃, 定位 shape tensor 误入 device path 并重构 HostMemory, 修复资源变量更新与 session 关闭问题; 从 500 轮成功率约 30% 提升至 1,000 轮 100%, 通过 4 万/40 万/80 万轮长跑验证。

开源贡献

- **Mooncake (7 个 PR 已合入):** 修复存储持久化、RDMA 端口恢复、内存注销生命周期、队列失败传播、副本选择与多租户清理问题, 补充 macOS 构建兼容支持。 [PR 链接](#)
- **摩尔线程 TME (10 个 PR 已合入):** 实现 GELU 融合及优化器算子, 优化逻辑算子与性能计时, 修复资源变量更新及长跑稳定性问题。 [PR 链接](#)
- **其他项目 (3 个 PR 已合入):** [Ray #66502](#) 修复 Serve gRPC handler 代理路由; [FlashInfer #5171](#) 修复 BF16 rank-major session 测试兼容性; [Mirage #755](#) 修复 Qwen3 demo 的 lm_head padding 配置导致的异常 token。

项目与科研

基于 PyTorch Extension 的高性能 LLM 量化推理 Runtime

2025.12-至今

- **部署目标与后端适配：**面向 H200 双卡上的 32B 量化模型推理交付，负责基于 PyTorch Extension 的 W4A16/W8A8/FP8 后端适配，以及 FlashAttention-2/4、GQA、softcap 与 SDPA 链路接入，完成量化算子到推理 Runtime 的集成。
- **正确性与多卡扩展：**使用 Compute Sanitizer 定位 gemv_kernel_g128 尾组越界并补充边界保护，实现 Qwen2 packed-AWQ TP=2 列/行切分与 NCCL all-reduce；代表 shape 四类 Sanitizer 检查均为 0 error/0 hazard，通过数值、跨 rank token 与交互验收。
- **部署结果：**Qwen2.5-Coder-32B W4A16 的 checkpoint/峰值显存降低 70.5%/66.8%，端到端输出吞吐提升 76.8%，完成 H200 双卡量化推理部署验证。

关键 Token 加权思维链蒸馏 | AAAI 2027 已投稿

2026.01-至今

- **研究问题与职责：**针对通用 CoT 蒸馏对关键推理 token 区分不足的问题，参与“结构恢复、关键 Token 加权监督、偏好优化”三阶段框架，负责模型训练、超参调优与 vLLM TP=4 评测。
- **训练方法：**以逐 token 扰动教师推理后、参考答案生成似然的下降量估计 token 重要性，将其用于加权 SFT 与辅助损失，并完成 LoRA/DPO 训练及对照评测。
- **实验结果：**Qwen2.5-7B-Instruct 在 GSM8K/SVAMP 达到 94.01%/94.00% accuracy，较最强基线提升 5.51/10.10 个百分点；论文已投稿 AAAI 2027。

综合素质

- **开发与性能工程：**C/C++、Python、CUDA、Triton、PyTorch Extension；使用 Nsys、NCU、Compute Sanitizer 完成算子剖析、确定性验证和多卡回归。
- **技术方向：**GPU 推理算子与 Serving/Rollout 优化，具备 MoE Router GEMM、异步状态管理、量化 Runtime、Tensor Parallel 与 CUDA Graph 工程实践。
- **语言与证书：**IELTS 6.5、CET-6、华为 HCIA-AI；具备英文技术文档阅读与跨仓源码分析能力。