

冯浩然

电话: (+86)15024999885 邮箱: 225010160@link.cuhk.edu.cn 个人网站: xfgd.github.io

教育经历

2025.09-2027.06(预计)	香港中文大学 (深圳)	集成电路与系统 硕士
2021.09-2025.06	山东大学 (985)	电子科学与技术/计算机科学与技术 本科

获得荣誉: 山东大学学业奖学金 (前 20%) 山东大学特长奖学金 (竞赛创新)

实习经历

2026.04-至今	九坤投资-AI 研究院	大模型与高性能计算实习生
------------	-------------	--------------

• **300B 级 MoE 基座模型推理内核与 Runtime 优化:** 面向内部 300B 级 MoE 基座模型的 serving 与 RL rollout 执行链路, 负责从 shape 感知选核、CUDA Graph 确定性到跨 step 状态管理和 Tensor Parallel 验证的推理侧优化。

• 推理算子与执行路径优化

- CUDA Graph 下的确定性 MoE Router GEMM:** 针对 batch-invariant decode 小 M 下 persistent tile 无效计算和 Graph replay 不能动态选核的约束, 在 vLLM 工程化接入 DeepGEMM/Triton Full-K/persistent 三级后端; 负责 tensor-signature selector、capture 前数值/Graph preflight、cache/fallback、workspace 生命周期与路径回归, replay 中固化后端决策。48 层 Router GEMM 中位耗时下降 73.39%, 135/135 kernel、20/20 模型场景逐位一致; prefix-cache hit 下 TP1/TP2 整请求性能提升 3.81%/4.36%。
- OE 异步状态算子与多卡安全路径:** 将 recent-token history 和 oe_input_ids 构造留在 GPU, 以 Triton fused-hash 移除 TP1 的 GPU 同步与 H→D 回传 bubble; 同时覆盖 prefill/decode/mixed batch/恢复/slot reuse/reorder 的跨 step 状态语义。TP1 严格 28/28 case 通过、吞吐较 sync +4.99%; TP>1 采用 async-unfused + batch-invariant 安全路径后, TP2/TP4 均 84/84、0 mismatch, decode 吞吐+4.6%/+3.0%。
- CUDA Graph Rollout hang 的 Kernel 级排障:** 针对 H200、vLLM TP=2 FULL CUDA Graph 下 rollout 卡死, 构建两卡最小复现并以 TP/Graph/fused 控制变量定位 fused AllReduce + RMSNorm 中 Lamport -0.0 sentinel 的 FTZ 误判; 采用 0x80000000 位级判断后, 模型级 Graph on/off 反复回归未再出现 hang 或 timeout。

• Rollout 一致性验证

- R3 Router Replay:** 为验证 rollout 推理与训练侧路由对齐, 完成 route 采集、response-mask 对齐、训练回放及 mismatch/fr²/KL 闭环; 8×H200、20-step 中 route mismatch 由 17%-19%降至 0, 并扩展至 128 卡内部 300B 级模型的单轮 200-step 观测。

2026.01-2026.04	摩尔线程	算子与编译器优化实习生
-----------------	------	-------------

• **TensorFlow MUSA Extension 算子与编译器优化:** 负责 TensorFlow on MUSA 的算子支持、图优化与稳定性治理: 完成 muDNN GELU 接入、GELU fusion 链路修复及 benchmark, 推动整网 11 个 GELU 全部融合、真实 shape 耗时降低 36.6%; 独立定位 StridedSlice<int32>/Pack<int32>的 shape tensor 误入 device path 根因并重构 HostMemory 路径, 使 inference 500 轮成功率约 30%提升至 1000 轮 100%, 4 万/40 万/80 万轮长跑稳定; 优化 Logical_Or scalar broadcast 将 21.2 μs 降至 10.7 μs, 整网吞吐由 8187.48 提升至 8284.65。

开源贡献

2026.08-09

AI Infra 上游开源贡献

- GitHub 已合入 5 个外部项目 PR (XFDG)：Mooncake [#3601/#3604/#3660/#3726](#) (Merged)，覆盖存储持久化、RDMA 端口恢复、内存注销生命周期与队列失败传播；Mirage [#755](#) (Merged) 修复 argmax 中 padding rows 错误取值。

项目与科研

2025.12-至今

基于 PyTorch Extension 的高性能 LLM 量化推理 Runtime 开发

- H200 量化 Runtime 部署与 TP2 扩展：为在双 H200 交付 32B 量化模型推理，负责 W4A16/W8A8/FP8 后端、FlashAttention-2/4 与 GQA/softcap/SDPA 链路适配；以 Compute Sanitizer 定位 gemv_kernel_g128 尾组越界并补齐边界保护，继而实现 Qwen2 packed-AWQ TP=2 的 Q/K/V、gate/up 列切分及 O/down 行切分与 NCCL all-reduce。代表 shape 四类 Sanitizer 均 0 error/0 hazard；32B W4A16 使 checkpoint/峰值显存降低 70.5%/66.8%，端到端输出吞吐提升 76.8%。

2026.01-至今

关键 Token 加权的思维链蒸馏 | AAAI 2027 已投稿

- 关键 Token 加权 CoT 蒸馏：负责训练、调优与 vLLM TP=4 评测；Qwen2.5-7B-Instruct 在 GSM8K/SVAMP 达到 94.01%/94.00%，较最强基线提升 5.51/10.10 个百分点。

综合素质

- 技术方向：聚焦 GPU 推理算子与大模型 Serving/Rollout 优化，具备 CUDA Graph、MoE Router GEMM、异步状态管理、量化 Runtime、Tensor Parallel 和多卡确定性验证经验。
- 开发与性能工程：熟练使用 C/C++、Python、CUDA、Triton、PyTorch Extension；能够使用 Nsys、NCU、Compute Sanitizer 完成算子性能分析与正确性验证。
- 语言与证书：IELTS 6.5、CET-6，持有华为 HCIA-AI 认证；具备英文技术文档阅读、检索与跨仓源码分析能力。