

冯浩然

电话: (+86)15024999885 邮箱: 225010160@link.cuhk.edu.cn 个人网站: [xfgd.github.io](https://xfdg.github.io)

教育经历

2025.09-2027.06(预计)	香港中文大学 (深圳)	集成电路与系统 硕士
2021.09-2025.06	山东大学 (985)	电子科学与技术/计算机科学与技术 本科

获得荣誉: 山东大学学业奖学金 (前 20%) 山东大学特长奖学金 (竞赛创新)

实习经历

2026.04-至今	九坤投资-AI 研究院	大模型与高性能计算实习生
------------	-------------	--------------

• **300B 级 MoE 基座模型训练优化:** 参与内部 300B 级 MoE 基座模型训练、RL rollout 与推理基础设施开发, 重点解决 Attention 反向、MoE GEMM-通信竞争、训推路由一致性与多卡稳定性问题。

• 训练算子优化 (重点)

- FA3 deterministic SWA backward 的 dQ 依赖链调度优化:** 通过 Nsys/NCU 与 dQ/dK/dV 因子隔离, 定位 dQ semaphore 依赖链占确定性增量 99.67%; 在原 fused kernel 内将绝对 ticket 改为 contributor-relative ticket, 并使 reverse scheduler 与归约顺序对齐, 不新增 kernel/workspace/D2H。代表 packed shape 完整 backward 由 6.755 ms 降至 1.699 ms (3.98 $\times$), 2K-12K 加速 1.59-5.37 $\times$; 1000 次 bitwise 与 3601/3601 回归通过。
- Sink FC1 GEMM 与通信竞争控核探究:** 训练 trace 显示跨 stream SendRecv/AllGatherV 使 FC1 额外退化 15.48%/28.73%; 搭建 4 $\times$ H200 双 stream 代理, 以 NCCL CTA 预算控制通信并行度、DeepGEMM SM budget 控制计算资源, 完成 121 组粗扫、89 组细扫及 Nsys 重叠验证。AllGatherV 代理中 12 CTA + DG120 使联合 span 降低 12.80%, 同通信设置下控核独立贡献 7.58%。

• RL 训推一致性与 Rollout 稳定性

- R3 Router Replay 与多卡可观测性:** 打通[token, MoE-layer, top-k] route 采集、传输与训练侧回放, 建立 response-mask 对齐、异常检测及 route mismatch/fr²/KL 闭环; 8 $\times$ H200、Qwen3-30B-A3B BF16 的 20-step 对照中, route mismatch 由 17%-19%降至 0, fr²/KL 分别降低 36-145 $\times$ /4-7 $\times$ 。进一步在内部 300B 级 MoE 基座模型完成 128 卡单轮 200-step rollout 与 SwanLab 监控。
- FlashInfer CUDA Graph hang 排查与修复:** 针对 H200、vLLM TP=2 FULL CUDA Graph rollout 卡死, 构建两卡最小复现, 经 TP/Graph/fused 控制变量将根因收敛至 fused AllReduce + RMSNorm 中 Lamport -0.0 sentinel 的 FTZ 误判; 回移 0x80000000 位级判断后, 模型级 Graph on/off 重复回归未再出现 hang 或 timeout。

• 推理算子工程经验

- CUDA Graph 确定性 MoE Router GEMM:** 在 vLLM 中接入 DeepGEMM/Triton Full-K/persistent 三级后端, 完成 selector、capture 前 preflight、cache/fallback 与 workspace 生命周期; 48 层 Router GEMM 中位耗时降低 73.39%, 135/135 kernel 和 20/20 模型场景逐位一致。
- OE 异步状态算子:** 将 recent-token history 与 oe_input_ids 构造保留在 GPU, 修复 prefill/decode/mixed batch/恢复/slot reuse/reorder 的跨 step 状态; TP1 28/28 case 通过、吞吐较 sync +4.99%, TP2/TP4 均 84/84、0 mismatch。

2026.01-2026.04	摩尔线程	算子与编译器优化实习生
-----------------	------	-------------

• **TensorFlow MUSA Extension 算子、图优化与稳定性:** 负责 muDNN GELU 接入、GELU fusion 链路修复、benchmark 和热点算子优化, 推动整网 11 个 GELU 全部融合, 真实 shape 耗时降低 36.6%; 独立定位 shape tensor 误入 device path 并重构 HostMemory, 使 inference 500 轮成功率约 30%提升至 1000 轮 100%, 4 万/40 万/80 万轮长跑稳定; Logical_Or 由 21.2 μ s 降至 10.7 μ s, 整网吞吐 8187.48 提升至 8284.65。

开源贡献

2026.08-09

AI Infra 上游开源贡献

- GitHub 已合入 5 个外部项目 PR (XFDG)：Mooncake [#3601/#3604/#3660/#3726](#) (Merged)，覆盖存储持久化、RDMA 端口恢复、内存注销生命周期与队列失败传播；Mirage [#755](#) (Merged) 修复 argmax 中 padding rows 错误取值。

项目与科研

2026.01-至今

关键 Token 加权的思维链蒸馏 | AAAI 2027 已投稿

- **关键 Token 加权 CoT 蒸馏**：针对通用 CoT 蒸馏对关键推理 token 区分不足的问题，参与“结构恢复—关键 Token 加权监督—偏好优化”三阶段框架，负责模型训练、超参调优与 vLLM TP=4 评测；以逐 token 扰动教师推理后参考答案生成似然的下降量估计重要性，并将其用于加权 SFT 与辅助损失。Qwen2.5-7B-Instruct 在 GSM8K/SVAMP 取得 94.01%/94.00% accuracy，较最强基线提升 5.51/10.10 个百分点。

2025.12-至今

基于 PyTorch Extension 的高性能 LLM 量化推理 Runtime 开发

- **H200 量化 Runtime 与 TP2 扩展**：完成 W4A16/W8A8/FP8、FlashAttention-2/4 与 GQA/softcap/SDPA 链路适配，定位并修复量化 GEMV 尾组越界；实现 packed-AWQ TP=2 切分与 NCCL all-reduce。32B W4A16 在双 H200 上使 checkpoint/峰值显存降低 70.5%/66.8%，端到端输出吞吐提升 76.8%。

综合素质

- **技术方向**：聚焦 GPU 训练算子与大模型训练优化，具备 Attention deterministic backward、MoE GEMM-通信竞争、RL 训推一致性和多卡性能/正确性验证经验。
- **开发与性能工程**：熟练使用 C/C++、Python、CUDA、Triton、PyTorch Extension；能够使用 Nsys、NCU、Compute Sanitizer 完成算子性能分析与正确性验证。
- **语言与证书**：IELTS 6.5、CET-6，持有华为 HCIA-AI 认证；具备英文技术文档阅读、检索与跨仓源码分析能力。