

冯浩然

电话: (+86)15024999885 邮箱: 225010160@link.cuhk.edu.cn 个人网站: xfgd.github.io

教育经历

2025.09-2027.06(预计)
2021.09-2025.06

香港中文大学 (深圳)
山东大学 (985)

集成电路与系统 硕士
电子科学与技术/计算机科学与技术 本科

获得荣誉: 山东大学学业奖学金 (前 20%) 山东大学特长奖学金 (竞赛创新)

实习经历

2026.04-至今

九坤投资-AI 研究院

大模型与高性能计算实习生

• **300B 级 MoE 基座模型训练算子与 RL 训练基础设施**: 面向内部 300B 级 MoE 基座模型, 负责训练侧热点算子与 rollout 训练闭环; 以 trace 归因、最小可控实验和数值/确定性回归推进优化, 核心聚焦 Attention backward 及 MoE 计算一通信竞争。

• 训练算子优化

- FA3 deterministic SWA backward 的 dQ 依赖链调度**: 针对长序列、变长滑动 Attention 的 deterministic backward 回退, 先以 Nsys/NCU 和 dQ/dK/dV 因子隔离将 99.67% 的确定性增量收敛到 dQ semaphore 链; 随后在原 fused main kernel 中将绝对 ticket 改为 contributor-relative ticket, 并对齐 reverse scheduler 与归约顺序, 不新增 kernel/workspace/D2H。代表 packed trace 完整 backward 由 6.755 ms 降至 1.699 ms (3.98 $\times$), 2K-12K 加速 1.59-5.37 $\times$; 1000 次自身 bitwise 与 3601/3601 回归通过。
- MoE Router orth-loss 的 compiled 子图融合**: 针对每层 orth-loss 重复构造 identity、Gram GEMM 之外仍有 normalize、margin、pointwise 与 reduction 碎片化的问题, 推导 identity-free/margin 等价式, 并以 torch.compile(fullgraph=True) 融合周边子图; 识别 V1 in-place 触发 CopySlices backward 回退后, 最终采用默认关闭的 V3 compiled 路径。steady forward GPU operation 由 17 降至 7, 目标函数 forward+backward 提升 18.77%、峰值显存降低 11.11%; 4 $\times$ H200 完整 MoE Layer forward+backward 提升 3.97%, value/gradient 9/9 通过。
- Sink FC1 GEMM—通信竞争的控核代理实验**: 针对训练 trace 中跨 stream SendRecv/AllGatherV 使 FC1 额外退化 15.48%/28.73% 的现象, 先校正真实 BF16 shape 为 8192 $\times$ 3072 $\times$ 3072 并排除“慢 GEMM”误判; 构建 4 $\times$ H200 双 stream 的 all_gather(list) 代理, 以 NCCL CTA 预算控制通信并发、DeepGEMM SM budget 控核, 完成 121 组粗扫、89 组细扫及 Nsys grid/重叠复验。12 CTA + DG120 使代理 joint span 降低 12.80%, 同通信设置下控核独立贡献 7.58%; 结果用于下一步训练 trace 验证, 不外推为 full-step 收益。

• RL 训练侧路由闭环

- R3 Router Replay 的训练侧回放与观测**: 为消除 rollout 侧 vLLM 与训练侧 Megatron 的 MoE 路由偏差, 打通[token, MoE-layer, top-k] 采集、传输、response-mask 对齐与训练回放, 建立 route mismatch/fr²/KL 异常闭环; 8 $\times$ H200、20-step 对照中 mismatch 由 17%-19% 降至 0, fr²/KL 降低 36-145 $\times$ /4-7 $\times$, 并完成 128 卡内部 300B 级模型单轮 200-step 监控运行。

2026.01-2026.04

摩尔线程

算子与编译器优化实习生

- GELU 融合与图优化**: 针对大图场景中部分 GELU 未被融合、整网图优化收益受限的问题, 负责 muDNN GELU 接入、fusion 链路修复与 benchmark 建设; 补齐融合条件和回归验证后, 推动整网 11 个 GELU 全部融合, 真实 shape 耗时降低 36.6%。
- 整网稳定性与热点算子优化**: 针对长跑 OOM/随机崩溃及 Logical_Or 热点, 定位 StridedSlice<int32>/Pack<int32> 将 shape tensor 误送 device path 的根因并重构 HostMemory 路径, 使 inference 500 轮成功率由约 30% 提升至 1000 轮 100%, 4 万/40 万/80 万轮长跑稳定; 同时优化 Logical_Or scalar broadcast 并补齐 Logical_And 测试, 平均耗时由 21.2 μ s 降至 10.7 μ s, 整网吞吐由 8187.48 提升至 8284.65。

开源贡献

2026.08-09

AI Infra 上游开源贡献

- GitHub 已合入 5 个外部项目 PR (XFDG)：Mooncake [#3601/#3604/#3660/#3726](#) (Merged)，覆盖存储持久化、RDMA 端口恢复、内存注销生命周期与队列失败传播；Mirage [#755](#) (Merged) 修复 argmax 中 padding rows 错误取值。

项目与科研

2026.01-至今

关键 Token 加权的思维链蒸馏 | AAAI 2027 已投稿

- 关键 Token 加权 CoT 蒸馏：针对通用 CoT 蒸馏无法区分关键推理 token 的问题，参与“结构恢复—关键 Token 加权监督—偏好优化”三阶段训练框架，负责训练、超参调优和 vLLM TP=4 评测；以逐 token 扰动教师推理后参考答案的生成似然下降量估计重要性，并用于加权 SFT 与辅助损失。Qwen2.5-7B-Instruct 在 GSM8K/SVAMP 达到 94.01%/94.00%，较最强基线提升 5.51/10.10 个百分点；论文已投稿 AAAI 2027。

2026.08-09

Blackwell 多精度训练验证 (B200)

- Blackwell 多精度训练验证：为验证低精度训练链路的数值、重启与强扩展稳定性，以 random-init + mock data 重建 dense decoder 工作负载，建立 BF16/FP8/MXFP8/NVFP4、1-8 GPU 与 80 个 Transformer Engine forward+backward shape 的矩阵，并覆盖 checkpoint save/load/restart。BF16/NVFP4 强扩展 24/24 正式运行、720 optimizer steps 的 step-time CV<1%；8 卡 NVFP4 相对 BF16 吞吐 1.265×、板卡 tokens/J 1.434×，80/80 有限值且 checkpoint 恢复 loss 相对差异 1.38e-6（不外推真实数据收敛）。

综合素质

- 技术方向：聚焦 GPU 训练算子与大模型训练优化，具备 Attention backward、MoE GEMM—通信竞争、RL 训练回放和多卡确定性/数值验证经验。
- 开发与性能工程：熟练使用 C/C++、Python、CUDA、Triton、PyTorch Extension；能够使用 Nsys、NCU、Compute Sanitizer 完成算子性能分析与正确性验证。
- 语言与证书：IELTS 6.5、CET-6，持有华为 HCIA-AI 认证；具备英文技术文档阅读、检索与跨仓源码分析能力。