

冯浩然

电话: 15024999885 | 邮箱: 225010160@link.cuhk.edu.cn | 个人网站 | GitHub: XFDG

教育经历

香港中文大学（深圳） | 集成电路与系统 硕士

2025.09-2027.06（预计）

山东大学（985） | 电子科学与技术 / 计算机科学与技术 本科

2021.09-2025.06

获得荣誉: 山东大学学业奖学金（前 20%）、特长奖学金（竞赛创新）。

实习经历

 九坤投资-至知创新研究院 | 大模型与高性能计算实习生

2026.04-至今

IQuest-Q1 (320B-A15B) MoE 模型训练算子与 RL 基础设施: 参与已发布模型的训练与 RL rollout 基础设施开发, 围绕 Attention backward、MoE Router 和计算通信竞争, 负责性能归因、算子实现及数值/确定性回归。

训练算子优化

- **FA3 确定性 SWA backward 调度:** 针对长序列确定性反向传播回退, 负责归因、调度实现与验证; 通过 Nsys/NCU 定位 dQ semaphore 依赖链, 在原 fused kernel 内实现 contributor-relative ticket 并对齐 reverse scheduler。代表 packed shape 完整 backward 从 6.755 ms 降至 1.699 ms (3.98 $\times$), 2K-12K 加速 1.59-5.37 $\times$; 通过 3,601 项回归及 1,000 次逐位确定性测试并交付 wheel。
- **Sink FC1 计算与通信竞争优化:** 针对跨 stream 通信导致 FC1 退化, 搭建 4 $\times$ H200 双 stream 代理, 以 NCCL CTA 预算和 DeepGEMM SM budget 联合控核, 完成 121 组粗扫、89 组细扫及复验; AllGatherV 代理联合耗时降低 12.80%, 同通信设置下控核独立贡献 7.58%。
- **MoE Router orth-loss 子图融合:** 针对每层重复构造 identity 及 normalize、margin、reduction 等碎片化计算, 推导等价式并以 torch.compile(fullgraph=True) 融合周边子图; 淘汰完整层回退的 in-place 方案后采用默认关闭的 V3 路径。steady forward GPU operation 从 17 降至 7, 目标函数 forward+backward 耗时降低 18.77%、峰值显存降低 11.11%; 4 $\times$ H200 完整 MoE Layer 耗时降低 3.97%, value/gradient 9/9 通过。

RL 训练侧路由回放

- **R3 Router Replay:** 针对 vLLM rollout 与 Megatron 训练侧路由偏差, 打通路由采集、传输与回放, 建立 response-mask 对齐及 mismatch/fr²/KL 监控; 8 $\times$ H200、Qwen3-30B-A3B 的 20-step 对照中, 执行路由不一致率从 17%-19% 降至 0, fr²/KL 降低 36-145 $\times$ /4-7 $\times$; 扩展至 128 卡, 在 300B 级模型研发阶段完成 200-step rollout。



摩尔线程 | 算子与编译器优化实习生

2026.01-2026.04

TensorFlow 国产 GPU 后端适配与优化: 参与 TensorFlow MUSA Extension 开发, 负责 MUSA 算子及优化器适配、GELU 图融合、性能分析工具与长跑稳定性修复。

- **算子与图优化:** 针对 GELU 融合缺失及热点算子开销, 接入 muDNN 并修复融合链路, 实现整网 11 个 GELU 全部融合、真实 shape 耗时降低 36.6%; Logical_Or 从 21.2 μ s 降至 10.7 μ s, 补充 Adam/AdaMax/GradientDescent 算子实现或修复及测试。
- **长跑稳定性:** 针对推理随机崩溃, 定位 shape tensor 误入 device path 并重构 HostMemory, 修复资源变量更新与 session 关闭问题; 从 500 轮成功率约 30% 提升至 1,000 轮 100%, 通过 4 万/40 万/80 万轮长跑验证。

开源贡献

- **Mooncake (7 个 PR 已合入):** 修复存储持久化、RDMA 端口恢复、内存注销生命周期、队列失败传播、副本选择与多租户清理问题, 补充 macOS 构建兼容支持。[PR 链接](#)
- **摩尔线程 TME (10 个 PR 已合入):** 实现 GELU 融合及优化器算子, 优化逻辑算子与性能计时, 修复资源变量更新及长跑稳定性问题。[PR 链接](#)
- **其他项目 (3 个 PR 已合入):** [Ray #66502](#) 修复 Serve gRPC handler 代理路由; [FlashInfer #5171](#) 修复 BF16 rank-major session 测试兼容性; [Mirage #755](#) 修复 Qwen3 demo 的 lm_head padding 配置导致的异常 token。

项目与科研

关键 Token 加权思维链蒸馏 | AAAI 2027 已投稿

2026.01-至今

- **研究问题与职责：**针对通用 CoT 蒸馏对关键推理 token 区分不足的问题，参与“结构恢复、关键 Token 加权监督、偏好优化”三阶段框架，负责模型训练、超参调优与 vLLM TP=4 评测。
- **训练方法：**以逐 token 扰动教师推理后、参考答案生成似然的下降量估计 token 重要性，将其用于加权 SFT 与辅助损失，并完成 LoRA/DPO 训练及对照评测。
- **实验结果：**Qwen2.5-7B-Instruct 在 GSM8K/SVAMP 达到 94.01%/94.00% accuracy，较最强基线提升 5.51/10.10 个百分点；论文已投稿 AAAI 2027。

Blackwell 多精度训练验证 (B200)

2026.08-09

- **验证目标与实现：**为验证低精度训练链路的数值、重启与强扩展稳定性，以 random-init + mock data 重建 dense decoder 工作负载，完成四种精度在 1/8 卡上的测试、BF16/NVFP4 在 1/2/4/8 卡上的强扩展，以及 80 项 Transformer Engine 前后向用例，覆盖 checkpoint save/load/restart。
- **验证结果：**BF16/NVFP4 强扩展 24/24 次运行、共 720 optimizer steps 通过，重复运行的 step-time 中位数 CV<1%；8 卡 NVFP4 相对 BF16 吞吐 1.265×、板卡 tokens/J 1.434×，80/80 用例有限值，BF16 checkpoint 恢复 loss 相对差异 1.38e-6；结果限定于 mock 工作负载，不外推真实数据收敛。

综合素质

- **开发与性能工程：**C/C++、Python、CUDA、Triton、PyTorch Extension；使用 Nsys、NCU、Compute Sanitizer 完成算子剖析、确定性验证和多卡回归。
- **技术方向：**GPU 训练算子与大模型训练优化，具备 Attention backward、MoE Router、计算通信竞争、RL 路由回放及多卡数值/确定性验证经验。
- **语言与证书：**IELTS 6.5、CET-6、华为 HCIA-AI；具备英文技术文档阅读与跨仓源码分析能力。