

冯浩然

电话: (+86)15024999885 邮箱: 225010160@link.cuhk.edu.cn 个人网站: xfgd.github.io

教育经历

2025.09-2027.06(预计)	香港中文大学 (深圳)	集成电路与系统 硕士
2021.09-2025.06	山东大学 (985)	电子科学与技术/计算机科学与技术 本科
获得荣誉: 山东大学学业奖学金 (前 20%) 山东大学特长奖学金 (竞赛创新)		

实习经历

2026.04-至今	九坤投资-AI 研究院	大模型与高性能计算实习生
------------	-------------	--------------

• **300B 级 MoE 基座模型开发与优化:** 参与内部 300B 级 MoE 基座模型的训练、推理与 RL rollout 基础设施开发, 围绕训练算子、推理算子和训推一致性进行性能优化、稳定性排障与多卡验证。

• 训练算子支持

- FA3 deterministic SWA backward 的 dQ 依赖链调度优化:** 针对长序列、变长滑窗 Attention 的 deterministic backward 回退, 负责问题归因、调度实现与验证; 通过 Nsys/NCU 和 dQ/dK/dV 因子隔离, 确认 dQ semaphore 依赖链占确定性增量 99.67%。在原 fused main kernel 中将绝对 ticket 改为 contributor-relative ticket, 并使 reverse scheduler 与归约顺序对齐; 复用既有长度元数据分流, 短序列保留 fallback, 不新增 kernel/workspace/D2H。代表 packed shape 完整 backward 由 6.755 ms 降至 1.699 ms (3.98 $\times$), 2K-12K 加速 1.59-5.37 $\times$; 1000 次自身 bitwise、3601/3601 回归通过并交付 wheel。
- Sink FC1 GEMM 与通信竞争控核探究:** 训练 trace 显示跨 stream SendRecv/AllGatherV 使 FC1 额外退化 15.48%/28.73%; 纠正实际 BF16 shape 为 8192 $\times$ 3072 $\times$ 3072, 确认约 200 μ s 基线正常。搭建 4 $\times$ H200 双 stream 代理, 以 NCCL CTA 预算控制通信并行度、DeepGEMM SM budget 控制计算资源, 并用 Nsys 校验实际 grid 与重叠; 完成 121 组粗扫、89 组细扫及复验。AllGatherV 代理中 12 CTA + DG120 将联合 span 降低 12.80%, 同通信设置下控核独立贡献 7.58%; AllToAllV 主要收益来自通信并行度, 不归因为 GEMM。

• 推理算子支持

- CUDA Graph 下的确定性 MoE Router GEMM:** 针对 batch-invariant decode 小 M 下 persistent tile 无效计算及 CUDA Graph 确定性约束, 负责在 vLLM 工程化接入 DeepGEMM/Triton Full-K/persistent 三级后端; 设计 tensor-signature selector、capture 前数值与 Graph preflight、cache/fallback、workspace 生命周期和路径回归, replay 固化后端、不在图内动态选核。48 层 Router GEMM 中位耗时下降 73.39%, 135/135 kernel、20/20 模型场景逐位一致; prefix-cache hit 下 TP1/TP2 整请求处理性能提升 3.81%/4.36%。
- OE 异步状态算子:** 将 recent-token history 与 oe_input_ids 构造保留在 GPU, 以 Triton fused-hash 消除 TP1 同步与回传, 并修复 prefill/decode/mixed batch/请求恢复/slot reuse/reorder 的跨 step 状态; TP1 严格 28/28 case 通过、吞吐较 sync +4.99%。TP>1 采用 async-unfused + batch-invariant 安全路径后, TP2/TP4 均达 84/84、0 mismatch, decode 吞吐+4.6%/+3.0%。

• RL 训推一致性与 Rollout 稳定性

- R3 Router Replay 与多卡可观测性:** 针对 rollout 侧 vLLM 与训练侧 Megatron 的 MoE 路由偏差, 打通[token, MoE-layer, top-k] route 采集、传输与训练侧回放, 建立 response-mask 对齐、异常检测及 route mismatch/fr²/KL 闭环; 8 $\times$ H200、Qwen3-30B-A3B BF16 的 20-step 对照中, route mismatch 由 17%-19%降至 0, fr²/KL 分别降低 36-145 $\times$ /4-7 $\times$ 。进一步扩展至 128 卡集群, 在内部 300B 级 MoE 基座模型上完成竞赛题单轮 200-step rollout 并接入 SwanLab 监控, 关键指标与 8 卡对照一致。
- FlashInfer CUDA Graph hang 排查与修复:** 针对 H200、vLLM TP=2 FULL CUDA Graph rollout 卡死, 构建两卡最小复现, 经 TP1/TP2、eager/FULL Graph、fused/unfused 等控制变量将根因收敛至 fused AllReduce + RMSNorm 中 Lamport -0.0 sentinel 的 FTZ 误判; 回移上游 0x80000000 位级判断修复并完成模型级 Graph on/off 回归, 重复 Graph replay 未再出现 hang 或 timeout。

2026.01-2026.04

摩尔线程

算子与编译器优化实习生

• **TensorFlow MUSA Extension 算子、图优化与稳定性:** 负责 muDNN GELU 接入、GELU fusion 链路修复、benchmark 和热点算子优化, 推动整网 11 个 GELU 全部融合, 真实 shape 耗时降低 36.6%; 独立定位 shape tensor 误入 device path 并重构 HostMemory, 使 inference 500 轮成功率约 30%提升至 1000 轮 100%, 4 万/40 万/80 万轮长跑稳定; Logical_Or 由 21.2 μ s 降至 10.7 μ s, 整网吞吐 8187.48 提升至 8284.65。

开源贡献

2026.08-09

AI Infra 上游开源贡献

- GitHub 已合入 5 个外部项目 PR (XFDG)：Mooncake [#3601/#3604/#3660/#3726](#) (Merged)，覆盖存储持久化、RDMA 端口恢复、内存注销生命周期与队列失败传播；Mirage [#755](#) (Merged) 修复 argmax 中 padding rows 错误取值。

项目与科研

2025.12-至今

基于 PyTorch Extension 的高性能 LLM 量化推理 Runtime 开发

- H200 量化 Runtime 部署与 TP2 扩展：为在 H200 双卡交付 32B 量化模型推理，负责 W4A16/W8A8/FP8 后端适配、FlashAttention-2/4 与 GQA/softcap/SDPA 链路接入，并以 Compute Sanitizer 定位 gemv_kernel_g128 尾组越界、补充边界保护；进一步实现 Qwen2 packed-AWQ TP=2 列/行切分与 NCCL all-reduce。代表 shape 四类 Sanitizer 检查均为 0 error/0 hazard；Qwen2.5-Coder-32B W4A16 使 checkpoint/峰值显存降低 70.5%/66.8%，端到端输出吞吐提升 76.8%，通过数值、跨 rank token 与交互验收。

2026.01-至今

关键 Token 加权的思维链蒸馏 | AAI 2027 已投稿

- 关键 Token 加权 CoT 蒸馏：针对通用 CoT 蒸馏对关键推理 token 区分不足的问题，参与“结构恢复—关键 Token 加权监督—偏好优化”三阶段框架，负责模型训练、超参调优与 vLLM TP=4 评测；以逐 token 扰动教师推理后参考答案生成似然的下降量估计重要性，并将其用于加权 SFT 与辅助损失。完成 LoRA/DPO 训练后，Qwen2.5-7B-Instruct 在 GSM8K/SVAMP 取得 94.01%/94.00% accuracy，较最强基线提升 5.51/10.10 个百分点；论文已投稿 AAI 2027。

综合素质

- 技术方向：关注 GPU 高性能算子开发与大模型训练/推理系统优化，具备 Attention、MoE Router、量化 GEMM、异步状态管理、Tensor Parallel 与 CUDA Graph 工程实践。
- 开发与性能工程：熟练使用 C/C++、Python、CUDA、Triton、PyTorch Extension；能够使用 Nsys、NCU、Compute Sanitizer 完成算子性能分析与正确性验证。
- 语言与证书：IELTS 6.5、CET-6，持有华为 HCIA-AI 认证；具备英文技术文档阅读、检索与跨仓源码分析能力。