

冯浩然

电话: (+86)15024999885 邮箱: 225010160@link.cuhk.edu.cn



教育经历

2025. 09–2027. 06 (预计)	香港中文大学 (深圳)	集成电路与系统 硕士
2021. 09–2025. 06	山东大学 (985)	电子科学与技术/计算机科学与技术 本科
获得荣誉: 山东大学学业奖学金 (前 20%) 山东大学特长奖学金 (竞赛创新)		

实习经历

2026. 04–至今	九坤投资-AI 研究院	大模型与高性能计算实习生
-------------	-------------	--------------

- FlashInfer CUDA Graph 稳定性修复:** 针对 H200 上 vLLM TP=2 FULL CUDA Graph 的 rollout 卡死问题, 构建两卡最小复现并将根因收敛到 fused AllReduce + RMSNorm 的通信轮询逻辑: 原实现通过浮点比较识别 Lamport -0.0 sentinel, FTZ 会将合法 FP32 负次正规数误判为负零, 导致轮询无法退出、GPU Kernel 不结束并最终触发 rollout timeout。在现用 FlashInfer 版本中将 sentinel 判断改为 0x80000000 位级精确比较后, 两卡最小复现及模型级 Graph on/off 回归全部通过, 重复 Graph replay 未再出现 timeout 或 hang。
- R3 Router Replay:** 复现小米论文, 针对 vLLM rollout 与 Megatron 训练侧 MoE 路由不一致问题, 打通 [token, MoE-layer, top-k] route 采集、传输与回放链路, 并建立 response-mask 对齐及异常检测, 覆盖 18 项 CPU 测试; 在 8×H200、Qwen3-30B-A3B BF16 的 20-step 实验中, 将 route mismatch 由 17%–19% 降至 0, F_{tau2} 降低 36–145×、KL 降低 4–7×; 最终扩展至 128 卡集群, 使用内部 300b 模型完成竞赛题单轮 200-step 运行并接入 SwanLab 监控, 结果与 8 卡情况对齐, 将改动合并进开发仓。
- OE 异步算子开发:** 将 recent-token history 与 oe_input_ids 构造保留在 GPU, 使用 Triton fused-hash 减少 GPU→CPU 同步等待及 CPU→GPU 回传, 并修复 prefill、decode、mixed batch、请求恢复、slot reuse 与 reorder 场景下的跨 step 状态更新问题; 三类执行阶段均通过正确性验证。TP1 下严格 28-case 矩阵全部通过, 吞吐较 sync 提升 4.99%、较 async-unfused 提升 1.94%; TP2/TP4 采用 async-unfused + batch-invariant 安全路径, 确定性通过率分别由 41/84、63/84 提升至 84/84, 均为 0 mismatch, decode 吞吐分别提升约 4.6%/3.0%。

2026. 01–2026. 04	摩尔线程	算子与编译器优化实习生
-------------------	------	-------------

- TensorFlow MUSA Extension 开发:** 负责 TensorFlow on MUSA 的算子支持、插件集成、测试验证及图优化; 完成 muDNN GELU 接入、GELU fusion 链路修复与 benchmark 建设, 解决大图场景下部分 GELU 未融合问题, 推动整网 11 个 GELU 全部融合, 真实 shape testcase 测试耗时降低约 36.6%。
- 解决 OOM / 随机崩溃:** 在整网长跑情况下, 独立定位 shape tensor 在 StridedSlice<int32> / Pack<int32> 链路中错误进入 device path 的根因, 重构 HostMemory 路径并完成修复; 将 inference 500 轮成功率从约 30% 提升至 1000 轮成功率 100%, 并通过 4 万 / 40 万 / 80 万轮长跑验证, 结果均稳定。
- 热点算子优化与稳定性修复:** 其中对 Logical_Or 的 scalar broadcast 路径做了专项优化并补齐 Logical_And 测试, 使 Logical_Or 平均耗时从 21.2 μ s 降至 10.7 μ s, 同配置整网吞吐从 8187.48 提升至 8284.65; 同时还完成 AddV2 hot path 优化与 ResourceApplyAdam graph mode 结果对齐等工作

项目经历

2025.12-至今

基于 PyTorch Extension 的高性能 LLM 量化推理 Runtime 开发

- **量化 Runtime 与后端适配：**在支持 W4A16 AWQ、W8A8 SmoothQuant 与 FP8 的 PyTorch Extension Runtime 中，完成 FlashAttention-2/4 可配置接入，补齐 GQA 的 KV heads 展开、softcap mask 及 SDPA Torch 回退；将 CUDA arch、cache 与模型路径改动态/可选配置，使工程可在本地 GPU（5060）与 H200 环境构建部署。
- **H200 Kernel 与 Tensor Parallel：**在 2×H200（SM90/CUDA 13.0）环境完成 AWQ Runtime 迁移；使用 NVIDIA Compute Sanitizer 将 decode 非法访存定位到 `gemv_kernel_g128`：当 `K/group_size=7` 时 warp 仍按 8 组读取，导致末尾 lane 越界访问 `scale/zero`；增加 group 边界保护、current-stream launch 与错误检查后，代表 `shape memcheck/initcheck/synccheck/racecheck` 均为 0 error/0 hazard；进一步实现 Qwen2 packed-AWQ TP=2，完成 Q/K/V、gate/up 列切分及 O/down 行切分与 NCCL all-reduce。
- **32B 量化部署与验证：**基于 128x512 本地代码校准完成 Qwen2.5-Coder-32B W4A16 量化与双卡交付；在同模型、prompt、64-token、3 次重复的公平对照下，checkpoint 由 61.04 GiB 降至 18.02 GiB（**-70.5%**），E2E output 吞吐（含 prefill、首 token 与 decode）由 2.53 提升至 4.47 tok/s（**+76.8%**），运行期峰值显存由 32.02 降至 10.63 GiB/rank（**-66.8%**）；通过 10 组 CUDA/PyTorch 数值对照（最大绝对误差 0.007812）、跨 rank token 一致性及中文交互验收。

专业技能

- **技术方向：**聚焦 RL Infra、GPU 算子与性能优化、大模型推理系统，具备 MoE 训推一致性、多卡推理及量化 Runtime 开发经验。
- **编程经验：**熟练使用 C/C++、Python，具备 CUDA、Triton 与 PyTorch Extension 开发经验；具有 PyTorch、veRL、Megatron-LM、vLLM、FlashInfer、CUTLASS、NCCL 等技术栈的工程实践；能够使用 Nsight Systems（Nsys）、Nsight Compute（NCU）与 NVIDIA Compute Sanitizer 完成 GPU Kernel 性能分析、故障定位、多卡正确性验证及 Kernel—Operator—E2E 分层性能回归。
- **综合能力：**具备跨仓源码分析、问题最小复现、控制变量实验、自动化测试、Benchmark 建设及技术文档沉淀能力；使用 Claude Code、Codex 辅助代码检索、实现与测试，并通过人工 Review 和正确性/性能回归保障交付质量；具备英文技术文档阅读与检索能力（IELTS 6.5、CET-6），持有华为 HCIA-AI 认证。