

冯浩然

电话: (+86)15024999885 邮箱: 225010160@link.cuhk.edu.cn



教育经历

2025.09-2027.06(预计)	香港中文大学 (深圳)	集成电路与系统 硕士
2021.09-2025.06	山东大学 (985)	电子/计算机科学与技术 本科
获得荣誉: 山东大学学业奖学金 (前 20%) 山东大学特长奖学金 (竞赛创新)		

实习经历

2024.08-2024.12	华为	通用软件工程师
- 维护大规模 C/C++ 代码库静态分析工具链, 通过日志分析与规则重构, 将 CI 流水线核心场景误报率降低 35%。 - 独立开发 Python 自动化代码生成工具, 将规则开发与验证周期缩短 40%, 支持 60+ 条核心规则快速迭代。		
2026.02-至今	摩尔线程	算子与编译器优化实习生
- 参与公司 TensorFlow MUSA Extension 插件工程开发, 面向 TensorFlow on MUSA 的算子支持、插件集成与调试分析, 覆盖算子执行链路、测试验证及图优化相关工作。 - 独立提交并合并官方仓库 PR #57, 新增/完善 kernel timing 调试功能, 增强了 kernel 级性能观测与问题定位能力。https://github.com/MooreThreads/tensorflow_musa_extension/pull/57 - 基于日志、环境变量和测试脚本构建调试闭环, 支持对算子执行时间、统计信息与异常行为进行分析, 加深了对 TensorFlow 插件机制、异构设备运行时、算子测试流程的理解。		

项目经历

2025.12-至今	基于 PyTorch Extension 的高性能 LLM 量化推理 Runtime 开发
- 推理 Runtime 设计：面向 Llama3/Qwen 等大模型部署中的显存瓶颈，设计并实现支持 W8A8 / FP8 / AWQ 等量化策略的轻量级推理 Runtime。 - 核心算子开发：基于 NVIDIA CUTLASS 开发并封装高性能 W8A8 (INT8) GEMM 算子，重构 Transformer 中 Linear 层逻辑，完成量化数据结构设计、内存布局优化及前向计算端到端正确性验证。 - 性能优化演进：使用 Nsight Compute (NCU) 等 profiling 工具分析 kernel 性能瓶颈，持续推进基于 Cutlass EVT 的算子融合以降低 Kernel Launch 开销，并针对 Decode 阶段设计手写 GEMV 算子以优化带宽受限场景下的推理性能。	
2024.03-2024.06	基于 ResNet 的图像分类与半监督学习研究
- 项目内容：基于 ResNet-18 架构搭建端到端图像分类流水线，深入探究 CNN 卷积计算特性。针对训练数据类别不平衡与标签稀缺痛点，设计了包含半监督学习（Pseudo-labeling）与混合数据增强的优化策略。 - 量化成果：通过上述策略，成功解决了过拟合问题，将模型在测试集上的 Top-1 准确率从 Baseline 的 51.8% 提升至 85.1%。获得 kaggle 比赛第七名的成绩。https://www.kaggle.com/competitions/dl2023autumexp2	

专业技能:

- 技术方向: 具备深度学习、异构计算与底层性能优化背景, 获得华为 HCIA-AI 认证, 关注 AI 系统中的软硬件协同设计与数据吞吐优化。
- 计算机技能: C/C++、Python、CUDA、熟练使用 Codex 等 AI 辅助开发工具进行代码生成、调试与原型验证。
- 英语: IELTS 6.5, CET-6, 具备良好的英文技术文档阅读、检索与工程协作能力。