

面试官您好，我叫冯浩然，目前在香港中文大学（深圳）攻读集成电路与系统硕士，本科毕业于山东大学。我的主要方向是大模型训推系统、RL Infra 和 GPU 性能优化。

目前我在九坤投资 AI 研究院实习，主要做大模型训练与推理基础设施。第一，我定位并修复了 H200 上 vLLM TP=2 Full CUDA Graph 的 rollout 卡死：通过两卡最小复现将问题收敛到 FlashInfer fused AllReduce + RMSNorm 的轮询逻辑，确认 FTZ 导致 Lamport sentinel 被误判，改为位级判断后模型级回归全部通过。第二，我完成 R3 Router Replay 的 route 采集、传输与回放链路，在 8 张 H200 上把 vLLM 与 Megatron 的 route mismatch 从 17%-19% 降到 0，并扩展到 128 卡。第三，我优化了 H200 上确定性 Router GEMM，DeepGEMM 路径将 48 层中位耗时从 789 微秒降到 210 微秒，降低 73.4%，同时保持 kernel 和整模型逐位一致。

此前在摩尔线程，我负责 TensorFlow MUSA Extension 的算子与图优化：修复 GELU 融合链路，使整网 11 个 GELU 全部融合、真实 shape 耗时降低 36.6%；还定位并修复 shape tensor HostMemory 路径导致的 OOM 和随机崩溃，将 1000 轮推理成功率提升到 100%，并通过最高 80 万轮长跑验证。

这些经历让我形成了从最小复现、源码与 Kernel 定位，到正确性回归和性能验证的完整工作方法。我希望继续从事 AI Infra、GPU 算子及大模型训练推理系统相关工作。谢谢。