

冯浩然

电话: (+86)15024999885 邮箱: 225010160@link.cuhk.edu.cn [个人网站](#)



教育经历

2025.09-2027.06(预计)

香港中文大学 (深圳)

集成电路与系统 硕士

2021.09-2025.06

山东大学 (985)

电子科学与技术/计算机科学与技术 本科

获得荣誉: 山东大学学业奖学金 (前 20%) 山东大学特长奖学金 (竞赛创新)

实习经历

2026.04-至今

九坤投资-AI 研究院

大模型与高性能计算实习生

- **RL 算子支持**: 面向 MoE-RL rollout 的训推一致性、异步解码与 CUDA Graph 卡死, 负责 Router Replay 的 route/logprob 可观测及 A/B 指标闭环, 实现 GPU token-history/Triton fused-hash 和 TP>1 batch-invariant 安全路径, 并将 TP2 hang 定位到 FlashInfer Lamport sentinel 的 FTZ 误判、回移上游位级修复; 20-step 对照中 replay target 达到 0 mismatch, ft²/KL 分别降低 36-145×/4-7×; TP1 吞吐较 sync 提升 **4.99%**, TP2/TP4 各 84 case 均 0 mismatch, decode 吞吐提升 **4.6%/3.0%**, Graph capture/replay 稳定通过。
- **训练算子支持**: 针对长序列变长 SWA deterministic backward 异常, 结合 Nsys/NCU 因子隔离确认 dQ semaphore 依赖链占确定性增量 99.67%; 在 FA3 原 fused main kernel 内对齐 reverse scheduler 与 contributor-relative ticket, 并基于 host 已有长度元数据动态分流, 不新增 kernel/workspace/D2H; 代表 packed shape 完整 backward 由 6.755 ms 降至 1.699 ms (**3.98×**), 2K-12K 加速 **1.59-5.37×**, 3601/3601 回归及 1000 次 bitwise 确定性通过, 短序列无显著退化并交付 wheel。
- **推理算子支持**: 针对 batch-invariant MoE Router 在小 M decode 中的无效计算及 CUDA Graph 动态选核风险, 在 vLLM 中工程化接入 DeepGEMM/Full-K/persistent 三级后端, 负责 tensor-signature selector、capture 前数值/Graph preflight、cache/fallback 及 workspace 生命周期; 48 层 Router GEMM 中位耗时下降 **73.39%**、每 step 的 device-kernel 时长之和下降 **6.16%**, 135/135 kernel 与 20/20 模型场景 bitwise 一致; prefix-cache hit 下 TP1/TP2 整请求处理性能提升 **3.81%/4.36%**, 与异步解码联合提升 **11.05%/8.26%**。

2026.01-2026.04

摩尔线程

算子与编译器优化实习生

- **TensorFlow MUSA Extension 开发**: 负责 TensorFlow on MUSA 的算子支持、插件集成、测试验证及图优化; 完成 muDNN GELU 接入、GELU fusion 链路修复与 benchmark 建设, 解决大图场景下部分 GELU 未融合问题, 推动整网 11 个 GELU 全部融合, 真实 shape testcase 测试耗时降低约 **36.6%**。
- **解决 OOM / 随机崩溃**: 在整网长跑情况下, 独立定位 shape tensor 在 StridedSlice<int32> / Pack<int32> 链路中错误进入 device path 的根因, 重构 HostMemory 路径并完成修复; 将 inference 500 轮成功率从约 30% 提升至 1000 轮成功率 **100%**, 并通过 4 万 / 40 万 / 80 万轮长跑验证, 结果均稳定。

开源贡献

2026.08

AI Infra 上游开源贡献

- Mooncake | [PR #3604](#) / [#3601](#) (Merged): 修复 RDMA 端口恢复后 stale QP 持续复用导致的传输停滞与超时; 重构存储写序, 在元数据提交前执行 fdatasync, 并补充同步失败与残留文件清理回归测试。

项目与科研

2025.12-至今

基于 PyTorch Extension 的高性能 LLM 量化推理 Runtime 开发

- **量化 Runtime 与后端适配**：在支持 W4A16 AWQ、W8A8 SmoothQuant 与 FP8 的 PyTorch Extension Runtime 中，完成 FlashAttention-2/4 可配置接入，补齐 GQA 的 KV heads 展开、softcap mask 及 SDPA Torch 回退：将 CUDA arch、cache 与模型路径改动态/可选配置，使工程可在本地 GPU（5060）与 H200 环境构建部署。
- **H200 Kernel 与 Tensor Parallel**：在 2×H200（SM90/CUDA 13.0）环境完成 AWQ Runtime 迁移；使用 NVIDIA Compute Sanitizer 将 decode 非法访存定位到 gemv_kernel_g128：当 K/group_size=7 时 warp 仍按 8 组读取，导致末尾 lane 越界访问 scale/zero：增加 group 边界保护、current-stream launch 与错误检查后，代表 shape memcheck/initcheck/synccheck/racecheck 均为 0 error/0 hazard：进一步实现 Qwen2 packed-AWQ TP=2，完成 Q/K/V、gate/up 列切分及 O/down 行切分与 NCCL all-reduce。
- **32B 量化部署与验证**：基于 128x512 本地代码校准完成 Qwen2.5-Coder-32B W4A16 量化与双卡交付；在同模型、prompt、64-token、3 次重复的公平对照下，checkpoint 由 61.04 GiB 降至 18.02 GiB（-70.5%），E2E output 吞吐（含 prefill、首 token 与 decode）由 2.53 提升至 4.47 tok/s（+76.8%），运行期峰值显存由 32.02 降至 10.63 GiB/rank（-66.8%）；通过 10 组 CUDA/PyTorch 数值对照（最大绝对误差 0.007812）、跨 rank token 一致性及中文交互验收。

2026.01-至今

[关键 Token 加权的思维链蒸馏 | AACL 2027 已投稿](#)

- **方法与职责**：负责模型训练与调优，参与构建“结构恢复—关键 Token 加权监督—偏好优化”三阶段框架；逐 Token 扰动教师推理，以参考答案生成似然下降量估计重要性，并用于加权 SFT 与高重要性辅助损失。
- **实验与投稿**：完成 LoRA/DPO 训练及 vLLM TP=4 评测；Qwen2.5-7B-Instruct 在 GSM8K/SVAMP 上取得 94.01%/94.00% accuracy，较最强基线分别提升 5.51/10.10 个百分点；论文已投稿 AACL 2027，修订版已提交。

综合素质

- **技术方向与语言**：聚焦 RL Infra、GPU 算子与大模型推理系统；IELTS 6.5、CET-6，持有华为 HCIA-AI 认证。
- **开发与工程能力**：熟练使用 C/C++、Python、CUDA、Triton、PyTorch Extension；具备 vLLM、veRL、Megatron-LM、FlashInfer、CUTLASS、NCCL 工程实践。
- **工程方法与工具**：具备跨仓源码分析、最小复现、控制变量实验、自动化测试、Benchmark 与技术文档能力；使用 Nsys、NCU、Compute Sanitizer 进行性能分析、故障定位与多卡正确性验证。