

面试介绍精简版

面试官您好，我叫冯浩然，本科毕业于山东大学，目前在香港中文大学（深圳）攻读集成电路与系统硕士，在九坤投资-至知创新研究院参与已发布的 IQuest-Q1（320B-A15B）模型的训练、推理与 RL 基础设施开发。

推理方面，我负责 vLLM 确定性 Router GEMM 接入和 OE 异步状态算子开发，分别使 48 层 Router GEMM 中位耗时下降 73.39%、OE 单卡 decode 吞吐提升 4.99%，并完成多卡一致性验证。

训练方面，我优化 FA3 确定性 Attention 反向调度，代表场景加速 3.98 倍，并研究 Sink FC1 的计算通信竞争，使四卡代理实验的联合耗时降低 12.80%。

RL 方面，我打通 R3 路由回放，将八卡对照中的执行路由不一致率降至 0 并扩展到 128 卡验证，同时定位 FlashInfer rollout 卡死根因、回移上游修复并完成回归。

此前在摩尔线程，我参与 TensorFlow MUSA Extension 的算子适配、图融合和稳定性优化，使 GELU 在真实测试形状下耗时降低 36.6%，并解决长时间推理随机崩溃的问题。

开源贡献方面，我在 Mooncake 合入 7 个 PR、摩尔线程 TME 合入 10 个 PR，并向 Ray、FlashInfer、Mirage 各合入 1 个 PR，覆盖算子正确性、运行时稳定性与存储通信修复。

此外，我开发了支持双卡的量化推理 Runtime，参与关键 Token 加权思维链蒸馏研究并负责训练评测，相关论文已投稿 AAAI 2027，希望继续发挥从底层算子优化到多卡系统验证的经验，深入 AI Infra 方向。