

冯浩然

电话: (+86)15024999885 邮箱: 225010160@link.cuhk.edu.cn



教育经历

2025.09-2027.06 (预计)	香港中文大学 (深圳)	集成电路与系统 硕士
2021.09-2025.06	山东大学 (985)	电子科学与技术 / 计算机科学与技术 本科

获得荣誉: 山东大学学业奖学金 (前 20%) ; 山东大学特长奖学金 (竞赛创新)

实习经历

2026.04-至今	九坤投资-AI 研究院	大模型与高性能计算实习生
• FlashInfer CUDA Graph 稳定性修复: 针对 H200 上 vLLM TP=2 FULL CUDA Graph rollout hang, 构建两卡最小复现, 将根因定位至 fused AllReduce + RMSNorm 通信轮询: 浮点比较受 FTZ 影响, 将合法 BF16 packed payload 对应的 FP32 负次正规位型误判为 Lamport -0.0 sentinel, 导致永久轮询; 向现用 FlashInfer 0.6.4 回移上游位级判断修复后, 两卡最小复现及模型级 Graph on/off 回归均通过, 重复 replay 未再出现 timeout/hang。 • R3 Router Replay: 针对 vLLM rollout 与 Megatron 训练侧的 MoE 路由不一致, 复现并工程化 R3 Router Replay 方法, 打通 [token, MoE-layer, top-k] route 采集、传输与回放链路, 建立 response-mask 对齐与异常检测并覆盖 18 项 CPU 测试; 在 8×H200、Qwen3-30B-A3B BF16 的 20-step 实验中, 将 route mismatch 从 17%-19% 降至 0, f_tau_2 降低 36-145×、KL 降低 4-7×; 进一步完成多节点长程工程运行与实验监控接入, 改动合并至开发仓。 • OE 异步算子开发: 将 recent-token history 与 oe_input_ids 构造保留在 GPU, 使用 Triton fused-hash 减少 D2H 同步等待与 H2D 回传, 并修复 prefill、decode、mixed batch、请求恢复、slot reuse 与 reorder 场景下的跨 step 状态更新; 三类场景均通过正确性验证。TP1 下 28/28 个用例通过, 吞吐较 sync 提升 4.99%、较 async-unfused 提升 1.94%; TP2/TP4 采用 async-unfused + batch-invariant 安全路径, 28 shapes×3 轮均为 0 mismatch, decode 吞吐分别提升约 4.6%/3.0%。		
2026.01-2026.04	摩尔线程	算子与编译器优化实习生
• TensorFlow MUSA Extension 开发: 负责 TensorFlow on MUSA 的算子支持、插件集成、测试验证及图优化; 完成 muDNN GELU 接入、GELU fusion 链路修复与 benchmark 建设, 解决大图场景下部分 GELU 未融合问题, 实现整网 11 个 GELU 全部融合, 真实 shape 测试耗时降低约 36.6%。 • OOM 与随机崩溃修复: 面向整网长跑场景, 独立定位 shape tensor 在 StridedSlice<int32>/Pack<int32> 链路中误入 device path 的根因, 重构 HostMemory 路径; 修复后完成 1,000 轮 inference 回归, 并进一步通过 4 万、40 万和 80 万轮长稳测试。 • 热点算子优化与稳定性修复: 优化 Logical_Or scalar broadcast 路径并补齐 Logical_And 测试, 将 Logical_Or 平均耗时从 21.2 μs 降至 10.7 μs (-49.5%), 同口径整网吞吐提升约 1.19%; 同时完成 AddV2 hot path 优化与 ResourceApplyAdam graph mode 结果对齐。		

项目经历

2025.12-至今

基于 PyTorch Extension 的高性能 LLM 量化推理 Runtime 开发

- **量化 Runtime 与后端适配**：在支持 W4A16 AWQ、W8A8 SmoothQuant 与 FP8 的 PyTorch Extension Runtime 中，完成 FlashAttention-2/4 可配置接入，补齐 GQA 的 KV heads 展开、softcap mask 及 SDPA→Torch Attention 回退；将 CUDA arch、ccache 与模型路径改为动态/可选配置，使工程可在 RTX 5060 Laptop GPU 与 H200 环境构建部署。
- **H200 Kernel 与 Tensor Parallel**：在 2×H200 (SM90/CUDA 13.0) 环境完成 AWQ Runtime 迁移；使用 NVIDIA Compute Sanitizer 将 decode 非法访存定位至 gemv_kernel_g128：当 K/group_size=7 时，warp 仍按 8 组读取，导致末尾 lane 越界访问 scale/zero；增加 group 边界保护、current-stream launch 与错误检查后，代表 shape 的 memcheck/initcheck/synccheck/racecheck 均为 0 error/0 hazard；进一步实现 Qwen2 packed-AWQ TP=2，完成 Q/K/V、gate/up 列切分、O/down 行切分与 NCCL all-reduce。
- **32B 量化部署与验证**：基于本地 128×512 代码样本完成 Qwen2.5-Coder-32B W4A16 量化与双卡交付；在同模型、prompt、固定 64 个输出 token、3 次重复的公平对照下，checkpoint 从 61.04 GiB 降至 18.02 GiB (-70.5%)，E2E output 吞吐 (含 prefill、首 token 与 decode) 从 2.53 提升至 4.47 tok/s (+76.8%)，运行期峰值显存从 32.02 降至 10.63 GiB/rank (-66.8%)；通过 10 组 CUDA/PyTorch 数值对照 (最大绝对误差 0.007812)、跨 rank token 一致性及中文交互验收。

专业技能

- **技术方向**：聚焦 RL Infra、GPU 算子与性能优化、大模型推理系统，具备 MoE 训推一致性、多卡推理及量化 Runtime 开发经验。
- **编程与性能工程**：熟练使用 C/C++、Python，具备 CUDA、Triton 与 PyTorch Extension 开发经验；熟悉 PyTorch、veRL、Megatron-LM、vLLM 等框架及 FlashInfer、CUTLASS、NCCL 等库，能够使用 Nsight Systems (Nsys) 与 NVIDIA Compute Sanitizer，并熟悉 Nsight Compute (NCU) 基本分析流程，完成 GPU Kernel 故障定位、多卡正确性验证及 Kernel-Operator-E2E 分层性能回归。
- **工程实践**：具备跨仓源码分析、问题最小复现、控制变量实验、自动化测试、benchmark 建设及技术文档沉淀能力；使用 Claude Code/Codex 辅助代码检索、测试与文档，并通过代码审查和正确性/性能回归保证质量；具备英文技术文档阅读与检索能力 (IELTS 6.5、CET-6)，持有华为 HCIA-AI 认证。