

AI INFRA 八股文

系统总览 · GPU · 通信 · 分布式并行 · 可靠性

把零散名词组织成一条可口述的工程链路：资源与硬件 → 运行时与通信 → 训练/推理执行 → 调度、观测与可靠性。每题采用“结论—机制—代价/指标”的回答顺序。

原创整理 · 公开题型检索与官方资料交叉核验 · 核验日期：2026-09-20
社区资料用于发现高频题型；技术结论以文末官方文档与原始论文为准。

建议口述顺序：先给结论，再讲机制与数据流，最后说明性能代价、适用边界和怎样用指标验证。遇到场景题，先澄清负载、硬件、SLO 与约束。

一、系统与硬件基线

Q01 什么是 AI Infra？它和模型算法、MLOps 的边界在哪里？

30 秒回答：AI Infra 的目标是让模型以可扩展、可观测、可控成本的方式训练和服务。它覆盖 GPU/网络/存储、编译与运行时、分布式框架、调度和服务系统；模型算法关注目标与结构，MLOps 更偏数据、发布与治理，三者在生产链路交叉但优化目标不同。

追问提示：补充具体负载、关键指标、失败模式，以及你会用什么 trace / profiler / 对照实验验证。

Q02 从下到上描述一套大模型系统的技术栈。

30 秒回答：可按硬件与互联、驱动/CUDA/NCCL、PyTorch/Megatron/vLLM 等框架、训练或 Serving 执行引擎、Kubernetes/Ray 等资源调度、日志指标追踪来分层。面试中重点说清每层暴露什么抽象、出现故障时怎样向下定位。

追问提示：补充具体负载、关键指标、失败模式，以及你会用什么 trace / profiler / 对照实验验证。

Q03 GPU 为什么适合深度学习，CPU 为什么仍不可替代？

30 秒回答：GPU 以大量轻量核心和高带宽内存处理规则、并行度高的张量计算；CPU 擅长低延迟控制流、tokenization、调度、网络协议和复杂串行逻辑。端到端性能取决于两者是否流水化，GPU 利用率高并不代表整条请求链路快。

追问提示：补充具体负载、关键指标、失败模式，以及你会用什么 trace / profiler / 对照实验验证。

Q04 thread、warp、block、SM 分别是什么？

30 秒回答：线程执行最小程序实例；通常 32 个线程组成一个 warp 进行 SIMT 调度；block 是能共享 shared memory 并同步的线程组；SM 同时驻留多个 block/warp 来隐藏延迟。回答时要补充：具体资源上限和调度细节随 GPU 架构变化。

追问提示：补充具体负载、关键指标、失败模式，以及你会用什么 trace / profiler / 对照实验验证。

Q05 如何理解 GPU 的内存层级？

30 秒回答：寄存器最快且线程私有，shared memory 是片上、block 内协作空间，L2/HBM 面向更大范围的数据；local memory 名字虽是 local，通常实际落在 device memory。优化不是死背时延，而是减少 HBM 往返、提高复用并避免访问串行化。

追问提示：补充具体负载、关键指标、失败模式，以及你会用什么 trace / profiler / 对照实验验证。

二、运行时、通信与并行

Q06 CUDA stream、event 和同步的工程意义是什么？

30 秒回答：stream 给操作定义顺序，event 用于跨 stream 建立依赖或计时；独立的数据拷贝、通信与计算可在不同 stream 尝试重叠。真正是否重叠需要看时间线，任何隐式同步、默认流语义或资源争用都可能把设计串行化。

追问提示：补充具体负载、关键指标、失败模式，以及你会用什么 trace / profiler / 对照实验验证。

Q07 AllReduce、AllGather、ReduceScatter、AlltoAll 如何区分？

30 秒回答：AllReduce 规约后每个 rank 得到相同结果，常用于 DDP 梯度；ReduceScatter 是规约后各 rank 留一片，AllGather 再收集分片；AlltoAll 让每个 rank 发不同块给不同 rank，是 MoE token dispatch 的典型模式。所有 rank 必须以一致顺序、dtype 和形状参与 collective。

追问提示：补充具体负载、关键指标、失败模式，以及你会用什么 trace / profiler / 对照实验验证。

Q08 NCCL 卡住时，第一轮排查怎么做？

30 秒回答：先固定最小复现并核对 rank、world size、collective 调用顺序、tensor shape/dtype 和进程错误；再看拓扑、网络、超时和 NCCL 日志。不要先把 timeout 调大，因为一个 rank 提前异常、分支不一致或未参与 collective 才是最常见根因。

追问提示：补充具体负载、关键指标、失败模式，以及你会用什么 trace / profiler / 对照实验验证。

Q09 DP、TP、PP、CP、EP 分别沿什么维度切分？

30 秒回答：DP 切 batch；TP 切单层张量；PP 按网络深度切层；CP 按序列维处理长上下文；EP 将 MoE 专家分布到不同设备。总卡数通常是这些模型并行维度与 DP 的乘积，选择时要同时看显存、通信频率、拓扑和气泡。

追问提示：补充具体负载、关键指标、失败模式，以及你会用什么 trace / profiler / 对照实验验证。

Q10 为什么多卡训练通常不能线性加速？

30 秒回答：计算可并行，但通信带宽/延迟、PP 气泡、MoE 负载倾斜、输入等待和慢节点不可消失。应把 step 拆成 data、forward、backward、optimizer、collective 和 idle，再比较扩卡前后的每一项，而不是只报总吞吐。

追问提示：补充具体负载、关键指标、失败模式，以及你会用什么 trace / profiler / 对照实验验证。

三、显存、性能与诊断

Q11 训练显存如何做一阶估算？

30 秒回答：分为模型状态、激活、临时 workspace、通信 buffer 与 allocator 碎片。以 Adam + BF16 为例，常见粗估会把低精度参数、梯度、FP32 master weight 和两个 FP32 optimizer state 合计到约 16 bytes/参数，但实际实现、分片和精度策略不同，必须用峰值统计复核。

追问提示：补充具体负载、关键指标、失败模式，以及你会用什么 trace / profiler / 对照实验验证。

Q12 推理显存主要花在哪里？

30 秒回答：权重、KV Cache、激活/临时 buffer 和运行时保留空间是主项。KV Cache 近似为 $2 \times \text{layers} \times \text{tokens} \times \text{kv_heads} \times \text{head_dim} \times \text{dtype_bytes}$ ，再乘并发序列数；GQA/MQA、量化和 block 对齐都会改变实际容量。

追问提示：补充具体负载、关键指标、失败模式，以及你会用什么 trace / profiler / 对照实验验证。

Q13 TTFT、TPOT、吞吐与 P99 分别说明什么？

30 秒回答：TTFT 衡量首 token 前的排队、tokenize 和 prefill；TPOT/ITL 衡量后续输出节奏；aggregate tokens/s 描述系统产能；P99 揭示尾部体验。必须同时报告输入/输出长度分布、到达率和 percentile，离线满 batch 的吞吐不能替代线上 SLO。

追问提示：补充具体负载、关键指标、失败模式，以及你会用什么 trace / profiler / 对照实验验证。

Q14 MFU 和 GPU-Util 有什么区别？

30 秒回答：MFU 是模型有效 FLOP/s 相对硬件理论峰值的比率，需要清楚 FLOP 与精度口径；GPU-Util 只是粗粒度忙闲状态，看不出 Tensor Core、通信、访存或无效计算。性能汇报应把二者与 step time 分解结合起来。

追问提示：补充具体负载、关键指标、失败模式，以及你会用什么 trace / profiler / 对照实验验证。

Q15 如何用 Roofline 做性能定位？

30 秒回答：先估算算术强度 FLOPs/bytes，再与设备计算屋顶和带宽屋顶比较。接近带宽斜线时优先减少 HBM 流量、改善访问或融合；接近计算平顶时再看 Tensor Core、GEMM shape 和指令利用。Roofline 是提出假设的起点，需 profiler 指标验证。

追问提示：补充具体负载、关键指标、失败模式，以及你会用什么 trace / profiler / 对照实验验证。

四、调度、可靠性与系统设计

Q16 为什么 AI 任务需要 gang scheduling 和拓扑感知放置？

30 秒回答：分布式作业若只拿到一部分必需资源，进程会在 rendezvous 或 collective 空等；gang scheduling 让资源齐备再启动。TP/EP 对同机 NVLink 或低延迟网络更敏感，拓扑感知可避免关键通信落到慢链路。

追问提示：补充具体负载、关键指标、失败模式，以及你会用什么 trace / profiler / 对照实验验证。

Q17 如何做 GPU 多租户隔离？

30 秒回答：资源隔离可从物理 GPU、MIG、配额/优先级、显存预算、CPU/网络限额和 namespace 权限分层实现。MPS、时间片或共享副本提高利用率，但会牺牲性能可预测性；要明确租户隔离、SLO 与成本三者的取舍。

追问提示：补充具体负载、关键指标、失败模式，以及你会用什么 trace / profiler / 对照实验验证。

Q18 一次训练 checkpoint 应保存哪些状态？

30 秒回答：至少包括模型、optimizer、学习率调度、随机数状态、global step、数据迭代位置/种子、并行配置和版本信息。大规模场景应使用分片 checkpoint、manifest/完成标记和原子提交，并定期做恢复演练，而不是只验证文件写出来了。

追问提示：补充具体负载、关键指标、失败模式，以及你会用什么 trace / profiler / 对照实验验证。

Q19 怎样设计可观测性，才能定位训练或推理故障？

30 秒回答：指标要覆盖资源层(GPU/显存/网络)、引擎层(queue、KV、tokens/s、NCCL)、业务层(SLO、错误率、成本)；日志与 trace 使用 request/job/rank 相关 ID 串联。告警应给出可执行的下一步，而不是只报警 GPU 利用率低。

追问提示：补充具体负载、关键指标、失败模式，以及你会用什么 trace / profiler / 对照实验验证。

Q20 系统设计题：如何回答“搭建一个 100 QPS 的 LLM 服务”？

30 秒回答：先澄清模型、输入/输出长度、流式协议、TTFT/TPOT/P99、区域和预算；再给出网关、鉴权、限流、路由、vLLM replica、KV/前缀缓存、监控与压测方案。最后说明容量以真实长度分布压测决定，并设计过载拒绝、降级、灰度和故障转移。

追问提示：补充具体负载、关键指标、失败模式，以及你会用什么 trace / profiler / 对照实验验证。

@小冯别放弃

60 秒答题模板

1. 定义与目标：先说它解决哪一个资源、正确性或 SLO 问题。
2. 机制与数据流：指出数据/张量如何移动，计算和通信在哪里发生。
3. 取舍：说明换来了什么显存、带宽、计算、复杂度或尾延迟代价。
4. 验证：给出应看的指标、对照实验和最小复现方式。

@小冯别放弃

资料来源与使用边界

以下社区面经/题库用于归纳问题主题；答案为原创整理。框架和硬件会演进，实际配置与行为应以对应版本的官方文档、源码和基准测试为准。

- 牛客: C++/CUDA/AI Infra 面试经验总结
- 牛客: 2025 春招 AI Infra 面经汇总
- GitHub: AI Infra 核心题清单
- GitHub: AI Infra 学习与面试高频问题
- GitHub: LLM/RL Infra 面试问题整理
- NVIDIA CUDA Programming Guide
- NCCL Collective Operations
- Megatron Core Parallelism Guide

@小冯别放弃