

训练八股文

DDP/FSDP/ZeRO · TP/PP/CP/EP · 显存 · 通信重叠 · 容错

面向大模型训练框架、性能优化和分布式系统岗位。核心不是罗列并行名词，而是说明每种方案切分了什么、换来了什么通信，以及如何用数据证明它更快或更稳。

原创整理 · 公开题型检索与官方资料交叉核验 · 核验日期：2026-09-20
社区资料用于发现高频题型；技术结论以文末官方文档与原始论文为准。

建议口述顺序：先给结论，再讲机制与数据流，最后说明性能代价、适用边界和怎样用指标验证。遇到场景题，先澄清负载、硬件、SLO 与约束。

一、训练步骤与模型状态

Q01 一个 LLM training step 的完整链路是什么？

30 秒回答：数据读取、tokenize/packing、H2D 后执行 forward 并保存必要激活，计算 loss、backward，再按并行组做梯度/参数通信，最后 optimizer 更新、学习率调度、日志和 checkpoint。哪种 collective 出现取决于 DP/TP/PP/EP 配置。

追问提示：补充具体负载、关键指标、失败模式，以及你会用什么 trace / profiler / 对照实验验证。

Q02 训练显存主要由哪些部分组成？

30 秒回答：模型状态(参数、梯度、optimizer state/主权重)、激活、临时 workspace、通信 buffer 和 allocator 碎片。模型状态主要随参数量增长，激活更受 batch、序列长度、层数与 hidden size 影响，故障时应看 peak allocated/reserved 而非只看参数量。

追问提示：补充具体负载、关键指标、失败模式，以及你会用什么 trace / profiler / 对照实验验证。

Q03 FP16、BF16、FP8 的取舍是什么？

30 秒回答：低精度减少显存并提高 Tensor Core 吞吐；FP16 指数范围较窄，常需 GradScaler 避免下溢；BF16 指数范围接近 FP32，通常更稳；FP8 还要管理 scaling、格式和关键路径的高精度累加。精度策略必须配套数值回归与 overflow 监控。

追问提示：补充具体负载、关键指标、失败模式，以及你会用什么 trace / profiler / 对照实验验证。

Q04 gradient accumulation 改变了什么，没有改变什么？

30 秒回答：它将多个 micro-batch 的梯度累积后再更新，能在单卡显存限制下提高 global batch。它不等价于所有情况下严格同一训练动态：dropout、学习率调度、归一化和通信时机都可能不同，报告时要说明 global batch、micro-batch、accumulation 与 DP 的关系。

追问提示：补充具体负载、关键指标、失败模式，以及你会用什么 trace / profiler / 对照实验验证。

Q05 为什么 loss spike / NaN 不能只靠减小 batch 解决?

30 秒回答: 先固定复现窗口, 检查输入与标签、学习率、grad norm、Inf/NaN、loss scaling 和精度路径; 再排查并行通信、随机性和自定义 kernel。性能/数值问题要分开看, 盲目降 batch 可能掩盖数据或算子 bug。

追问提示: 补充具体负载、关键指标、失败模式, 以及你会用什么 trace / profiler / 对照实验验证。

二、状态分片与模型并行

Q06 DDP 与 FSDP/ZeRO 的根本差别是什么?

30 秒回答: DDP 在每个 DP rank 复制完整模型状态, 反向主要 AllReduce 梯度; FSDP/ZeRO 将状态分片, 以更多 AllGather/ReduceScatter 换显存。DDP 简单规律, FSDP/ZeRO 更省显存但对通信、checkpoint 和 overlap 更敏感。

追问提示: 补充具体负载、关键指标、失败模式, 以及你会用什么 trace / profiler / 对照实验验证。

Q07 ZeRO Stage 1/2/3 分别分片什么?

30 秒回答: Stage 1 分 optimizer states; Stage 2 再分 gradients; Stage 3 连参数也分片, 并在 forward/backward 按需聚合后释放。它不是“把模型按层切开”, 而是数据并行组内的状态分片策略。

追问提示: 补充具体负载、关键指标、失败模式, 以及你会用什么 trace / profiler / 对照实验验证。

Q08 TP、PP 如何取舍?

30 秒回答: TP 切单层矩阵, 层内高频 collective, 适合高带宽低延迟拓扑; PP 按层切, 显存切分直接但会有 pipeline bubble 和相邻 stage 激活传输。大模型常混合使用: 先根据模型/层是否容纳与网络拓扑, 再根据 profile 调并行度。

追问提示: 补充具体负载、关键指标、失败模式, 以及你会用什么 trace / profiler / 对照实验验证。

Q09 pipeline bubble 是什么, 怎样缓解?

30 秒回答: 流水线起停阶段有些 stage 无 micro-batch 可执行, GPU 空转形成 bubble。增加 micro-batch、1F1B、interleaved/virtual pipeline 可缓解, 但会增加激活、调度与通信复杂度; 必须一起看吞吐和峰值显存。

追问提示: 补充具体负载、关键指标、失败模式, 以及你会用什么 trace / profiler / 对照实验验证。

Q10 CP 与 sequence parallel 有何区别？

30 秒回答：sequence parallel 常切分某些按序列布局的激活；CP 更彻底地沿 sequence 切输入与激活，attention 处必须处理跨分片 KV 交互。CP 特别适合长上下文以降低每卡激活显存，但不能忽略它的通信模式。

追问提示：补充具体负载、关键指标、失败模式，以及你会用什么 trace / profiler / 对照实验验证。

三、MoE、通信与内存优化

Q11 MoE 训练为什么容易被通信和不均衡拖慢？

30 秒回答：router 选 Top-k experts 后，EP 下 token 要 AlltoAll 发到专家卡并回传；热点 expert、capacity、padding/drop token 都会影响吞吐和质量。需要同时观察每 expert token 分布、A2A 时间、router auxiliary loss 和 capacity 策略。

追问提示：补充具体负载、关键指标、失败模式，以及你会用什么 trace / profiler / 对照实验验证。

Q12 activation checkpointing 为什么省显存又会变慢？

30 秒回答：它不保存一部分 forward 激活，在 backward 重跑相应片段，用额外 FLOPs 换显存。含 dropout 等随机算子时要保存/重建 RNG 状态，否则 checkpoint 与非 checkpoint 路径可能产生不一致的结果或梯度。

追问提示：补充具体负载、关键指标、失败模式，以及你会用什么 trace / profiler / 对照实验验证。

Q13 activation offload 与 recompute 如何比较？

30 秒回答：recompute 用计算换显存，offload 用 GPU-CPU 传输换显存。轻量模块通常更适合重算，重且可异步传输的激活可能适合 offload；选择取决于 GPU 计算余量、PCIe/NVLink 带宽与能否隐藏传输。

追问提示：补充具体负载、关键指标、失败模式，以及你会用什么 trace / profiler / 对照实验验证。

Q14 怎样实现通信—计算 overlap，如何确认真的生效？

30 秒回答：将梯度按 bucket 切分，在 backward 未结束时异步发起 reduce，使后续反向覆盖 collective；TP/PP 也可重叠独立通信。必须用 Nsight 时间线观察 NCCL 与 kernel 的实际并行区间，单纯打开配置项不代表加速。

追问提示：补充具体负载、关键指标、失败模式，以及你会用什么 trace / profiler / 对照实验验证。

Q15 为什么 AllReduce 的调用顺序错误会导致 hang?

30 秒回答: collective 是组内协作协议, 各 rank 必须在同一 communicator 上以一致顺序、count 和 dtype 参与。某个 rank 分支提前返回、抛异常或 shape 不同, 其他 rank 会永远等匹配操作; 应从最早异常和各 rank 的调用序列定位。

追问提示: 补充具体负载、关键指标、失败模式, 以及你会用什么 trace / profiler / 对照实验验证。

四、性能、输入与可靠性

Q16 如何用 MFU 与 timeline 分解训练瓶颈?

30 秒回答: MFU 提供计算效率宏观指标; timeline 则拆 data wait、forward、backward、optimizer、collective 和 idle。扩卡后 MFU 降低时, 应先确认通信、PP bubble、MoE imbalance、输入或慢节点哪个增长, 而不是仅以 GPU-Util 解释。

追问提示: 补充具体负载、关键指标、失败模式, 以及你会用什么 trace / profiler / 对照实验验证。

Q17 数据输入管线如何拖慢训练?

30 秒回答: 对象存储/磁盘、解压、tokenize、packing、CPU worker 和 H2D 都可能让 GPU 等待。监控 data wait、CPU 利用、H2D 时间和 tokens/s, 采用合理 sharding、prefetch、pinned memory、异步拷贝, 同时保证 resume 后数据不重不漏。

追问提示: 补充具体负载、关键指标、失败模式, 以及你会用什么 trace / profiler / 对照实验验证。

Q18 如何排查 OOM?

30 秒回答: 先区分 allocated、reserved 与碎片, 记录发生在 forward、backward、optimizer 还是 checkpoint; 再按影响排序考虑减 micro-batch/序列、activation checkpoint、分片、低精度、offload 或改变并行。不要无条件调大 allocator 参数或牺牲稳定性。

追问提示: 补充具体负载、关键指标、失败模式, 以及你会用什么 trace / profiler / 对照实验验证。

Q19 checkpoint 如何做到可恢复而非只做到可写入?

30 秒回答: 除模型外保存 optimizer、scheduler、RNG、global step、数据迭代位置、并行配置与版本; 大规模训练使用分片、manifest 和完成标记, 采用原子提交。验证包括冷启动恢复、不同节点故障恢复和数据无重复/无遗漏检查。

追问提示: 补充具体负载、关键指标、失败模式, 以及你会用什么 trace / profiler / 对照实验验证。

Q20 为什么训练需要 gang scheduling 和拓扑感知?

30 秒回答: 分布式训练要同时获得整组 GPU 才能启动, 缺卡会在 rendezvous/collective 空等; TP/EP 更敏感于机内高速互联。调度器应兼顾全量资源、NVLink/IB 拓扑、存储局部性、优先级和可抢占策略。

追问提示: 补充具体负载、关键指标、失败模式, 以及你会用什么 trace / profiler / 对照实验验证。

@小冯别放弃

60 秒答题模板

1. 定义与目标：先说它解决哪一个资源、正确性或 SLO 问题。
2. 机制与数据流：指出数据/张量如何移动，计算和通信在哪里发生。
3. 取舍：说明换来了什么显存、带宽、计算、复杂度或尾延迟代价。
4. 验证：给出应看的指标、对照实验和最小复现方式。

@小冯别放弃

资料来源与使用边界

以下社区面经/题库用于归纳问题主题；答案为原创整理。框架和硬件会演进，实际配置与行为应以对应版本的官方文档、源码和基准测试为准。

- 牛客: C++/CUDA/AI Infra 面试经验总结
- 牛客: 2025 春招 AI Infra 面经汇总
- GitHub: AI Infra 核心题清单
- GitHub: AI Infra 学习与面试高频问题
- GitHub: LLM/RL Infra 面试问题整理
- Megatron Core Parallelism Guide
- Megatron Core Context Parallel
- PyTorch FSDP
- NCCL Collective Operations
- DeepSpeed ZeRO

@小冯别放弃