

RL 八股文

RLHF · PPO · GRPO · DPO · Rollout 系统 · 对齐与可观测性

面向 RLHF、RLVR 与 Agentic RL 系统岗位。回答必须同时覆盖算法目标、样本与版本、资源布局和稳定性指标；只会写 PPO 公式不够，不能说明 actor-learner 数据流也不够。

原创整理 · 公开题型检索与官方资料交叉核验 · 核验日期：2026-09-20
社区资料用于发现高频题型；技术结论以文末官方文档与原始论文为准。

建议口述顺序：先给结论，再讲机制与数据流，最后说明性能代价、适用边界和怎样用指标验证。遇到场景题，先澄清负载、硬件、SLO 与约束。

一、RLHF 算法与目标

Q01 从数据流讲清 RLHF。

30 秒回答：通常从 SFT 初始化策略；在同一 prompt 的多回答上训练 reward model；当前策略 rollout 后以 RM、规则或 verifier 得到 reward，计算 advantage，再用 PPO 等方法更新 actor，同时用 reference policy 的 KL 约束偏移。生产系统还要记录数据和权重版本。

追问提示：补充具体负载、关键指标、失败模式，以及你会用什么 trace / profiler / 对照实验验证。

Q02 为什么 SFT 不能完全替代偏好对齐？

30 秒回答：SFT 最小化示范 token 的 NLL，表达的是模仿；偏好数据表达候选之间的相对好坏，RL/偏好优化可直接优化序列级目标。代价是引入 reward 偏差、online rollout 成本与稳定性挑战，二者常是连续阶段而非互斥选择。

追问提示：补充具体负载、关键指标、失败模式，以及你会用什么 trace / profiler / 对照实验验证。

Q03 Reward Model 如何用 chosen/rejected 数据训练？

30 秒回答：同一 prompt 下希望 chosen 的标量 reward 高于 rejected，常用 Bradley-Terry 形式的 pairwise loss。数据切分要防问题泄漏，检查标注一致性、覆盖和长度偏差；RM 分数是代理指标，不能当真实用户价值的唯一衡量。

追问提示：补充具体负载、关键指标、失败模式，以及你会用什么 trace / profiler / 对照实验验证。

Q04 PPO 的 clip 在控制什么？

30 秒回答：用新旧策略概率比 r 与 advantage 构造 surrogate objective，并将比率限制在 $1 \pm \epsilon$ 附近，抑制一次更新过大。clip 不是保证 KL 永远很小，也不代替监控 reward、entropy、clip fraction、梯度和策略陈旧度。

追问提示：补充具体负载、关键指标、失败模式，以及你会用什么 trace / profiler / 对照实验验证。

Q05 GAE 的 γ 与 λ 分别影响什么?

30 秒回答: GAE 用 TD residual 的折扣和加权来估计 advantage; γ 表示未来回报折扣, λ 控制偏差—方差折中。LLM 场景还要正确处理 token mask、EOS、变长序列和 reward 归属, 否则公式正确也会训练错。

追问提示: 补充具体负载、关键指标、失败模式, 以及你会用什么 trace / profiler / 对照实验验证。

二、对齐方法比较

Q06 为什么要加 KL(reference) 约束?

30 秒回答: 它限制策略为了提高 RM/规则奖励而偏离 SFT/reference 太远, 保护语言质量与安全先验。KL 过大时训练学不动, 过小时可能出现 reward hacking 或能力回退; 还要说明 KL 是 token/sequence、mean/sum 哪种口径。

追问提示: 补充具体负载、关键指标、失败模式, 以及你会用什么 trace / profiler / 对照实验验证。

Q07 PPO 与 GRPO 的关键区别是什么?

30 秒回答: PPO 常依赖 critic/value 来估计 advantage; GRPO 对同一 prompt 采样一组回答, 用组内相对奖励构造 advantage, 可减少独立 critic 的成本。GRPO 仍依赖组大小、奖励归一化与 reference/KL 等稳定化设计, 不能简单说成“没有约束”。

追问提示: 补充具体负载、关键指标、失败模式, 以及你会用什么 trace / profiler / 对照实验验证。

Q08 DPO 与 PPO-RLHF 如何选择?

30 秒回答: DPO 直接在离线偏好对上优化, 省去单独 RM 和在线 rollout 闭环, 工程简单; PPO-RLHF 能利用在线采样和可计算奖励, 但资源与稳定性成本更高。选择取决于是否需要探索、奖励形态、数据新鲜度和评估预算。

追问提示: 补充具体负载、关键指标、失败模式, 以及你会用什么 trace / profiler / 对照实验验证。

Q09 哪些任务适合 verifier, 哪些更需要 RM?

30 秒回答: 数学、代码测试、格式/约束常有可验证的 outcome reward; 帮助性、风格、安全权衡更依赖偏好模型或人工/AI 评审。复杂任务可组合 outcome、process 和 safety reward, 但要避免多个 proxy 互相抵消。

追问提示: 补充具体负载、关键指标、失败模式, 以及你会用什么 trace / profiler / 对照实验验证。

Q10 什么是 reward hacking，如何修复？

30 秒回答：策略提高代理奖励却没提升真实目标，例如刷长度、模板或格式漏洞。通过 RM 分数与盲测、held-out verifier、红队和长度分布对照定位；修复靠对抗样本、奖励拆分、长度控制、重标注和多维评估，不能只盲调 KL。

追问提示：补充具体负载、关键指标、失败模式，以及你会用什么 trace / profiler / 对照实验验证。

三、Rollout 与分布式系统

Q11 PPO 为什么偏 on-policy，样本陈旧会怎样？

30 秒回答：PPO 比率以行为策略为基准；worker 使用旧权重、更新轮数过多或同步滞后会导致分布失配，使 ratio/KL 异常并伤稳定性。每条样本应带 policy version、old logprob，并限制可接受 lag。

追问提示：补充具体负载、关键指标、失败模式，以及你会用什么 trace / profiler / 对照实验验证。

Q12 一条可复现的 rollout 样本应保存什么？

30 秒回答：至少保存 prompt、completion、token ids/mask、行为与 reference logprob、reward 分量、终止原因、sampling 参数、模型/奖励/环境版本。这样才能重算 loss/advantage、定位数据漂移和区分算法问题与服务问题。

追问提示：补充具体负载、关键指标、失败模式，以及你会用什么 trace / profiler / 对照实验验证。

Q13 actor、reference、RM、critic/verifier 各做什么，哪些反传？

30 秒回答：actor 生成并更新；reference 通常只前向计算 KL；RM/verifier 通常只评分；critic 估计 value 并在 PPO 中训练。要区分逻辑角色与物理进程：它们可 colocate，也可部署在独立 GPU 池。

追问提示：补充具体负载、关键指标、失败模式，以及你会用什么 trace / profiler / 对照实验验证。

Q14 为什么 RLHF 比普通 SFT 更难做资源规划？

30 秒回答：除 actor 反向外，还要承受 rollout 生成、多个前向、可能的 critic/RM、轨迹和 logprob 存储、权重同步。生成与训练的最优 batch/并行策略不同，资源规划需比较每阶段 GPU-seconds、队列、显存峰值和网络开销。

追问提示：补充具体负载、关键指标、失败模式，以及你会用什么 trace / profiler / 对照实验验证。

Q15 colocate 与 disaggregate 如何取舍?

30 秒回答: colocate 可复用 GPU 并减少跨池传输, 但角色争抢显存/计算并可能重建通信组; disaggregate 隔离稳定、可独立扩缩容, 但会增加数据/权重移动。选择不凭习惯, 而是由排队、吞吐、网络、显存和失败域测量决定。

追问提示: 补充具体负载、关键指标、失败模式, 以及你会用什么 trace / profiler / 对照实验验证。

四、稳定性、Agent 与评估

Q16 如何设计 rollout 与 trainer 的权重同步协议?

30 秒回答: 使用版本化 checkpoint 或增量更新、原子切换、worker ACK 与样本版本标记; trainer 只接受允许窗口内的样本, 失败可回滚到已验证版本。关键是避免同一训练 batch 混入不可解释的多策略数据。

追问提示: 补充具体负载、关键指标、失败模式, 以及你会用什么 trace / profiler / 对照实验验证。

Q17 Agentic RL 的长轨迹信用分配难点是什么?

30 秒回答: 奖励稀疏、工具失败/环境随机、上下文长且早期动作影响远期结果。可用可验证子目标、过程监督、轨迹切分、确定性环境与回放, 但要防只优化局部 proxy 而损害最终任务成功率。

追问提示: 补充具体负载、关键指标、失败模式, 以及你会用什么 trace / profiler / 对照实验验证。

Q18 actor-learner 解耦为什么会引入 off-policy 风险?

30 秒回答: 解耦提高吞吐, 但 actor 用旧参数采样时 learner 已更新, 数据分布开始偏移。PPO 系统通常控制 version lag、更新轮数与队列水位; 若采用重要性修正, 也要监控权重、方差与数值稳定性。

追问提示: 补充具体负载、关键指标、失败模式, 以及你会用什么 trace / profiler / 对照实验验证。

Q19 RL/RLHF 评估为什么不能只看 reward?

30 秒回答: RM/规则 reward 是代理信号, 还要看 held-out 偏好或人评、可验证成功率、安全红队、长度/格式分布、基础能力回退、成本和延迟。若 reward 上升但这些指标变差, 应优先怀疑 reward hacking 或数据/版本错配。

追问提示: 补充具体负载、关键指标、失败模式, 以及你会用什么 trace / profiler / 对照实验验证。

Q20 RL 训练曲线异常时的排查顺序是什么？

30 秒回答：先对齐数据版本、reward 版本、policy/reference 版本与环境版本；再看 reward 分量、KL、entropy、clip fraction、优势分布、value loss、grad norm、response length、rollout 吞吐与 policy lag。先建立因果链，再动超参。

追问提示：补充具体负载、关键指标、失败模式，以及你会用什么 trace / profiler / 对照实验验证。

@小冯别放弃

60 秒答题模板

1. 定义与目标：先说它解决哪一个资源、正确性或 SLO 问题。
2. 机制与数据流：指出数据/张量如何移动，计算和通信在哪里发生。
3. 取舍：说明换来了什么显存、带宽、计算、复杂度或尾延迟代价。
4. 验证：给出应看的指标、对照实验和最小复现方式。

@小冯别放弃

资料来源与使用边界

以下社区面经/题库用于归纳问题主题；答案为原创整理。框架和硬件会演进，实际配置与行为应以对应版本的官方文档、源码和基准测试为准。

- 牛客: C++/CUDA/AI Infra 面试经验总结
- 牛客: 2025 春招 AI Infra 面经汇总
- GitHub: AI Infra 核心题清单
- GitHub: AI Infra 学习与面试高频问题
- GitHub: LLM/RL Infra 面试问题整理
- InstructGPT / RLHF
- PPO
- Generalized Advantage Estimation
- DPO
- DeepSeek-R1 / GRPO
- OpenRLHF
- TRL 文档

@小冯别放弃