

GROUP TECH BRIEF / TIBO TALK SERIES #05

Agent 会杀死 SaaS 吗

Tibo + Peter Steinberger x VivaTech: The Agentic Enterprise

大会舞台对谈 / 官方回放 • 25 分钟 • 会谈日期 2026.06.18

一句话结论

这场把 Agent 的产业形态讲得很透：下一阶段不是“一个更强聊天框”，而是模型可以调度其他 Agent；短期 SaaS 不会消失，但 UI 会越来越按需生成，长期用户可能只和自己的 Agent 交互。

四个最值得关注的信号

01 AI talks to AI 从用户 -> 单 Agent，升级到主 Agent -> 多个专业 Agent 的级联编排。	02 Mainstream enterprise 增长不再只来自开发者，而是一般企业知识工作。
03 SaaS 不会立刻死 可靠服务包含维护、数据、权限和运营，不是一个 prompt 就能替代。	04 Personal software Agent 根据个人目标动态生成 dashboard / workflow / UI，软件界面变得一次性和定制化。

说明：下文将“访谈观点”“技术解读”“方向推演”分开呈现；预测不视为正式产品承诺。

OVERVIEW

访谈背景与章节地图

受访者：Thibault “Tibo” Sottiaux，OpenAI Core Product / Codex 相关负责人。

对谈方：Charlie Perreau（Les Echos）；Peter Steinberger（OpenClaw）

形式：大会舞台对谈 / 官方回放；时长：25 分钟

- 访谈观点
- 技术解读
- 方向推演
- 外部核验

章节地图 / 讨论顺序

时间 / 顺序	主题
开场	为什么从 Generative AI 转向 Agentic AI
第一段	更长 context、更好 tool use、更长 coherent execution
第二段	“好模型 + 好 Harness = Agent”
中段	主 Agent 委派其他 Agent：AI talks to AI
中段	企业一般工作成为增长来源
后段	Taste / Judgment / Safety 仍是通用 Agent 难点
后段	SaaS apocalypse postponed
结尾	个人 Agent、个人软件、先自动化“讨厌但必须做”的任务

阅读方法

先看 Tibo 明确表达的系统设计原则，再看这些原则对 Agent Runtime、Serving、Sandbox、Memory、Multi-agent 或软件工程流程的含义。不要把方向判断直接当作已经落地的功能。

CORE IDEAS

1. Multi-agent 的价值不是 “多开几个模型”

- Peter 描述的下一阶段，是主模型能把子问题拆给其他 Agent，再汇总结果。真正的难点不是并发数量，而是 decomposition、通信、共享状态、冲突解决和最终验证。
- 从系统视角看，它类似动态 DAG：节点不是固定算子，而是会根据中间结果继续生成新任务。调度器必须同时考虑 token/算力成本、deadline、工具资源和依赖。
- 这也意味着 “test-time compute” 可以通过更多 Agent 并行扩展，但收益不会线性增长，协调和重复探索会形成新的 overhead。


核心判断：这场把 Agent 的产业形态讲得很透：下一阶段不是 “一个更强聊天框”，而是模型可以调度其他 Agent；短期 SaaS 不会消失，但 UI 会越来越按需生成，长期用户可能只和自己的 Agent 交互。

2. SaaS 被替代的是 “固定 UI”，不是可靠能力本身

- 现场双方都没有认同短期 SaaS apocalypse。原因很朴素：真正可靠的软件服务包含数据一致性、权限、合规、持续维护、SLA 和组织流程。
- 但 Tibo 的长期判断更激进：个人 Agent 了解你的目标和偏好后，可以动态生成你需要的 dashboard、脚本和界面。于是 “软件” 仍在，固定应用入口的重要性下降。
- 对基础设施厂商来说，价值可能从前端 UI 迁到 API、数据层、身份权限和可组合的服务能力。

SYSTEM VIEW

把访谈观点翻译成系统结构



这里最容易误解的一点

Agent 的“能力”并不等于裸模型能力。对真实任务而言，更接近：

$$\text{Agent Utility} = \text{Model} \times \text{Context} \times \text{Tools} \times \text{Runtime} \times \text{Safety} \times \text{Verification}$$

任何一项接近 0，端到端体验都会坍塌；这也是为什么模型 benchmark 提升并不总能等比例转化为产品收益。

工程上应该关注的闭环

Observe	任务 trace、tool call、权限、失败位置、人工介入、最终结果。
Diagnose	区分是模型、Harness、环境、数据、延迟还是安全策略导致失败。
Improve	把问题放回最合适的层修，而不是默认继续堆 prompt 或规则。
Verify	用可重复 eval 证明端到端成功率、成本和 latency 真正改善。

AI INFRA TAKEAWAYS

对 Multi-agent / Enterprise Infra 的启发

调度目标	不再只最小化单请求 latency，而是优化 makespan、质量、成本和冗余探索。
Shared context	多 Agent 不能每个都复制完整 context；需要分片、摘要、共享 artifact store 和 provenance。
通信	Agent-to-Agent 消息也会成为 token/latency 成本；应像分布式系统一样减少无效同步。
服务化	未来最抗替代的 SaaS 能力更像可信 API/数据/事务，而不是仅靠固定 UI。
Taste bottleneck	可验证任务先被 Agent 吃掉；审美、模糊目标、组织判断仍更依赖 human-in-the-loop。

给组内讨论的一个统一框架

把每项 Agent 优化问成四个问题：①端到端成功率提升多少；②wall-clock 缩短多少；③总算力/Token/工具成本增加多少；④风险与人工验收成本是否变高。单看模型分数、Kernel 峰值或单 Token 价格都不够。

$$T_{total} = T_{queue} + T_{prefill} + T_{decode} + T_{tool} + T_{network} + T_{environment} + T_{verification} + T_{human_wait}$$

WHAT TO BELIEVE / WHAT TO DO

需要打折看的部分

- VivaTech 是高层趋势对谈，技术实现细节少于工程播客，适合看方向而不是直接当架构规范。
- “企业增长来自一般工作”是受访者观察，缺少公开分母和完整统计口径。
- “只和 Agent 交互”是长期设想；监管、专业工具和高可靠交互很可能长期保留独立界面。

给组员的三个可执行动作

1. 做 multi-agent 实验时同时记录质量增益和 duplication ratio，避免“更多 Agent = 更强”的错觉。
2. 把可组合 API / connector 当成产品资产：Agent 时代 UI 可能变化，稳定的服务接口反而更重要。
3. 为模糊目标任务设计人类 checkpoint，把 taste/judgment 放在高杠杆节点。

本场会谈的最终一句话

这场把 Agent 的产业形态讲得很透：下一阶段不是“一个更强聊天框”，而是模型可以调度其他 Agent；短期 SaaS 不会消失，但 UI 会越来越按需生成，长期用户可能只和自己的 Agent 交互。

原始资料

<https://vivatech.com/sessions/session/d4198606-e65f-f111-8fcb-6045bd954326>

<https://www.blogdumoderateur.com/vivatech-openai-openclaw-racontent-tournant-ia-agentique/>

整理日期：2026-09-10。报告为技术阅读笔记，不代表 OpenAI 官方路线承诺；产品状态以最新官方文档为准。