

GROUP TECH BRIEF / TIBO TALK SERIES #06

Ultra 其实是另一种 Test-time Scaling

Tibo x TBPN：GPT-5.6、Multi-agent Ultra、Computer Use 与 Voice

直播节目访谈 / 自动逐字稿 • 节目访谈片段 • 会谈日期 2026.07.09

一句话结论

这场把“速度”和“多 Agent”连接起来了：Ultra 不是单纯把一个模型推得更慢更深，而是让多个 Agent 并行协作；同时 computer use、推理 token 效率和高速 decode 一起决定 Agent 能否从后台任务变成实时操作伙伴。

四个最值得关注的信号

01 Ultra = Multi-agent Tibo 公开描述 Ultra 里可看到约 8 个 Agent 协作，把它视为 test-time compute 的新扩展方式。	02 Computer use 约 3x 相对上一代，他称 computer use 端到端明显更快，来源既有专门训练也有效率提升。
03 750 tok/s 他提到 Cerebras 版本约 750 tok/s；后来官方 Ultrafast 预览也公布 up to 750 output tok/s。	04 Voice -> Jarvis 语音 + computer use + Agent execution 组合后，交互从“发 prompt”更接近实时指挥。

说明：下文将“访谈观点”“技术解读”“方向推演”分开呈现；预测不视为正式产品承诺。

OVERVIEW

访谈背景与章节地图

受访者：Thibault “Tibo” Sottiaux，OpenAI Core Product / Codex 相关负责人。

对谈方：TBPN hosts

形式：直播节目访谈 / 自动逐字稿；时长：节目访谈片段

- 访谈观点
- 技术解读
- 方向推演
- 外部核验

章节地图 / 讨论顺序

时间 / 顺序	主题
开场	GPT-5.6 Sol 的整体能力变化
核心段 1	Ultra：多个 Agent 协同，另一种 test-time scaling
核心段 2	Prompt engineering 是否被更高级 orchestration 隐藏
中段	ChatGPT Work / connected apps
中段	Computer use 为什么变快：专门努力 + token efficiency + visual accuracy
后段	工程师如何管理长时间 Agent 工作负载
后段	Cerebras 高速版本 ~750 tok/s 与成本
结尾	Voice + desktop actions = “modern-day Jarvis”

阅读方法

先看 Tibo 明确表达的系统设计原则，再看这些原则对 Agent Runtime、Serving、Sandbox、Memory、Multi-agent 或软件工程流程的含义。不要把方向判断直接当作已经落地的功能。

CORE IDEAS

1. Multi-agent Ultra：把 Test-time Compute 横向扩展

- 传统 test-time scaling 常让单模型“想更久”：更多 reasoning tokens、更多搜索步骤。Ultra 暗示另一条轴：把任务拆成多个并行 workstream，让不同 Agent 同时探索、验证、产出。
- 这种方法最适合可分解任务。如果任务存在强串行依赖，或者多个 Agent 会重复读同一 context，扩展效率会迅速下降。
- 因此 Multi-agent 的关键指标不是 Agent 数，而是 parallel efficiency：最终 wall-clock 缩短多少、额外 token/工具调用增长多少、质量提升多少。


核心判断：这场把“速度”和“多 Agent”连接起来了：Ultra 不是单纯把一个模型推得更慢更深，而是让多个 Agent 并行协作；同时 computer use、推理 token 效率和高速 decode 一起决定 Agent 能否从后台任务变成实时操作伙伴。

2. Computer Use 的速度来自“更少犯错 + 更少 token + 更快系统”

- Tibo 明确说 computer use 并不是随模型规模“免费获得”，有专门团队针对 Windows / Mac / mobile 做工作；同时模型越准确，误点和回退越少。
- 这意味着 UI Agent 的 latency 不是纯 decode latency，而是 action loop：看屏幕 -> 推理 -> 点击/输入 -> 等 UI -> 再观察。任何一步变慢都会累加。
- 高速模型的真正价值是缩短每个控制回路，从而允许更密的反馈和人类实时纠偏。

SYSTEM VIEW

把访谈观点翻译成系统结构



这里最容易误解的一点

Agent 的“能力”并不等于裸模型能力。对真实任务而言，更接近：

$$\text{Agent Utility} = \text{Model} \times \text{Context} \times \text{Tools} \times \text{Runtime} \times \text{Safety} \times \text{Verification}$$

任何一项接近 0，端到端体验都会坍塌；这也是为什么模型 benchmark 提升并不总能等比例转化为产品收益。

工程上应该关注的闭环

Observe	任务 trace、tool call、权限、失败位置、人工介入、最终结果。
Diagnose	区分是模型、Harness、环境、数据、延迟还是安全策略导致失败。
Improve	把问题放回最合适的层修，而不是默认继续堆 prompt 或规则。
Verify	用可重复 eval 证明端到端成功率、成本和 latency 真正改善。

AI INFRA TAKEAWAYS

对推理优化 / Serving 的启发

并发放大	Ultra 会把单个用户请求放大成多个并行请求，KV cache、调度、公平性和峰值容量都会变难。
Speed tiers	高速 decode 只有端到端关键路径上的部分收益；tool/network/UI wait 仍受 Amdahl 定律限制。
Computer loop	要 profiling perception latency、reasoning latency、action dispatch、UI response、recovery 次数，而不是只看 TPOT。
Cost per result	多 Agent 与高速硬件都更贵，产品应优化“每个完成任务的成本”而不是单 token 单价。
Voice realtime	语音交互要求更稳定的 tail latency；P50 很快但 P99 卡顿仍会破坏“实时伙伴”体验。

给组内讨论的一个统一框架

把每项 Agent 优化问成四个问题：①端到端成功率提升多少；②wall-clock 缩短多少；③总算力/Token/工具成本增加多少；④风险与人工验收成本是否变高。单看模型分数、Kernel 峰值或单 Token 价格都不够。

$$T_{total} = T_{queue} + T_{prefill} + T_{decode} + T_{tool} + T_{network} + T_{environment} + T_{verification} + T_{human_wait}$$

WHAT TO BELIEVE / WHAT TO DO

需要打折看的部分

- TBPN 页面明确标注逐字稿为自动生成，具体措辞需谨慎；本报告对关键数字用官方 OpenAI 后续页面做了交叉验证。
- “约 8 个 Agent” 是 Tibo 对 Ultra 体验的描述，不代表所有 Ultra 请求固定启动 8 个 Agent。
- “computer use 约 3x faster” 是访谈中的相对描述，未给出统一 benchmark 条件，不应直接用于容量规划。

给组员的三个可执行动作

1. Multi-agent benchmark 同时画 quality / latency / total tokens / peak concurrency 四条曲线，找最优 Agent 数。
2. 把 Agent UI 操作做 trace span，统计 misclick / retry 对端到端延迟的贡献。
3. Serving 侧提前考虑 “一个用户请求 = N 个并发子请求” 的 admission control 与 quota。

本场会谈的最终一句话

这场把“速度”和“多 Agent”连接起来了：Ultra 不是单纯把一个模型推得更慢更深，而是让多个 Agent 并行协作；同时 computer use、推理 token 效率和高速 decode 一起决定 Agent 能否从后台任务变成实时操作伙伴。

原始资料

<https://www.tbpdigest.com/story/2026-07-09/openais-thibault-sottiaux-on-gpt-56-multi-agent-ultra-mode-3x-faster-computer-use-and-a-jarvis-style-voice-experience/transcript>

<https://openai.com/index/gpt-5-6/>

<https://openai.com/index/previewing-ultrafast/>

整理日期：2026-09-10。报告为技术阅读笔记，不代表 OpenAI 官方路线承诺；产品状态以最新官方文档为准。