

Blackwell (B200/B300/GB200/GB300) 业内状态与公开基线

公司、模型、生命周期、框架、精度与组件摸底

资料截止：2026-09-01

范围：B200、B300、GB200 NVL72、GB300 NVL72。严格区分生产案例、标准 benchmark、官方参考性能和仅支持状态；每条外部证据只保留一个主链接。

1. 执行摘要

- 1. 公开证据最成熟的落地方向是在线推理：B200/GB200 已形成 NVFP4 + P/D 分离 + DP/EP/WideEP + MTP/投机解码的稳定组合，B300/GB300 正从基线验证进入生产 SLA 阶段。
- 2. 训练侧的主流顺序仍是 BF16 作为质量基线，MXFP8 作为目前公开证据最充分的低精度训练方案；NVFP4 原生预训练已出现，但公开公司级采用面仍明显小于 MXFP8。
- 3. 大规模预训练的公开标杆已覆盖 8,192 张 GB300、DeepSeek-V3 671B、MXFP8；单机/小集群则已有 B300 对 B200 的 LoRA 与预训练可比数据。
- 4. 强化学习公开基线少于预训练和 serving。现阶段最可信的是 GB200 + NeMo RL/Megatron Core 的 BF16 GRPO，以及“集中训练 + 异构分布式 rollout”的工程实践。
- 5. Prefill 与 Decode 的最优栈已经分化：Prefill 更看重 Attention、长上下文、KV 传输与 CP/PP；Decode 更看重 NVFP4 MoE、低延迟 All-to-All、CUDA Graph、MTP/DFlash 与高接受率。
- 6. FA4、FlashInfer、DeepGEMM、DeepEP 等组件都已出现 Blackwell 实测，但成熟度不同：cuDNN/FlashInfer 更接近通用生产组件；FA4 与部分 Blackwell 专用 kernel 仍需按模型、shape、版本验证。
- 7. 任何跨来源的“几倍加速”都不能直接相加。模型、输入/输出长度、batch、SLA、精度、GPU 数、并行策略、软件版本和是否包含量化开销必须一致。

2. 证据等级与数据口径

等级	名称	定义
P	生产/客户案例	公开确认已用于真实客户、生产集群或生产 SLA；但厂商可能不披露全部栈。
B	标准或验证 benchmark	MLPerf、Exemplar 等可审计/标准化结果；证明能力，不等于该模型已长期生产运行。
R	官方参考性能	框架或硬件厂商给出的可复现参考；通常使用合成负载或理想调参。
S	支持/Day-0 readiness	证明框架、模型或精度能够运行；没有公开端到端性能或生产稳定性证据。

关键口径： tok/s/GPU、TPS/user、总 tokens/s、TTFT、TPOT、step time 与 time-to-train 不能互换；GB200/GB300 rack-scale 与 8-GPU HGX 也不能直接横比。

未披露项不做反向推断；厂商“x 倍”只在同一来源、同一负载、同一精度和同一软件版本内成立。

3. 使用 B 卡的公司、模型与公开状态

证据	公司/平台	B 卡与模型	阶段与场景	公开技术栈	公开状态/性能	来源
P	Microsoft Azure / OpenAI	4,608 张 GB300 GPU（64 个 NVL72 rack）；OpenAI 多万亿参数模型（未公开具体名称）	前沿模型训练；在线推理/Serving	GB300 NVL72、Quantum-X800 InfiniBand、NVLink rack-scale；框架/精度未披露	首个大规模 GB300 生产集群；目标扩展至数十万 Blackwell Ultra GPU；未给模型吞吐	Azure 官方
P	Microsoft Azure / Anthropic	GB300 NVL72；Claude	在线 serving、Agentic inference	Microsoft Foundry on Azure；精度与框架未披露	Claude 在 GB300 NVL72 上进入一般可用；未公开 tokens/s	NVIDIA 官方
P	Cohere / CoreWeave	GB200 NVL72；North、约 100B 参数模型	预训练/训练迭代；企业 Agentic AI 模型	生产 GB200 集群 + CoreWeave Kubernetes/对象存储；框架和精度未披露	相对 Hopper 训练性能最高约 3x，且是在 Blackwell 专项优化之前；存储最高 7 GB/s/GPU	CoreWeave 案例
P	IBM / CoreWeave	数千张 GB200；Granite 系列	训练与推理	CoreWeave 生产集群；框架/精度未披露	客户案例称 MLPerf 性能提升超过 80%；精确对照口径需回到原始提交	CoreWeave 案例

证据	公司/平台	B 卡与模型	阶段与场景	公开技术栈	公开状态/性能	来源
P	Prime Intellect / Nebius	16 张 GB200 PoC；后续 HGX B300 预训练；INTELLECT-3、Trinity Large	分布式预训练、后训练、强化学习、rollout	TorchTune；异构多云 rollout + 集中训练；拓扑感知调度	迁移仅需调整 Grace ARM 依赖；BF16 为训练基线，FP8 用于多数推理及部分 RL，FP4 仍谨慎	Nebius 案例
P	Cursor / Together AI	GB200 NVL72 与 HGX B200；Cursor 私有代码模型	低延迟在线 serving	TensorRT-LLM、NVFP4 量化、跨数据中心部署	以最坏情况下并发延迟为约束；新权重数天内可转测试端点；具体 tok/s 未披露	Together 案例
P	DaoCloud / vLLM	24 张 B300；GLM-5.2- NVFP4，744B/40B active	在线 serving；16K-256K；P/D 分离	4P+1D；Prefill TP1 DP4 EP，Decode TP1 DP8 EP；NIXL、FlashInfer A2A、MTP、CUDA Graph	生产 SLA：mean TTFT <=2.5s、mean TPOT <=20ms；16K TPOT 约 40ms 降至 17ms	vLLM 生产复盘
P	Together AI	HGX B200；DeepSeek-R1-0528	在线 serving；低并发/专用端点	自研引擎、定制 kernel、投机解码；FP4/BF16 混合	公开最高约 334 tok/s；专用 batch=1 最高约 386 tok/s	Together 官方
P/R	Fireworks AI	B200；DeepSeek-V3/R1 类模型	在线 serving；高吞吐推理	FireAttention V4、NVFP4、QAT/量化部署	公开结果超过 250 tok/s；对比 H200 SGLang 展示约 3.5x 吞吐；属于厂商公开基线	Fireworks 官方
P	xAI / Colossus	超过 22 万张 GPU 的集群，包含 GB200；未绑定到具体 Grok 版本	训练、微调与推理基础设施	超大规模集群；具体框架、精度和并行策略未披露	确认 GB200 已进入实际算力池；不能据此断言某个特定 Grok 模型由 GB200 完成训练	xAI 官方
B	Oracle OCI	GB300 NVL72、HGX B300；DeepSeek V3、GPT-OSS 120B、Kimi-K2、Llama 3.1、Qwen3 等	云平台训练/推理 readiness	NVIDIA Exemplar 验证栈	参考工作负载达到 NVIDIA 目标性能的 5% 范围内；属于平台验证，不等于客户生产案例	Oracle 官方
R/S	Thinking Machines Lab / vLLM	4 张 GB200；Inkling 约 1T 多模态模型	在线推理；8K input / 1K output	vLLM、MTP8、LoRA、TP/DP/EP/PP、prefix cache、P/D、FA4 sheared-bias	约 380 tok/s/user (MTP8)，不使用 MTP 时约 140；仅 routed experts 为 NVFP4，其余关键权重保留 BF16	vLLM Day-0
R	NVIDIA	B200；Nemotron 3 Super，120B/12B active	原生 NVFP4 预训练、SFT、RL、推理	NeMo/Megatron、NeMo Gym/NeMo RL；vLLM/SGLang/TRT-LLM 推理 cookbook	公开称 25T token 原生 NVFP4 预训练；SFT 约 7M 样本；RL 超过 120 万 rollouts；B200 推理相对 H100 FP8 约 4x	NVIDIA 官方
S	Mistral AI	Mistral Large 3，675B/41B active；Blackwell NVFP4 checkpoint	Blackwell 推理 readiness	llm-compressor、vLLM；TRT-LLM/SGLang 支持 P/D 与 speculative decode	原始训练明确使用约 3,000 张 H200，并非 B 卡；B 卡证据是 NVFP4 checkpoint 与 serving 支持	Mistral 官方
S	Qwen / vLLM	Qwen3.8-2.4T-A95B；BF16/FP8/ NVFP4/MXFP4 checkpoints	在线/离线推理 readiness	vLLM；NVFP4 FlashInfer CuTeDSL linear backend；MTP	非 FP4 版本至少需要两节点 B300，FP4 可单节点；公开文档为 Day-0 支持，未给生产 SLA	vLLM 官方
P/S	Fireworks AI Training	Qwen3.5 397B-A17B 32xB200；Kimi K2.5 64xB200；Kimi K2.5 LoRA 8xB300；Nemotron 3 Super 16xB200	预训练、SFT/LoRA、RL policy/reference	FSDP/PP/CP/EP、DeepEP、MXFP8 grouped GEMM、FA4、QAT	展示可用模型规模和系统组合；不是统一测试条件下的横向 benchmark	Fireworks 官方

4. 生命周期：哪个阶段在用 B 卡

阶段	当前 B 卡主流状态	典型框架/策略	主流精度	迁移判断	来源
预训练	GB200/GB300 已有千到万卡标准基线；B300 单机也有公开结果	Megatron Bridge / NeMo；TP+PP+CP+VP+EP；CUDA Graph、通信重叠	BF16 质量基线；MXFP8 最成熟；NVFP4 进入原生预训练	先复现 MXFP8/BF16，再评估 NVFP4；不要用理论 PFLOPS 代替 tok/s/GPU	Megatron Bridge
后训练/SFT	公开公司细节少于预训练；框架能力已成熟	Megatron/NeMo、FSDP、PEFT；模型并行与 sequence packing	BF16/FP8/MXFP8；量化感知训练用于 NVFP4 部署	质量验收优先；保留高精度 optimizer/master weights 和关键层	Fireworks Training

阶段	当前 B 卡主流状态	典型框架/策略	主流精度	迁移判断	来源
微调/LoRA	B300/B200 已有 MLPerf 可比结果；单机即可形成稳定基线	LoRA/PEFT；单机或小规模 DP/FSDP	BF16/FP8；权重打包和前向反量化可进一步节省显存	适合作为第一批迁移验收 workload，变量少、结果容易和 H 卡对照	Nebius MLPerf
强化学习	公开数据仍有限，但 GB200 已有 DeepSeek/Qwen GRPO 基线	NeMo RL + Megatron Core；生成 TP/PP 与训练 TP/CP/EP/PP 分离；on/off-policy	BF16 最稳；FP8 可用于 rollout 及部分端到端 RL	必须分开记录 generation 与 training 占比、接受率、平均生成长度和 idle time	NeMo RL
在线 Serving	目前公开生产证据最充分	vLLM/SGLang/TRT-LLM；P/D、DP/EP/WideEP、MTP/DFlash、KV-aware routing	NVFP4 混合精度；Attention/KV 常保留 FP8/BF16	以 SLA 下的可持续吞吐为主，不以峰值离线吞吐作为上线条件	GLM-5.2 生产
离线推理	MLPerf 与 TRT-LLM 参考数据成熟，便于做硬件/版本对照	TensorRT-LLM、ModelOpt；TP/EP/DEP；最大负载或固定并发	FP4/NVFP4、FP8	可作为芯片和 kernel 上限基线，但不能直接代表在线 P99/TTFT/TPOT	TRT-LLM 性能
Prefill	长上下文与 P/D 推动 Prefill 独立优化	PP/CP、chunked prefill、P/D；NIXL/Mooncake KV transfer；FA4/cuDNN/FlashInfer	BF16/FP8/MXFP8 attention；模型线性层可 NVFP4	关注 prompt tok/s/GPU、TTFT、chunk size、KV 容量与网络传输，不只看 GEMM	SGLang 长上下文
Decode	Blackwell 收益最依赖系统协同，而非单 kernel	WideEP/DEP、低延迟 All-to-All、full CUDA Graph、MTP/DFlash、FP4 MoE	NVFP4 MoE/linear；FP8/BF16 attention/KV/关键层	重点测 TPOT/P99、每用户 tok/s、MTP 接受率、batch 长尾和 EP 通信	TRT-LLM 低延迟

5. 训练公开基线

Megatron Bridge 的数据是 recipe 级参考；MLPerf 是到达质量阈值的标准化 benchmark；客户案例中的相对倍数仍要回到原始负载验证。

证据	模型/任务	硬件	精度	分布式	结果	来源
R	DeepSeek-V3 预训练	256x DGX-GB300	MXFP8	TP1 PP2 CP1 VP8 EP32；seq 4096	6,288 tok/s/GPU；1,635 model TFLOPS/GPU	Megatron Bridge
R	DeepSeek-V3 预训练	256x DGX-GB200	MXFP8	TP1 PP4 CP1 VP4 EP64；seq 4096	4,912 tok/s/GPU；1,276 model TFLOPS/GPU	Megatron Bridge
R	DeepSeek-V4 Flash 预训练	128x DGX-GB300	MXFP8	TP1 PP1 EP64；seq 4096	8,224 tok/s/GPU；748 model TFLOPS/GPU	Megatron Bridge
R	GPT-OSS 120B 预训练	64x DGX-GB300	MXFP8	TP1 PP1 EP16；GBS1280、MBS4、seq4096	33,024 tok/s/GPU；1,077 model TFLOPS/GPU	Megatron Bridge
R	Qwen3 235B-A22B 预训练	256x DGX-GB300	MXFP8	TP1 PP4 VP12 EP32；seq4096	8,816 tok/s/GPU；1,306 model TFLOPS/GPU	Megatron Bridge
R	Nemotron 3 Super 预训练	64x DGX-GB300	MXFP8	TP1 PP1 EP64；seq8192	9,856 tok/s/GPU；831 model TFLOPS/GPU	Megatron Bridge
R	Nemotron 3 Super 预训练	64x DGX-GB300	NVFP4	TP1 PP1 EP64；seq8192	10,240 tok/s/GPU；864 model TFLOPS/GPU	Megatron Bridge
B	DeepSeek-V3 671B MLPerf Training v6.0	8,192x GB300	MXFP8	2,048 nodes；Spectrum-X；MoE 大规模训练	达到质量目标用时 2.02 分钟	CoreWeave MLPerf
B	DeepSeek-V3 671B MLPerf Training v6.0	4,096x GB300	MXFP8	1,024 nodes	3.09 分钟	CoreWeave MLPerf
B	DeepSeek-V3 671B MLPerf Training v6.0	2,048x GB300	MXFP8	512 nodes	5.54 分钟	CoreWeave MLPerf
B	Llama 3.1 405B MLPerf Training v6.0	4,096x GB300	官方提交精度	NeMo 26.04；full CUDA Graph；TP/PP/CP 调优	9.77 分钟；相对同测试此前结果约 2.8x	CoreWeave MLPerf

证据	模型/任务	硬件	精度	分布式	结果	来源
B	Llama 2 70B LoRA	8x HGX B300	MLPerf 提交配置	单节点微调	8.48 分钟; 8xB200 为 9.55 分钟	Nebius MLPerf
B	Llama 3.1 8B 预训练	8x HGX B300	MLPerf 提交配置	单节点	75.84 分钟; 8xB200 为 85.37 分钟	Nebius MLPerf
B	Llama 2 70B LoRA 扩展	8/16/32x B200	MLPerf 提交配置	单机到多机	9.55 / 5.82 / 3.10 分钟; 8 到 32 GPU 约 3.1x	Nebius MLPerf
P	Cohere 约 100B 模型训练	GB200 NVL72	未披露	生产集群; Blackwell 专项优化前	相对上一代 Hopper 最高约 3x 训练性能	Cohere/CoreWeave
R	Llama/Nemotron 多尺寸训练	DGX B200	MXFP8 vs BF16	NeMo + Transformer Engine	官方汇总约 1.28x-1.37x 训练吞吐提升; 大 GEMM 收益更明显	NVIDIA NeMo
R	DeepSeek-16B / DeepSeek-V3 671B 训练	256x B200	训练 recipe 精度	TorchTitan + DeepEP/NVSHMEM/IBGDA	DeepSeek-16B 吞吐约 +65%; V3 671B 约 +25%; MFU 同步提升	Nebius 工程复盘

6. 强化学习公开基线

证据	模型/算法	硬件	精度	训练/生成并行	负载	结果	来源
R	DeepSeek-V3 GRPO on-policy	128x GB200-NVL72	训练 BF16; 生成 BF16	生成 TP32 PP1; 训练 TP1 CP1 EP16 PP8	T-max 1536; 平均生成 711	30.2 tok/s/GPU; step 108s	NeMo RL
R	DeepSeek-V3 GRPO on-policy	256x GB200-NVL72	BF16/BF16	生成 TP32 PP1; 训练 TP1 CP1 EP16 PP8	平均生成 700	16.4 tok/s/GPU; step 98.7s	NeMo RL
R	DeepSeek-V3 GRPO 1-step off-policy	256x GB200-NVL72	BF16/BF16	生成 TP16 PP1; 训练 TP1 CP1 EP16 PP8	平均生成 708	26.7 tok/s/GPU; step 61.7s	NeMo RL
R	Qwen3-235B GRPO on-policy	64x GB200-NVL72	BF16/BF16	生成 TP8 PP1; 训练 TP2 CP2 EP16 PP4	T-max 8192; 平均生成 5709	163 tok/s/GPU; step 286s	NeMo RL
R	Llama 3.1 8B GRPO	Blackwell/Hopper 对照栈	端到端 FP8 blockwise vs BF16	vLLM rollout + Megatron Core training	训练与 rollout 混合	公开示例准确率 0.613 vs BF16 0.616; 吞吐提升超过 15%	NVIDIA FP8 RL
P	Prime Intellect 分布式 RL	GB200 PoC、B300 预训练及异构云 GPU	BF16 主训练; FP8 用于适合的 rollout/推理	多集群分布式 rollout, 汇总后集中训练	INTELLECT-3 100B+ MoE 等	公开证明工作流已实际运行; 未给统一 tok/s 或 step time	Prime Intellect

7. 推理公开基线：在线、离线、Prefill 与 Decode

在线生产结果应优先看 SLA 下可持续吞吐和 P99; 离线与 MLPerf 结果更适合看硬件、框架和精度上限。

证据	模型/硬件	场景	精度	框架/组件	公开结果	来源
R	DeepSeek 671B / GB200	P/D 分离; ISL 约 2000	FP8 路径	SGLang、Large EP、DeepGEMM、DeepEP、FlashInfer、Mooncake	Decode 7,583 output tok/s/GPU; 约 2.7x H100	SGLang Part I
R	DeepSeek V3/R1 / GB200	Prefill + Decode; ISL2000	FP8 Attention + NVFP4 MoE	SGLang、P/D、DeepGEMM、DeepEP、FlashInfer/CuTe/CUTLASS	Prefill 26,156 input tok/s/GPU; Decode 13,386 output tok/s/GPU; 约 3.8x/4.8x H100	SGLang Part II
R	DeepSeek-R1-NVFP4 / GB300	128K input / 8K output 长上下文	NVFP4 linear; FP8 Attention/KV	SGLang + Dynamo; PP Prefill、WideEP Decode、MTP	峰值 226.2 TPS/GPU; 约 1.53x GB200; MTP 每用户吞吐约 1.87x; TTFT 8.6s	SGLang GB300

证据	模型/硬件	场景	精度	框架/组件	公开结果	来源
R	DeepSeek R1/V3/V3.1 / GB200	P/D, 2K input / 2K output	NVFP4/FP8 GEMM	vLLM、DP+EP、WideEP、NVFP4 dispatch、fusion	Prefill 26.2K TPGS; Decode 10.1K TPGS; 约 3-5x H200	vLLM WideEP
R	Qwen3.5 397B-A17B NVFP4 / GB200 NVL72	高并发, 8K input / 1K output	NVFP4	vLLM、P/D、异步调度、FlashInfer GDN prefill	总吞吐超过 25K TPS/GPU; FlashInfer kernel 最高 5.92x, Prefill 端到端 +13%, mean TTFT -12%	vLLM Qwen3.5
R	DeepSeek-R1-0528 / 8xB200	离线参考, 1000/1000	FP4	TensorRT-LLM; DEP4	6,463 output tok/s/GPU	TRT-LLM 性能
R	DeepSeek-R1-0528 / GB200	离线参考, 1000/1000	FP4	TensorRT-LLM; DEP4	6,939 output tok/s/GPU; 同页 H200 FP8 为 1,627	TRT-LLM 性能
R	GPT-OSS 120B / B200	离线参考, 1000/1000	FP4	TensorRT-LLM; DEP2	25,943 output tok/s/GPU	TRT-LLM 性能
R	GPT-OSS 120B / GB200	离线参考, 1000/1000	FP4	TensorRT-LLM; TP1	27,198 output tok/s/GPU; 同页 H200 FP8 为 6,868	TRT-LLM 性能
R	DeepSeek-R1 / 8xB200	低延迟、每用户吞吐	Attention BF16; dense FFN/MoE NVFP4; MTP/router BF16	TensorRT-LLM; Attention TP8, 专家 TP4+EP2, 共享专家 TP8, 其他 DP8	优化路径约 67 -> 253 -> 368 TPS/user; MTP3 相对无 MTP 约 2.28x	TRT-LLM 低延迟
B	Llama 2 70B / 8xB200	MLPerf Inference v5.0 Server/Offline	FP4	TensorRT-LLM + ModelOpt	Server 98,443 tok/s; Offline 98,858 tok/s; 约 3.0x/2.8x 8xH200	MLPerf v5.0
B	Mixtral 8x7B / 8xB200	MLPerf Inference v5.0 Server/Offline	FP4	TensorRT-LLM + ModelOpt	Server 126,845 tok/s; Offline 128,148 tok/s; 约 2.1x 8xH200	MLPerf v5.0
B	DeepSeek-R1 / GB300	MLPerf Inference v5.1 Offline/Server	NVFP4	TRT Model Optimizer + TRT-LLM; EP + ADP Balance	Offline 5,842 tok/s/GPU; Server 2,907 tok/s/GPU; 相对 GB200 +45%/+25%	MLPerf v5.1
P	GLM-5.2-NVFP4 / 24xB300	生产 P/D; 16K-256K; SLA 驱动	NVFP4	vLLM、NIXL、FlashInfer A2A、MTP3 decode、FULL_DECODE_ONLY graph	mean TTFT <=2.5s、mean TPOT <=20ms; 16K TPOT 约 17ms	vLLM 生产复盘
P	DeepSeek-R1-0528 / HGX B200	Serverless/专用在线端点	FP4/BF16 混合	Together 自研引擎、定制 kernel、投机解码	最高约 334 tok/s; 专用 batch=1 约 386 tok/s	Together 官方
P/R	DeepSeek-V3/R1 / B200	在线推理	NVFP4	FireAttention V4、QAT	超过 250 tok/s; 相对 H200 SGLang 展示约 3.5x 吞吐	Fireworks 官方
R/S	Inkling 1T 多模态 / 4xGB200	8K input / 1K output; 每用户吞吐	routed experts NVFP4; 关键权重 BF16	vLLM、FA4 sheared-bias、MTP8、LoRA、P/D	约 380 tok/s/user; 无 MTP 约 140	vLLM Inkling
R	GPT-OSS 120B / 8xB300	高交互吞吐; SPEED-Bench	模型对应低精度路径	TensorRT-LLM + DFlash	相同 interactivity 下吞吐超过自回归 15x; 相对 EAGLE-3 约 1.5x	NVIDIA DFlash

8. 框架成熟度

框架	覆盖阶段	B 卡状态	分布式能力	精度	当前判断	来源
Megatron Bridge / NeMo	预训练、SFT、PEFT、部分后训练	GB200/GB300/B300 官方性能 recipe 完整	TP/PP/CP/VP/EP、FSDP、通信重叠、CUDA Graph	BF16、FP8、MXFP8、NVFP4	训练侧首选基线; 适合把 H 卡 recipe 与 B 卡 recipe 做同模型同 seq 对照	Megatron Bridge
NeMo RL	GRPO/PPO/DAPO、on/off-policy RL	GB200 BF16 有公开 DeepSeek/Qwen 基线	生成与训练采用不同 TP/PP/CP/EP; Megatron Core backend	BF16 已验证; FP8 路径逐步成熟	公开 RL 基线最系统; 必须锁定 checkpoint 和平均生成长度	NeMo RL
vLLM	在线 serving、离线推理、P/D、spec decode	B300 生产 SLA、GB200/B200 多模型参考均已公开	TP/DP/EP/DEP、P/D、NIXL、CUDA Graph、MTP	BF16/FP8/NVFP4/MXFP4	开源 serving 首选之一; Blackwell 专用 backend 与版本迭代很快	vLLM 生产案例
SGLang	在线 serving、长上下文、P/D、WideEP	GB200/GB300 DeepSeek 系列连续公开基线	Prefill/Decode 分离、Large/Wide EP、Dynamo、DeepEP	FP8 Attention/KV、NVFP4 MoE	MoE + P/D + WideEP 的重要参考栈; 适合对照 vLLM	SGLang Part II

框架	覆盖阶段	B 卡状态	分布式能力	精度	当前判断	来源
TensorRT-LLM	在线/离线推理、低延迟与 MLPerf	B200/GB200/GB300 参考表和 MLPerf 最完整	TP/EP/DEP、混合并行、spec decode、P/D	FP8、NVFP4/FP4 混合	NVIDIA 平台峰值和标准 benchmark 的核心参考；构建期和模型适配成本较高	TRT-LLM 性能
NVIDIA Dynamo	分布式 serving 控制面	已用于 GB300 长上下文公开方案	P/D orchestration、KV-aware routing、弹性与多后端	继承后端	适合大规模 P/D 与多实例调度；不是单机 kernel 替代品	SGLang+Dynamo
TorchTune	预训练/后训练/RL 工程栈	Prime Intellect GB200->B300 实际迁移案例	配合异构多云 rollout 与集中训练	BF16 主线，FP8 用于部分推理/RL	PyTorch-native 迁移阻力较小；公开性能数字少	Prime Intellect
TorchTitan	PyTorch 原生大模型训练	B200 上 DeepSeek recipe + DeepEP 实测	FSDP/TP/CP/EP；可接 DeepEP/NVSHMEM	依 recipe	适合研究 PyTorch-native MoE 训练；生态成熟度低于 Megatron	Nebius TorchTitan
veRL	RLHF/GRPO rollout + training	文档支持 aarch64 GB200；可选 FSDP/FSDP2/Megatron 与 vLLM/SGLang	训练/rollout 后端组合；镜像含 DeepEP 配置路径	依训练与 rollout 后端	具备 Blackwell bring-up 路径，但公开 B 卡模型级性能不如 NeMo RL 完整	veRL 文档

9. 精度成熟度

精度	训练成熟度	推理成熟度	典型 B 卡用法	主要风险	来源
BF16	最高；仍是预训练/后训练/RL 的质量与稳定性基线	可用于 attention、router、shared experts、MTP 等敏感模块	先建立 H/B parity；低精度模型也常保留部分 BF16	吞吐/容量不能充分利用 Blackwell FP4/FP8 优势	Prime Intellect
FP8 blockwise	可用于训练和端到端 RL；源自 DeepSeek 类局部缩放思路	线性层、Attention/KV 可用	默认 block 128；activation 1D、weight 2D、gradient 1D；无需跨节点同步 scale	在 Blackwell 的 TE 实现中通过 MXFP8 模拟/映射，官方更推荐直接使用 MXFP8；版本差异大	Transformer Engine
MXFP8	目前 B 卡公开证据最充分的低精度训练格式	成熟，但很多推理栈更偏向 NVFP4	E4M3/E5M2 + E8M0 block scale；32 values/block；GB300 大规模预训练	转置方向需要独立量化/scale；小 GEMM 与 metadata 成本可能压低收益	TE Primer
NVFP4	已出现原生预训练与标准 recipe，但公司级公开采用仍少于 MXFP8	Blackwell serving 的主流高性能路径	E2M1，16 values/block，E4M3 block scale + tensor-wide FP32 scale；常做混合精度	量化开销、敏感层、scale layout、软件版本正确性；不能只看 pre-quantized GEMM	NVFP4 文档
MXFP4	公开训练证据有限，更多作为模型原生/发布格式	GPT-OSS、Qwen 等模型在 Blackwell 推理已支持	E2M1 + E8M0 scale、32 values/block；MoE weights 常量化、其余保留 BF16	动态范围和质量较 NVFP4 更受限；kernel/layout 支持依赖模型与框架	vLLM GPT-OSS

10. 组件成熟度

组件	作用位置	B 卡公开状态	公开性能/能力	迁移建议	来源
FlashAttention-4 (FA4)	Prefill/训练 Attention forward+backward	B200 论文级实测；已进入部分模型/框架集成	最高约 1,613 TFLOPS，约为理论峰值 71%；相对 cuDNN 9.13 约 1.3x、Triton 约 2.7x（特定 shape）	先验证 head dim、mask/bias、GQA/MLA、反向与确定性；不要把论文峰值当通用收益	FA4 论文
cuDNN Attention	训练/Prefill Attention	官方生产库；持续增加 Blackwell SDPA/MLA/MXFP8 支持	B200 FP8 Flash Attention 相对 H100 公开最高约 +50% forward、+84% backward（特定配置）	优先作为正确性和稳态基线；再对比 FA4/FlashInfer	NVIDIA cuDNN
FlashInfer	Prefill/Decode Attention、GEMM、MoE、A2A	vLLM/SGLang 多个 B 卡生产或参考方案采用	GLM-5.2 B300 中 NVLink two-sided A2A 使 TPOT 再降约 4%；Qwen3.5 GDN prefill kernel 最高 5.92x	按具体 backend 锁版本；A2A one/two-sided、CuTeDSL linear、GDN 分别测试	GLM 生产案例

组件	作用位置	B 卡公开状态	公开性能/能力	迁移建议	来源
DeepGEMM	FP8/FP4/BF16 GEMM，尤其 MoE grouped GEMM	SGLang GB200 高性能栈的重要组成；开源支持 Blackwell	与 DeepEP、P/D、NVFP4 MoE 联合后形成 GB200 DeepSeek 公开高吞吐基线	先从真实 shape histogram 建 JIT/autotune cache；单 GEMM 峰值不代表端到端	DeepGEMM GitHub
DeepEP	MoE dispatch/combine、All-to-All	训练与推理均有 B200 实测	TorchTitan B200 训练中公开 DeepSeek-16B 吞吐约 +65%、V3-671B 约 +25%；SGLang 也报告推理收益	区分节点内 NVLink 与跨节点 RDMA；测试 normal/low-latency 模式、token 分布与尾部专家	Nebius DeepEP
DFlash	Decode 投机解码	TRT-LLM、vLLM、SGLang 均有 Blackwell 路径	GPT-OSS 120B/8xB300 在指定 interactivity 下相对自回归超过 15x；另有 B200/SGLang 等结果	关注接受率、draft 开销、CUDA Graph、batch 混合和质量，不只看理论 draft length	NVIDIA DFlash
NIXL	P/D 分离的 KV cache 传输与内存连接	GLM-5.2 B300 生产配方直接使用	支撑独立 Prefill/Decode 池与远端 KV handoff；公开案例重点是 SLA 稳定性而非单链路 GB/s	单独测 KV transfer latency、队列深度、partial block、异步加载与 host memory 稳定性	NIXL GitHub
Transformer Engine	FP8/MXFP8/NVFP4 训练与推理算子/recipe	Blackwell 低精度训练核心库	提供 MXFP8、NVFP4、FP8 blockwise recipes 与量化管理	锁 TE/CUDA/cuBLAS 版本；分开测 quantization-inclusive 与 pre-quantized	Transformer Engine
TensorRT Model Optimizer	FP8/FP4 量化、模型压缩与 TRT-LLM 部署	MLPerf B200/GB300 栈采用	用于 Llama、Mixtral、DeepSeek 等 FP4/NVFP4 提交	建立校准、敏感层保留、精度评估和 checkpoint 可追溯链	ModelOpt GitHub
FlashMLA（相邻组件）	MLA Prefill/Decode	开源项目提供 B200 预填充/稀疏 MLA 数据	项目公开 B200 MHA prefill 最高约 1,460 TFLOPS forward、约 1,000 backward，依 shape	只对 MLA/稀疏 Attention 模型适用；与 FA4/cuDNN/FlashInfer 同 shape 比较	FlashMLA GitHub

11. 已经证明的事情与仍然缺失的证据

11.1 已经有较强公开证据

- GB300 可在数千至 8,192 GPU 规模上运行 MXFP8 MoE 预训练标准 workload。
- B200/GB200 在线推理已形成 NVFP4 + P/D + EP/WideEP + 投机解码的成熟组合。
- B300 已出现 24 GPU、长上下文、真实 SLA 约束下的 vLLM 生产案例。
- GB200 上 BF16 GRPO 已有 DeepSeek-V3 与 Qwen3-235B 的公开并行配置和 step time。
- NVFP4 可用于原生预训练，但公开公司级实践仍不如 MXFP8 广泛。

11.2 仍然缺失或常被混淆

- 大量公司只公布“已使用 B 卡”，没有模型名、精度、框架、并行策略和长期稳定性数据。
- NVFP4 数字常混合 pre-quantized GEMM、离线 max-load 与在线 SLA，不能直接横比。
- MXFP4 的公开训练证据明显不足；当前主要是模型发布格式和推理支持。
- RL 的 B300/GB300 公开基线仍少；生成、训练和环境执行的占比常未披露。
- FA4 论文峰值、cuDNN/FlashInfer production coverage 与具体 feature 支持不是同一维度。

12. H 卡 -> B 卡建议验收工作包

工作包	必须收集	验收输出	来源
1. 资产盘点	模型/权重 digest、shape histogram、ISL/OSL、batch/concurrency、训练 seq/GBS/MBS、NCCL 消息分布	H 卡基线矩阵和所有软件 commit/digest	性能口径参考
2. BF16 parity	loss/accuracy、kernel coverage、step time 或 TTFT/TPOT、显存、功耗	排除架构、编译和通信问题后再进入低精度	BF16 实践
3. MXFP8/FP8	量化开销、scale layout、转置、梯度/optimizer、通信量	训练 tok/s/GPU、质量、稳定性、checkpoint 兼容	FP8 blockwise
4. NVFP4/MXFP4	敏感层保留、量化校准、每层误差、pre-quantized vs inclusive	性能-质量 Pareto，而非单一峰值	NVFP4 文档
5. Prefill/Decode 拆分	TTFT、TPOT、P50/P99、KV transfer、chunk size、每池利用率	P/D 拓扑与资源比；不同上下文长度的 SLA 容量曲线	GLM 生产方法
6. MoE 通信	expert load、dispatch/combine 时间、跨节点比例、tail expert、A2A backend	DeepEP/FlashInfer/NCCL 后端按 token 分布选择	DeepEP 训练
7. 投机解码	接受率、mean accepted length、draft/verify 时间、graph miss、质量	不同并发和长度下 MTP/DFlash 是否净收益	DFlash
8. 生产稳定性	长稳、host/GPU memory、冷启动/JIT、rolling update、故障恢复	多日稳定性与回滚方案；不能只过短 benchmark	GLM 稳定性

13. 对本次迁移的直接建议

- 训练第一批：一个 dense + 一个 MoE，先 BF16 parity，再 MXFP8；NVFP4 放第二轮。
- 推理第一批：固定 Prefill-only、Decode-only、端到端 P/D 三套测试，避免综合数字掩盖瓶颈。
- 框架矩阵：vLLM 与 SGLang 做开源对照，TensorRT-LLM 做 NVIDIA 峰值对照；训练以 Megatron Bridge 为官方参考。
- 组件矩阵：Attention 先 cuDNN，再 FA4/FlashInfer；MoE GEMM 先框架默认/CUTLASS，再 DeepGEMM；A2A 先 NCCL，再 DeepEP/FlashInfer。
- 精度矩阵：BF16、FP8/MXFP8、NVFP4 分别记录质量和性能；MXFP4 只在模型原生支持时纳入。
- 上线指标：在线推理以 TTFT/TPOT/P99/SLA 下可持续吞吐为准；RL 以有效 rollout tok/s、step time、接受率和 GPU idle 为准。

生成日期：2026-09-01。正式验收请锁定驱动、CUDA、NCCL、框架 commit、容器 digest、模型和数据集版本。