


Harness 是什么？

把大模型从“会回答”变成“能执行”的工程系统
并结合 DeepSeek Harness 最新公开进展



面向 AI Infra / Coding Agent / 评测开发

信息截止：2026-08-14

文中把官方确认、媒体报道与工程推断分开标注。

Harness 到底是什么？

Harness 原意是“挽具、线束、测试夹具”。在大模型工程中，它指围绕模型搭建的**执行与控制系统**：接收任务、组织上下文、调用模型、执行工具、保存状态、验证结果，并决定何时继续、重试、回滚或结束。


模型提供“智力”；Harness 把智力接到文件、终端、工具、记忆与安全边界上。

裸模型：一次输入 -> 一次输出



适合问答、摘要、翻译。模型无法自行验证代码是否真的运行，也不会天然持久化任务状态。

Agent + Harness：多轮观察 -> 行动 -> 验证




Harness 维护循环与状态：模型可以读仓库、运行测试、观察报错、修改代码，再次验证。

常用公式： $\text{Model} + \text{Harness} + \text{Tools} + \text{Environment} = \text{Agent System}$ 。DeepSeek 的招聘描述把它进一步概括为“ $\text{Model} + \text{Harness} = \text{Agent}$ ”。^[10]

术语并无唯一中文翻译，常见叫法包括“执行框架”“驾驭层”“Agent 运行时”“支架系统”。保留英文 Harness 最不容易产生歧义。

一次 Agent 执行，Harness 做了什么？

模型并不直接控制操作系统。一个可靠的 Harness 会把“模型建议的动作”变成经过校验、隔离和记录的真实执行。



模型负责

理解任务、选择动作、生成参数、根据反馈修正计划。

Harness 负责

维护循环、协议、状态、权限、重试、超时与结果回传。

Sandbox 负责

在隔离资源中执行不可信代码，限制文件、网络 and 计算资源。

关键区别：模型“提出动作”，Harness“决定动作如何落地”。因此相同模型换一个 Harness，成功率、成本、速度与安全性都可能明显变化。^{[1][2]}

一个完整 Harness 的 9 个核心模块

不是所有 Agent 都需要全部模块。原则是：先做最小闭环，再为真实失败增加结构。过度脚手架也可能限制模型。



控制平面 vs 执行平面： Harness 更像控制平面，决定“做什么、何时做、能否做”；Sandbox / 浏览器 / GPU 容器是执行平面，负责真正运行。把两者分离有利于安全、恢复和扩展。^[4]


最小可用版本（MVP）



当任务开始跨文件、跨小时、跨多个工具时，再加入 checkpoint、压缩、多 Agent、异步任务与复杂审批。

Harness、Sandbox、MCP、Skill 到底有什么区别？

概念	它是什么	它不是什么 / 与 Harness 的关系
Model	负责预测、推理和生成动作。	通常无持久状态，也不会天然执行工具。
Agent	能围绕目标连续观察、行动和修正的系统。	Agent 通常是“模型 + Harness + 工具 + 环境”的整体。
Agent Harness	让模型作为 Agent 运行的执行、编排与控制系统。	负责 loop、context、工具、状态、权限、恢复和验证。
Sandbox	隔离执行代码/命令的环境。	只是 Harness 的一个执行组件；它不负责规划和上下文。
Tool	Agent 可调用的具体能力，如 shell、git、浏览器、数据库。	工具是“手脚”；Harness 管理工具可见性、参数和权限。
MCP	连接 Agent 与外部工具/数据源的标准协议。	MCP 不是 Agent 本身；Harness 可作为 MCP Client 管理多个 Server。
Skill	按需加载的任务说明、流程、脚本或知识包。	Skill 告诉模型“怎样做”；Harness 决定何时加载并如何执行。
Parser	把模型文本/流式 delta 解析为 reasoning、content、tool_calls。	通常是协议适配模块。解析错误会让“模型算对、系统解释错”。
Eval Harness	批量运行评测任务、记录轨迹、打分和汇总指标的基础设施。	它评测“模型 + Agent Harness”的整体；不是生产 Agent loop 本身。 [1]



最实用的记忆法：Harness 是“总控台”，Sandbox 是“隔离机房”，Tool 是“设备”，MCP 是“插座协议”，Skill 是“操作手册”，Parser 是“翻译器”。

为什么同一个模型，换 Harness 后表现会差很多？

评测一个 Agent，本质上是在评测模型与 Harness 的组合。Harness 会改变模型看见的信息、可用动作、反馈质量、重试预算和最终判定标准。^[1]

脆弱 Harness

整仓库塞入 → 一次生成 → 不验证


- 上下文噪声大，关键文件被淹没
- 工具 schema 含糊，参数经常出错
- Parser 丢失流式 tool call
- 失败后只重复同一动作
- 没有测试、回滚和状态恢复

可靠 Harness

检索相关文件 → 执行验证 → 反馈修正

- 先构建地图，再逐步披露细节
- 工具参数强类型、错误可解释
- 执行结果以结构化 observation 返回
- 区分可重试错误与不可恢复错误
- 每个阶段都有明确完成条件

Harness 的 6 个“能力放大器”



也不能无限加复杂度：每个 Harness 组件都隐含“模型做不到什么”的假设。随着模型增强，这些假设可能过时；应持续做消融测试，保留真正 load-bearing 的部分。^[3]

DeepSeek Harness：截至 2026-08-14 能确认什么？

2026-04-24

DeepSeek-V4 预览版发布

官方称 V4 对 Agent 能力做了专门优化，已接入 Claude Code、OpenClaw、OpenCode，并用于公司内部 Agentic Coding。^[6]

2026-05-20

Harness 团队招聘进入公开视野

公开报道引用官方职位描述：团队把前沿模型能力转化为桌面端 Agent 产品，方向对标 Claude Code。^[10]

2026-06-21 至 06-25

团队扩招

招聘公开涉及 Harness 研究员、工程师、产品经理；“Model + Harness = Agent”成为核心表述。^[11]

2026-08-13

V4-Pro-0813 正式发布

Reuters 报道正式版进一步增强 Agent 能力，并向 API、App、Web 提供。^[12]

2026-08-14

当前官方可见状态

DeepSeek 招聘官网仍列出“Agent Harness 团队”，同时列出 Agent Infra、Code Agent 数据等相关岗位。^[5]

已确认

公开证据支持

- DeepSeek 内部存在独立 Agent Harness 团队
- 方向是把模型能力产品化为桌面端 / Coding Agent
- 官方招聘页当前仍有该团队岗位
- DeepSeek V4 已支持主流第三方 Agent Harness
- V4 API 支持工具调用、思考模式和 1M 上下文

尚未官方公开

不能当作已发布事实

- 最终产品名是否叫“DeepSeek Code”
- CLI、IDE、桌面端还是云端多任务形态
- 内部架构、是否开源、定价与正式发布日期
- 网上流传的封闭测试截图与功能清单


重要结论：目前可以谈“DeepSeek 正在建设自研 Harness”，但不能把某个第三方同名仓库、非官方网站或传闻中的内测包，当成 DeepSeek 官方产品。

当前形态可以理解为：DeepSeek 已有强 Agent 模型 + 外部 Harness 生态，同时正在补齐自己的 Harness 产品层。

官方招聘页是当前最直接的官方证据；产品目标与“Model + Harness = Agent”来自同期媒体对官方职位页和团队公开招聘信息的记录。

DeepSeek 目前如何被各种 Harness 使用？

DeepSeek 官方文档已经给出多种 Agent 工具接入指南。它们大多是第三方 Harness，DeepSeek 提供模型与兼容 API；Harness 提供工具循环、代码编辑、记忆、权限和产品体验。[\[6\]](#)[\[9\]](#)



Claude Code

官方指南推荐通过 DeepSeek 的 Anthropic 兼容端点接入，可保留其成熟的代码编辑、工具和子 Agent 能力。[\[9\]](#)

Pi

DeepSeek 官方文档直接称其为“minimal, aggressively extensible terminal coding harness”，突出扩展、Skill 与树状 session。[\[9\]](#)

Reasonix

围绕 DeepSeek API 设计：Cache-First、Flash-First 成本控制和工具调用自动修复，体现 Harness 的路由价值。[\[9\]](#)

所以“用 DeepSeek 做 Coding Agent”不等于“使用 DeepSeek 自研 Harness”：你可以把 DeepSeek 作为模型后端，接到不同 Harness 上；最终体验由两者共同决定。

DeepSeek 专用 Harness，最容易踩坑的地方

1. `reasoning\_content` 生命周期

DeepSeek V4 思考模式默认开启。普通多轮对话中，历史 reasoning 可被忽略；但**只要发生工具调用**，该 assistant 消息的 `reasoning\_content` 就必须在后续请求中完整回传，否则 API 返回 400。^[8]

```
# 正确做法：保存完整 assistant message
messages.append(response.choices[0].message)

# 其中包含：
# content + reasoning_content + tool_calls
```

这正是 Harness 的职责：应用层不应只保留最终文本，而要保存协议所需的结构化状态。



2. 其他 Harness 适配点

思考参数

默认 thinking enabled；effort 支持 high / max。复杂 Agent 请求可能自动使用 max。^[8]

端点选择

同时提供 OpenAI 与 Anthropic 兼容接口。某些客户端在 OpenAI 路径无法保留 reasoning 状态，应改用 Anthropic 端点。^[9]

流式解析

Harness 要聚合 content、reasoning 与 tool-call delta，并正确匹配 tool_call_id，不能只拼接文本。

模型路由

Flash 适合高频、低成本迭代；Pro 用于困难规划、复杂修复与最终审查。Reasonix 的 Flash-First 是典型模式。^[9]

长上下文

1M 上下文并不意味着全部塞入。仍需检索、缓存、摘要、结构化 artifact 和 token 预算。^[7]

协议回归测试

模型/API 更新后，要重跑 tool loop、streaming、parser、长会话与错误恢复测试，避免静默兼容性回退。

实战：Harness 如何真正修一个 vLLM MoE 报错？

输入问题：RuntimeError: gate_up_weight.size(1) must be a multiple of 128, TP=4 可运行, TP=8 启动失败。



Harness 持久化：analysis.md · shape.json · test.log · benchmark.csv · git commit

任何一步失败，都能从 checkpoint 恢复，而不是重新开始

模型单独能做

阅读 traceback、提出 TP shard / alignment 假设、建议打印 shape。


有 Harness 后能做

真的进入仓库、插桩、申请 GPU、运行 A/B、修改代码、执行回归、生成 PR。

安全边界：读取仓库可自动；修改工作树在临时分支；GPU 任务有 lease 与超时；推送远端、合并和生产部署需要明确审批。

长任务 Harness: Planner -> Builder -> Evaluator

对完整应用、复杂重构或多轮调试，单 Agent 可能“越做越偏”。常见做法是拆成规划、执行、评估三种角色，并用结构化 artifact 交接。Anthropic 的长时程实验使用了类似模式。^[3]



上下文管理

- 代码库知识做成索引与文档地图
- 自动 compaction, 而非无限增长
- 关键事实落到文件, 不只放在对话中
- 每轮只加载当前阶段需要的上下文


任务连续性

- 用 git commit 固化可恢复状态
- 长任务定期 checkpoint
- 重启 Sandbox 后重新挂载 artifact
- 失败原因写入结构化状态, 避免重复踩坑

设计原则：先用单 Agent 建立可验证闭环；只有当失败轨迹证明“规划、执行、评审相互干扰”时，才拆成多 Agent。复杂度必须有证据。

可靠 Harness：既要能做事，也要能控制后果

Agent 的风险不仅来自模型，还来自 Harness 指令、工具权限和运行环境。一个能力很强的模型，也可能被过度开放的工具或暴露的环境拖垮。^[2]



权限

读操作、写操作、外发操作分级；危险动作需要用户确认；凭证通过代理而非直接注入。

隔离

文件白名单、默认断网、CPU/GPU/内存/进程限制、超时、一次性容器和输出大小限制。

可恢复

Harness 状态外置，Sandbox 可随时销毁；通过 snapshot、artifact 和 checkpoint 在新环境继续。^[4]

最安全的架构： Harness 持有任务状态和权限策略；Sandbox 只拿到完成当前步骤所需的最小文件与临时凭证。即使生成代码失控，影响范围仍受限。

Agent Harness 与 Eval Harness：一个负责干活，一个负责判卷

Agent Harness

让模型在一个任务中持续行动：读文件、写代码、调用工具、运行测试、修复错误。

Task



Model Loop



Artifact

Evaluation Harness

批量创建干净环境、启动 Agent、记录完整轨迹、执行 grader、汇总 pass rate、成本和延迟。

Task Suite



Trials



Metrics

以 KernelBench / CUDA BMK 为例



Eval Harness 负责整个外层实验

创建干净容器 · 固定驱动 / 依赖 · 多次 trial · 捕获崩溃 · 限时 · 记录 trace

汇总 pass@k / pass^k · speedup · cost · failure taxonomy

评分结果不仅由模型决定

Harness 限制、环境残留、grader bug、重试预算都会改变分数

这也解释了为什么 BMK 要强调 harness：同一个 kernel 或同一个模型，如果编译参数、输入生成、warmup、同步、计时、容错和 grader 不一致，结果没有可比性。

Anthropic 将 evaluation harness 定义为端到端运行评测、并发执行、记录步骤、评分和聚合结果的基础设施；并强调要用干净、隔离、稳定的环境避免评测噪声。^[1]

从 0 到 1：一个 AI Infra Coding Harness 的推荐路线

Level 0 Chat Wrapper

模型 API + system prompt + 基础日志。只能提供建议，不能验证。

Level 1 Tool Loop

增加 read_file、grep、shell、apply_patch；每轮把结构化 observation 回传模型。

Level 2 Safe Coding Agent

独立 git worktree、Sandbox、权限分级、测试门禁、超时、artifact 和 checkpoint。

Level 3 Production Harness

模型路由、上下文检索、并行 subagents、异步 GPU job、可观测、回归评测和成本治理。

适合你当前工作的 MVP

```
User task
-> Repo map / Log parser
-> DeepSeek V4 Pro or Flash
-> Tools:
    read_file / grep / git diff
    shell / pytest / build
    submit_gpu_job / collect_metrics
-> Sandbox + GPU lease
-> Test gate + benchmark gate
-> Patch report / draft PR
```

建议的终止条件

- 能稳定复现原始问题
- 根因与证据链一致
- 修复后 correctness 通过
- 关键性能指标无不可接受退化
- 新增回归测试覆盖原始失败
- 输出 patch、日志、数据与回滚方案

不要把“Agent 说已经修好”当完成。完成应由机器可验证信号定义：测试、文件状态、服务状态、性能阈值或外部系统状态。

工程 Checklist

Context

代码地图、渐进披露、token 预算、compaction、结构化记忆。

Tools

强 schema、幂等、可取消、错误分类、结果大小限制。

Safety

最小权限、worktree、断网默认、审批、密钥代理、审计。

Reliability

checkpoint、重试策略、故障恢复、超时、任务去重。

Evaluation

固定任务集、多次 trial、成本/延迟、失败分类、回归门禁。

DeepSeek Compat

reasoning_content、thinking effort、stream parser、端点兼容测试。

最后总结：Harness 是 Agent 时代的“操作系统层”

大模型决定“可能做到什么”，Harness 决定“能否稳定、安全、低成本地做到”。

1

不是简单 Prompt

Harness 是持续运行的工程系统，包含 loop、状态、工具、权限、恢复和验证。

2

Sandbox 是子集

Sandbox 负责安全执行；Harness 负责决定何时执行、传入什么、如何处理结果。

3

同模不同表现

Context、工具、parser、反馈和 grader 的差异，会显著改变 Agent 成功率。

4

DeepSeek 已进入产品层

官方招聘页当前列出 Agent Harness 团队；V4 已广泛适配外部 Coding Harness。

5

自研产品仍未完全公开

截至截止日，最终产品名、架构、下载、定价和正式发布计划仍无完整官方说明。

6

协议细节很关键

DeepSeek 工具调用中的 reasoning_content 回传，是 Harness 兼容层的典型职责。

最实用的判断法：凡是“模型本身之外、为了让它持续完成任务而存在的控制逻辑”，通常都属于 Harness——包括上下文组装、工具路由、沙箱、状态、重试、验收和审计。

基础概念与架构参考

[1] Anthropic, Demystifying evals for AI agents, 2026-01-09. 定义 Agent Harness、Evaluation Harness，并讨论隔离评测环境。
anthropic.com/engineering/demystifying-evals-for-ai-agents

[2] Anthropic, Trustworthy agents in practice, 2026-04-09. 将 Harness、Tools、Environment 作为 Agent 可信性的不同层。
anthropic.com/research/trustworthy-agents

[3] Anthropic, Harness design for long-running application development, 2026-03-24. Planner/Generator/Evaluator、结构化 artifact 与长时程任务设计。
anthropic.com/engineering/harness-design-long-running-apps

[4] OpenAI, The next evolution of the Agents SDK, 2026-04-15. Model-native Harness、Sandbox-aware orchestration、MCP、Skills、AGENTS.md、shell、apply_patch，以及 Harness 与 Compute 分离。
openai.com/index/the-next-evolution-of-the-agents-sdk

DeepSeek Harness：公开证据与资料边界

已由公开资料确认

存在 Agent Harness 团队与岗位；V4 文档化支持多种第三方 Coding Agent；工具调用协议包含 reasoning_content 状态要求。

尚未完整公开

DeepSeek 自研 Harness 的最终产品名、完整架构、下载入口、定价和正式发布路线。本文未把媒体推测写成官方事实。

DeepSeek 官方资料

- [5] DeepSeek 官方招聘页，访问于 2026-08-14。当前列出 Agent Harness 团队、Agent Infra、Code Agent 数据等岗位。
talent.deepseek.com
- [6] DeepSeek 官方 API 文档，DeepSeek-V4 预览版，2026-04-24。Agent 优化、1M 上下文、第三方 Agent 集成和内部 Agentic Coding。
api-docs.deepseek.com/zh-cn/news/news260424
- [7] DeepSeek 官方 API 文档，模型 & 价格，访问于 2026-08-14。V4 Pro/Flash 的上下文、输出、工具调用等能力。
api-docs.deepseek.com/zh-cn/quick_start/pricing
- [8] DeepSeek 官方 API 文档，思考模式，访问于 2026-08-14。thinking、effort 与 tool-call 轮次的 reasoning_content 回传规则。
api-docs.deepseek.com/zh-cn/guides/thinking_mode
- [9] DeepSeek 官方 Agent 工具接入指南：Claude Code、Pi、Reasonix、OpenCode、Copilot CLI 等，访问于 2026-08-14。
api-docs.deepseek.com/zh-cn

团队与发布动态的交叉验证

- [10] 第一财经，对标 Claude Code！DeepSeek 新业务招人了，2026-05-20。记录官方岗位描述与团队方向。
yicai.com/news/103192868.html
- [11] 每日经济新闻，DeepSeek 发布招聘信息...加码 Harness 人才布局，2026-06-26。记录扩招与团队岗位。
nbd.com.cn/articles/2026-06-26/4438435.html
- [12] Reuters, DeepSeek releases official V4 Pro model as it steps up expansion, 2026-08-13。用于确认 V4-Pro-0813 正式发布及 Agent 能力增强。
reuters.com

阅读建议：先看第 2-5 页建立概念，再看第 7-9 页理解 DeepSeek，最后用第 10、13、14 页映射到你的 AI Infra / Kernel 评测工作。