

阿里

AI Infra / 推理系统与算子优化

从语音转写到可复用的面试能力地图

覆盖模型推理、分布式缓存、算子与框架稳定性。面试会从基础计算机知识切入，再逐层追问到性能证据、系统边界和工程取舍。

整理口径	6 份多轮记录综合。内容经语义去噪、合并与重写，不保留逐字稿。
隐私处理	已剔除候选人身份、教育/履历、地点、时间、个人选择、流程沟通与全部反问；不引用原始对话。
阅读方式	先看考察地图定位重点，再按题型练习“定义 - 原理 - 方案 - 验收 - 边界”的闭环表达。

通用高分闭环

任何技术或业务题，都不要直接跳到“方案”。先固定问题边界和度量方式，再展现分析过程、取舍和验收证据。



01 考察地图

下图为材料中反复出现的主题相对覆盖度，用于决定复习优先级，而非量化评分。



面试官真正想验证什么？

面试形态

基础八股 + 项目深挖并行出现。项目题不只问“做了什么”，更会追问瓶颈如何量化、为什么该方案成立、失败路径与回归策略。

系统主线

围绕请求进入、KV Cache 生命周期、存储与传输、计算执行、调度与隔离展开。回答应明确数据所有权和跨节点代价。

Kernel 主线

Attention、融合、访存与规约是重点。面对硬件代际差异，先说数据流和瓶颈，再谈指令或库特性。

风险提示

不要把复杂度、算子边界或硬件指令混为一谈。没有 profiling 证据的“快很多”结论，不如说明测量方法与适用范围。

答题表达式

问题定义（场景、约束、指标） -> 机制拆解（数据流、资源、依赖） -> 方案选择（备选与取舍） -> 验证（正确性、性能、稳定性） -> 边界（何时无效、如何回退）。

02 高频题型与回答框架

以下不是原始问答转写，而是把多轮追问归纳为可迁移的答题骨架。练习时请替换为可公开、不可识别个人信息的案例。

题型 / 考察意图	可复用回答框架
KV Cache 如何跨实例共享？ 考察推理系统、缓存语义与成本意识。	先定义缓存粒度与 key；再说明命中、失效、一致性与冷热层；最后比较本地显存、主机内存、远端存储的延迟/带宽/容量取舍，并给出观测指标：命中率、TTFT、网络开销。
如何解释 Attention 或反向性能异常？ 考察从症状到根因的诊断链。	用 trace 先划分 kernel、同步、访存和调度时间；定位到具体算子后核查 shape、精度、确定性路径和数据访问；提出最小改动实验；以数值误差、端到端时延和稳定性共同验收。
TP/PP/EP 如何选型？ 考察并行策略是否能落到通信与负载。	从模型结构、batch/序列长度、节点拓扑和显存约束出发；分别说明切分对象、通信原语和尾部风险；再用计算/通信重叠、负载均衡与故障边界给出选择理由。
项目出现偶发卡死，排查顺序是什么？ 考察工程化 debug 能力。	先稳定复现并缩小变量：并行度、图捕获、通信优化、输入形状；用日志/trace 建时间线；构造对照关闭路径；最后落到根因修复、回归矩阵和长期监控，而不是只停留在 workaround。

项目题的五层追问



同一个项目至少准备三层深度：90 秒概览、3 分钟机制解释、10 分钟证据链。若缺少真实数据，宁可说明观测方法和待验证假设，也不要编造结论。

03 面试前 30 分钟清单

01	准备一张推理请求数据流图：请求 -> 调度 -> KV -> 执行 -> 回收。
02	每个项目按“目标 - 约束 - 证据 - 方案 - 验收 - 边界”组织。
03	复习链表、树、哈希表复杂度与 C++ 常见资源管理语义。
04	为一个性能优化准备 profiler 截图口径、正确性口径与回滚方案。

模拟练习规则

随机抽取一题，先用 20 秒复述问题与边界；再用 90 秒给出结构化答案；最后接受三轮“为什么 / 如何验证 / 何时失效”的追问。录音回听时，只检查逻辑、术语准确性和证据完整性，不保留个人信息。

本讲义只输出可复用的岗位知识与面试方法，不含个人隐私、逐字转写或反问内容。

小红书小冯别放弃