

字节跳动

AI Infra / RL 推训一致性与性能优化

从语音转写到可复用的面试能力地图

以项目真实性为第一筛选条件：要求把 RL 推训一致性、MoE 路由、GPU 性能优化和系统稳定性讲成可验证的工程闭环，并穿插算法编码。

整理口径	2 份多轮记录综合。内容经语义去噪、合并与重写，不保留逐字稿。
隐私处理	已剔除候选人身份、教育/履历、地点、时间、个人选择、流程沟通与全部反问；不引用原始对话。
阅读方式	先看考察地图定位重点，再按题型练习“定义 - 原理 - 方案 - 验收 - 边界”的闭环表达。

通用高分闭环

任何技术或业务题，都不要直接跳到“方案”。先固定问题边界和度量方式，再展现分析过程、取舍和验收证据。



01 考察地图

下图为材料中反复出现的主题相对覆盖度，用于决定复习优先级，而非量化评分。



面试官真正想验证什么？

问法特征

同一个项目会反复改写提问：先问原理，再问指标，再问异常现象，最后追问为何不是其他原因。必须避免只背项目结论。

一致性主线

重点是采样/回放、训练执行与路由决策之间的偏差如何被测量、归因和控制。任何指标都要说清分子、分母及低/高分分别代表什么。

性能主线

小 shape、decode、路由 GEMM 等场景应从工作量、访存、并行度和 launch 开销共同判断，不可只用单一吞吐结论。

工程主线

对图捕获、通信和融合算子交互引发的问题，强调复现矩阵、二分缩小与回归测试，而非只描述修了某个开关。

答题表达式

问题定义（场景、约束、指标） -> 机制拆解（数据流、资源、依赖） -> 方案选择（备选与取舍） -> 验证（正确性、性能、稳定性） -> 边界（何时无效、如何回退）。

02 高频题型与回答框架

以下不是原始问答转写，而是把多轮追问归纳为可迁移的答题骨架。练习时请替换为可公开、不可识别个人信息的案例。

题型 / 考察意图	可复用回答框架
如何讲清 MoE 路由回放的一致性？ 考察能否把论文/系统机制转为工程指标。	先界定收集点、回放点与比较对象；给出路由不一致率等指标的定义；说明偏差会如何影响训练目标；再讲检测、对齐和长轮验证，区分“相关性”与“因果修复”。
Decode 小矩阵为什么跑不满？ 考察 roofline、并行粒度与 kernel 意识。	先判断问题是算力、带宽还是 launch/同步主导；检查 tile、并发 CTA、数据布局与访存合并；分别评估融合、专用 kernel、分组执行等路径，并以端到端延迟验收。
CUDA Graph 与并行通信同时启用为何有风险？ 考察执行时序和资源生命周期。	说明 capture/replay 对 shape、指针、stream 和通信顺序的约束；通过最小配置复现并逐项放回优化；修复后覆盖不同并行度、输入与长轮运行，确保无死锁/超时。
算法题如何兼顾思路与工程质量？ 考察基本功与沟通。	先澄清输入、边界和复杂度目标；给出核心数据结构与不变量；用样例走读；最后补充时间/空间复杂度与极端 case。代码完成后主动解释测试覆盖。

项目题的五层追问



同一个项目至少准备三层深度：90 秒概览、3 分钟机制解释、10 分钟证据链。若缺少真实数据，宁可说明观测方法和待验证假设，也不要编造结论。

03 面试前 30 分钟清单

01	能在 90 秒内定义每个关键一致性指标。
02	准备一个“先禁用、后定位、再修复”的稳定性案例模板。
03	复习 MoE 的 top-k、负载均衡、EP 通信和 token dispatch。
04	手写常见哈希、双指针、栈/队列题，并练习边界说明。

模拟练习规则

随机抽取一题，先用 20 秒复述问题与边界；再用 90 秒给出结构化答案；最后接受三轮“为什么 / 如何验证 / 何时失效”的追问。录音回听时，只检查逻辑、术语准确性和证据完整性，不保留个人信息。

本讲义只输出可复用的岗位知识与面试方法，不含个人隐私、逐字转写或反问内容。

小红书小冯别放弃