

字节跳动

大模型推训优化 / Kernel 与量化

从语音转写到可复用的面试能力地图

强调把高性能优化讲透：从模型链路和硬件特性出发，解释算子、量化、图执行与并行策略如何共同影响训练/推理成本。

整理口径	1 份记录提炼。内容经语义去噪、合并与重写，不保留逐字稿。
隐私处理	已剔除候选人身份、教育/履历、地点、时间、个人选择、流程沟通与全部反问；不引用原始对话。
阅读方式	先看考察地图定位重点，再按题型练习“定义 - 原理 - 方案 - 验收 - 边界”的闭环表达。

通用高分闭环

任何技术或业务题，都不要直接跳到“方案”。先固定问题边界和度量方式，再展现分析过程、取舍和验收证据。



01 考察地图

下图为材料中反复出现的主题相对覆盖度，用于决定复习优先级，而非量化评分。



面试官真正想验证什么？

核心要求

回答要同时有“上层业务形状”和“下层执行事实”。例如，先解释 prefill/decode 差别，再推导 kernel 设计与图执行的收益边界。

量化要求

不仅问格式定义，还会问 scale、离群值、权重/激活选择、精度回退与线上监控。不能把 FP8、INT8 和权重量化简单等同。

性能要求

区分单 kernel、子图与端到端指标；明确 warmup、输入分布和硬件/软件版本，避免不可复现的绝对结论。

表达要求

项目成果必须让面试官能追问：瓶颈证据是什么、方案为何可行、收益从哪来、哪些场景不会收益。

答题表达式

问题定义（场景、约束、指标） -> 机制拆解（数据流、资源、依赖） -> 方案选择（备选与取舍） -> 验证（正确性、性能、稳定性） -> 边界（何时无效、如何回退）。

02 高频题型与回答框架

以下不是原始问答转写，而是把多轮追问归纳为可迁移的答题骨架。练习时请替换为可公开、不可识别个人信息的案例。

题型 / 考察意图	可复用回答框架
算子融合的收益与代价？ 考察是否理解 launch、访存与可维护性的平衡。	说明减少中间读写和 launch 的收益；再分析寄存器压力、occupancy、shape 泛化、调试复杂度；给出按热点和形状分桶启用、保留 fallback 的工程策略。
INT8 / FP8 量化如何落地？ 考察数值表示和工程闭环。	先区分数值范围与精度特性；定义 scale 的统计粒度与更新时机；分析离群值和累积误差；最后以离线精度、线上质量、延迟和显存共同决策。
如何评估 CUDA Graph 是否值得接入？ 考察静态图约束与收益边界。	估算 launch 占比和 shape 稳定性；说明 warmup、capture、replay 和内存地址约束；对动态输入使用分桶或 fallback；以 p50/p99 与成功率共同评估。
优化如何避免“局部更快、整体更慢”？ 考察系统视角。	建立从请求到输出的时间分解；先消除全局关键路径，再看局部热点；测量同步、通信、显存和队列效应；在真实工作负载上做 A/B 与回归。

项目题的五层追问



同一个项目至少准备三层深度：90 秒概览、3 分钟机制解释、10 分钟证据链。若缺少真实数据，宁可说明观测方法和待验证假设，也不要编造结论。

03 面试前 30 分钟清单

01	复习量化格式、scale 粒度、校准与回退机制。
02	为一个 kernel 优化准备 roofline/trace 解释。
03	能清晰对比 prefill 与 decode 的资源主导项。
04	准备 3 个常见性能指标：吞吐、TTFT、ITL/p99。

模拟练习规则

随机抽取一题，先用 20 秒复述问题与边界；再用 90 秒给出结构化答案；最后接受三轮“为什么 / 如何验证 / 何时失效”的追问。录音回听时，只检查逻辑、术语准确性和证据完整性，不保留个人信息。

本讲义只输出可复用的岗位知识与面试方法，不含个人隐私、逐字转写或反问内容。

小红书小冯别放弃