小马智行一面：性能分析与归一化编码

> 技术面复盘 · Kernel 调度 / Profiling / Roofline / CUDA 编译 / 归约。基于个人转写改写；公司与轮次沿用来源文件标注，不代表官方题库。

一、这一轮主要考什么

项目讨论会落到具体执行方式：CPU 如何 launch、GPU 上哪些工作在等待、数据在哪里、证据来自哪份报告。后半段要求从零写归一化相关 CUDA Kernel，并讨论归约和访存优化。

二、源记录中可确认的提问

1. 讲一个最熟悉的训练算子优化案例，说明原来的瓶颈。
2. 所谓串行等待发生在 host launch、device 内循环，还是 block 之间？
3. 代码中是谁检查标志、谁更新标志？数据是否需要回传 CPU？
4. Nsight Systems 与 Nsight Compute 分别看什么？你实际看过哪些指标？
5. timeline 中的空隙如何分析？怎样确认是依赖、通信、搬运还是启动问题？
6. 介绍 Roofline，怎样把报告中的指标关联到优化假设？
7. 是否写过流水线？由 AI 辅助时如何确认执行依赖和同步正确？
8. 简述 NVCC 编译流程，以及 PTX 与 SASS 的区别。
9. 根据给定形状和归一化公式写 Kernel 与 launch 方式。
10. 在基础归约实现之后，怎样考虑 warp shuffle 与向量化访存？
11. 跨 warp 的部分结果如何汇总，哪些线程负责写共享内存？

三、代码题：能确认的约束与缺失信息

口述中给出输入、输出约为 `1 × 512`，并将若干参数简化为浮点常量。现场讨论涉及均值、方差、gamma、beta、epsilon 和归约；要求写 CUDA Kernel 与启动方式，后续追问 shuffle 优化。

原始公式通过截图呈现，本次 **TXT** 没有截图或代码。转写还出现“L2 norm”等称谓，与后续均值、方差描述存在歧义。因此不能据此完整还原为某一道确定的 L2Norm 或 LayerNorm 原题，也不能声称已有原题通过代码。

练习时先主动确认：是否减均值；分母是平方和、均方根还是方差；gamma/beta 是标量还是向量；epsilon 放在哪里；输出类型和误差标准是什么。之后再实现你已明确写出的算子契约。

四、整理补充：怎样准备这一类面试

先画执行图，再解释性能

画清 host、stream、kernel、block 和数据缓冲区。用两个不同的图分别描述“host 逐次发射”与“kernel 内等待”，不要用“激活计算单元”含糊代替真正的代码路径。准备能够对应源码的伪代码，以及改动前后同口径 timeline。

做一组可解释的归约练习

从单 block 单行的清晰实现开始，分别检查索引、边界、共享内存、同步和输出；然后仅改变一种方案，比较树形归约与 warp 级归约。补充非整 warp 宽度、极小值、全相同值和不同输入长度等用例。

讲优化时同时说明前提：向量化的对齐条件、尾部元素处理、跨 warp 汇总方式、寄存器占用，以及怎样测量性能。不要把记住一个 intrinsic 名称当成理解完整归约。

五、模拟追问与来源

- 为什么一个利用率数字不足以判定瓶颈？还需要什么对照或指标？
- 如果优化方案更快但改变了结果，先看归约顺序、类型转换还是索引？怎样安排检查？
- 能否指出一条源码语句，对应性能报告中的一个现象？

来源：`小马智行一面_转写_2.txt`。已删去个人履历、内部团队和流程信息；不保留个人项目收益数字。技术基础校准见本目录《阅读说明与基础校准》。