AI Infra 一面：混合精度与 Softmax

> 技术面复盘 · 训练与推理指标 / 数值类型 / MoE / 路由一致性 / Softmax 编码。来源文件标注“禾赛”，但对话出现其他公司业务称谓，公司归属待核对；本篇按通用 AI Infra 题型提供。

一、这一轮主要考什么

前半段检查项目结果能否联系到训练效率、精度和模型结构；后半段要求解释并实现 Softmax。主题横跨低层 Kernel 和上层框架，表达时需要区分知道、亲自实现和仅听过的内容。

二、源记录中可确认的提问

1. 训练反向优化对完整流程的影响是什么，前向是否变化？
2. 计算与通信重叠时遇到过哪些问题？如何说明变化来自哪里？
3. 介绍一个推理优化，其输入、路径和收益如何测量？
4. FP32、FP16、BF16 等类型有哪些差异，如何理解动态范围和精度？
5. 混合精度里哪些环节用什么类型，为什么要这样组织？
6. 算子融合与中间类型转换有什么关系，怎样确认误差来源？
7. 介绍 MoE 的结构，区分总参数量、激活参数量和实际计算。
8. 相同输入下推理与训练的 Router 分数或 Top-k 为什么可能不同？
9. 为什么采用路由回放，而不是直接统一两侧实现？方案边界是什么？
10. 解释 Softmax，再尝试用 Python/张量操作实现。
11. TP 的具体含义是什么？怎样描述张量切分和计算协作？
12. 对 MoE 专家负载不均衡了解多少，有哪些可以进一步验证的方向？

三、代码题：Softmax 练习范围

转写能确认要求说明 Softmax 并现场实现，讨论过 Python/张量接口；没有保存完整题面、测试用例或最终代码。不能据此宣称存在一份通过现场测试的原题答案。

练习前先约定输入维度、规约轴、dtype、输出形状，以及遇到特殊值的处理方式。然后从定义检查指数、求和和归一化步骤；再用小规模输入、较大幅值输入与不同维度验证结果。是否需要手写 CUDA 或允许调用现成接口，应重新明确，不能从记录猜测。

四、整理补充：数值与系统的准备路径

做一张类型表，而非背模糊印象

分别列指数位、有效精度、可表达范围、存储、计算和累加类型。使用公开文档核对后，再说明为什么某个环节采用某种类型。原记录中 BF16 与 FP16 的特点有混淆，不能直接作为答案。

用对照定位误差，而非只归因于转换

先用高精度参考检查算子数学语义，再分别改变输入类型、累加类型和输出转换。比较融合前后时，保证计算定义一致；不要预设“融合就一定改善精度”或“训练结果不同都是归约造成”。

路由问题先描述差异，再讨论补救

分别记录输入是否一致、权重版本、实现和精度、Router 分数、Top-k 专家及重算行为。路由回放、确定性实现和数值对齐各自解决什么，需要结合系统目标说明；不能将它们混为一个操作。

五、来源与核对事项

来源：`禾赛科技1面_转写.txt`。已删除身份、实习公司、个人模型规模、地点和流程。后段出现其他公司称谓，本次保留来源标注以便回查，但不将其包装为已确认的某公司官方面试题。公司归属确认前，上架文案宜归入“补充 AI Infra 一面”。基础校准见本目录《阅读说明与基础校准》。