

百度

AI Infra / 推理与 RL 系统

从语音转写到可复用的面试能力地图

聚焦推理性能、RL 支撑和模型上线三条主线。项目追问以推训链路和 MoE 并行作为抓手，测试候选人能否把底层机制与服务目标连接起来。

整理口径	1 份记录提炼。内容经语义去噪、合并与重写，不保留逐字稿。
隐私处理	已剔除候选人身份、教育/履历、地点、时间、个人选择、流程沟通与全部反问；不引用原始对话。
阅读方式	先看考察地图定位重点，再按题型练习“定义 - 原理 - 方案 - 验收 - 边界”的闭环表达。

通用高分闭环

任何技术或业务题，都不要直接跳到“方案”。先固定问题边界和度量方式，再展现分析过程、取舍和验收证据。



01 考察地图

下图为材料中反复出现的主题相对覆盖度，用于决定复习优先级，而非量化评分。



面试官真正想验证什么？

岗位视角

不只看单算子速度，更关心推理服务如何稳定承载 RL、模型试运行和上线需求。回答要带上服务等级、资源效率与可观测性。

链路视角

把 rollout、请求调度、KV Cache、执行器、采样/回传视作一条数据链路，明确哪个阶段最影响时延或一致性。

并行视角

MoE 不只等于专家并行：还涉及 token 路由、A2A、容量、负载与主干模型并行的协同。

复盘视角

面对系统不稳定，应表现出“先止血、再归因、后固化”的方法论，且每一步有数据支撑。

答题表达式

问题定义（场景、约束、指标） -> 机制拆解（数据流、资源、依赖） -> 方案选择（备选与取舍） -> 验证（正确性、性能、稳定性） -> 边界（何时无效、如何回退）。

02 高频题型与回答框架

以下不是原始问答转写，而是把多轮追问归纳为可迁移的答题骨架。练习时请替换为可公开、不可识别个人信息的案例。

题型 / 考察意图	可复用回答框架
推理服务如何支撑 RL 工作负载？ 考察服务与训练耦合的认识。	说明 rollout 对吞吐、时延、采样一致性和弹性的要求；拆解模型服务、缓存、批处理与结果回传；设计隔离、限流和指标，避免训练峰值拖垮在线链路。
MoE 的 EP 通信瓶颈如何判断？ 考察通信与负载分析能力。	先看 token 分布、专家容量和 A2A 时间；区分网络带宽、排队和失衡；再评估分组、重排、通信计算重叠与负载均衡策略，并验证长尾。
如何介绍一次推训一致性优化？ 考察是否会把复杂项目讲成闭环。	以“偏差定义 - 基线复现 - 观测指标 - 根因假设 - 修复设计 - 跨规模验证”组织，明确保留哪些不确定性和失败实验。
怎样定义上线前性能验收？ 考察工程质量意识。	列出固定工作负载、版本和硬件；同时检查吞吐、延迟分位、显存、错误率与质量指标；建立回归阈值和降级策略。

项目题的五层追问



同一个项目至少准备三层深度：90 秒概览、3 分钟机制解释、10 分钟证据链。若缺少真实数据，宁可说明观测方法和待验证假设，也不要编造结论。

03 面试前 30 分钟清单

01	画出 rollout 到训练回传的闭环。
02	掌握 KV Cache、批处理、调度和 preemption 的基本语义。
03	复习 EP/A2A 与负载均衡的常见指标。
04	将所有优化收益改写为“场景 + 指标 + 对照 + 验收”。

模拟练习规则

随机抽取一题，先用 20 秒复述问题与边界；再用 90 秒给出结构化答案；最后接受三轮“为什么 / 如何验证 / 何时失效”的追问。录音回听时，只检查逻辑、术语准确性和证据完整性，不保留个人信息。

本讲义只输出可复用的岗位知识与面试方法，不含个人隐私、逐字转写或反问内容。

小红书小冯别放弃