

MiniMax

AI Infra / 推理优化与框架稳定性

从语音转写到可复用的面试能力地图

从硬件代际、Attention 演进和 RL 场景稳定性切入，重视候选人对“性能、精度、并行、框架行为”之间耦合关系的理解。

整理口径	1 份记录提炼。内容经语义去噪、合并与重写，不保留逐字稿。
隐私处理	已剔除候选人身份、教育/履历、地点、时间、个人选择、流程沟通与全部反问；不引用原始对话。
阅读方式	先看考察地图定位重点，再按题型练习“定义 - 原理 - 方案 - 验收 - 边界”的闭环表达。


通用高分闭环

任何技术或业务题，都不要直接跳到“方案”。先固定问题边界和度量方式，再展现分析过程、取舍和验收证据。



01 考察地图

下图为材料中反复出现的主题的相对覆盖度，用于决定复习优先级，而非量化评分。



面试官真正想验证什么？

技术风格

题目常把 Attention 算法变化与 GPU 新特性放在一起，重点不在背名词，而在说明数据如何移动、哪个阶段变成新瓶颈。

框架风格

对 CUDA Graph、通信和融合算子的故障，会追问触发条件、排查实验和最终修复验证。

并行风格

TP/PP/EP 的配置不是孤立选择；需要结合模型、序列、专家路由、网络拓扑和显存压力讨论。

表达边界

硬件指令和库实现随版本变化。面试中先讲稳定设计逻辑，再补“取决于具体架构/软件版本”的条件。

答题表达式

问题定义（场景、约束、指标） -> 机制拆解（数据流、资源、依赖） -> 方案选择（备选与取舍） -> 验证（正确性、性能、稳定性） -> 边界（何时无效、如何回退）。

02 高频题型与回答框架

以下不是原始问答转写，而是把多轮追问归纳为可迁移的答题骨架。练习时请替换为可公开、不可识别个人信息的案例。

题型 / 考察意图	可复用回答框架
FlashAttention 演进解决了什么？ 考察 IO-aware 思维。	从避免大中间矩阵落显存开始；说明 tile、在线 softmax、共享内存/寄存器与流水的作用；再解释不同硬件代际会改变最佳 tile、数据通路和可用指令。
算力提升后为何仍可能变慢？ 考察瓶颈迁移。	用 roofline 判断计算、显存、通信或标量/归约路径；指出矩阵单元加速可能暴露 softmax、归约、调度等尾部；基于 trace 选择下一步优化而非假设。
MoE 中 TP 与 EP 如何配合？ 考察多维并行的整体性。	分别说明张量切分和专家分片的对象、通信；分析 token 分配、A2A、专家容量与网络层级；用有效吞吐和长尾而不是理论 FLOPS 选配置。
框架 hang 的定位流程？ 考察稳定性工程。	先锁定最小触发组合；检查 capture/replay、stream、collective 与 shape；关闭可疑优化做对照；修复后跑不同并行度/随机输入/长轮回归，并保留监控。

项目题的五层追问



同一个项目至少准备三层深度：90 秒概览、3 分钟机制解释、10 分钟证据链。若缺少真实数据，宁可说明观测方法和待验证假设，也不要编造结论。

03 面试前 30 分钟清单

01	能用数据流解释 Attention，而不是只列特性名称。
02	准备一页硬件代际迁移时的检查清单。
03	复习 TP/PP/EP 的对象、通信和失衡来源。
04	建立性能问题的“测量 - 假设 - 实验 - 验收”日志。

模拟练习规则

随机抽取一题，先用 20 秒复述问题与边界；再用 90 秒给出结构化答案；最后接受三轮“为什么 / 如何验证 / 何时失效”的追问。录音回听时，只检查逻辑、术语准确性和证据完整性，不保留个人信息。

本讲义只输出可复用的岗位知识与面试方法，不含个人隐私、逐字转写或反问内容。

小红书小冯别放弃