

曦望

AI 加速器 / 算子与推训优化

从语音转写到可复用的面试能力地图

面试把 AI 加速器、算子实现、推训优化和硬件基础串联，重视候选人能否从软硬件协同视角解释性能路径。

整理口径	1 份记录提炼。内容经语义去噪、合并与重写，不保留逐字稿。
隐私处理	已剔除候选人身份、教育/履历、地点、时间、个人选择、流程沟通与全部反问；不引用原始对话。
阅读方式	先看考察地图定位重点，再按题型练习“定义 - 原理 - 方案 - 验收 - 边界”的闭环表达。

通用高分闭环

任何技术或业务题，都不要直接跳到“方案”。先固定问题边界和度量方式，再展现分析过程、取舍和验收证据。



01 考察地图

下图为材料中反复出现的主题相对覆盖度，用于决定复习优先级，而非量化评分。



面试官真正想验证什么？

能力交叉

既会问加速器/硬件基础，也会追问训练、推理和 RL 场景中的软件优化。关键是把硬件资源映射到实际执行行为。

算子主线

Kernel、融合、布局与调度题出现频繁。回答应先描述工作负载，再描述瓶颈和硬件资源，而不是从 API 名称开始。

系统主线

在大规模推理里，单卡优化仍需放在并行、通信和端到端吞吐中判断。

低精度主线

FP8 等话题要关注格式、scale、累加精度、数据分布和框架支持的完整闭环。

答题表达式

问题定义（场景、约束、指标） -> 机制拆解（数据流、资源、依赖） -> 方案选择（备选与取舍） -> 验证（正确性、性能、稳定性） -> 边界（何时无效、如何回退）。

02 高频题型与回答框架

以下不是原始问答转写，而是把多轮追问归纳为可迁移的答题骨架。练习时请替换为可公开、不可识别个人信息的案例。

题型 / 考察意图	可复用回答框架
硬件背景如何服务算子优化？ 考察能否把知识转为方法。	从计算单元、片上存储、带宽与同步模型出发；将其映射到 tile、layout、流水和规约设计；用 profile 验证瓶颈是否真的对应假设。
训练和推理的 kernel 设计差异？ 考察工作负载意识。	比较 batch、序列、形状稳定性、算子比例和延迟目标；指出训练偏吞吐/反向与通信，推理尤其 decode 关注小 batch、KV 与尾延迟。
FP8 落地时要检查什么？ 考察精度工程。	说明格式选择、scale 策略、amax/离群值处理、累加精度和 fallback；以收敛/质量、吞吐、显存三类指标共同验收。
如何解释一次融合优化？ 考察因果链。	按 baseline -> 瓶颈证据 -> 融合边界 -> 数据复用/访存减少 -> 资源副作用 -> 正确性和端到端结果回答，并说明未覆盖 shape 的退化策略。

项目题的五层追问



同一个项目至少准备三层深度：90 秒概览、3 分钟机制解释、10 分钟证据链。若缺少真实数据，宁可说明观测方法和待验证假设，也不要编造结论。

03 面试前 30 分钟清单

01	用一张图把硬件资源映射到 kernel 设计。
02	能对比训练/prefill/decode 的优化重点。
03	复习精度、scale、累加与回退的术语。
04	准备针对不同 shape 的性能与正确性回归表。

模拟练习规则

随机抽取一题，先用 20 秒复述问题与边界；再用 90 秒给出结构化答案；最后接受三轮“为什么 / 如何验证 / 何时失效”的追问。录音回听时，只检查逻辑、术语准确性和证据完整性，不保留个人信息。

本讲义只输出可复用的岗位知识与面试方法，不含个人隐私、逐字转写或反问内容。

小红书小冯别放弃