OPPO 高性能计算与端侧部署

> 技术面复盘 · 多卡稳定性 / 确定性 / GPU 基础 / 端侧迁移。根据个人语音转写提炼，问题均已改写；公司与轮次沿用来源文件标注，不代表官方题库。

一、这一轮主要考什么

主线是把服务器端算子优化经历讲成可验证的工程过程，再判断这些能力能否迁移到资源受限的端侧设备。面试会连续追问根因、方案边界、已有社区方案和本人实际贡献。

二、源记录中可确认的提问

1. 多卡通信等待与浮点标志值有什么关系？为何考虑用位级判断？
2. 使用的是自研通信机制，还是开源库？问题属于通用缺陷，还是特定配置才触发？
3. 推理与训练的 Top-k 专家选择为什么可能不一致？“非确定性归约”具体指什么？
4. 问题影响有多大？已有通用方案为什么不能直接满足需求？
5. 新方案与原有确定性方案相比，付出了什么时间、空间或工程成本？
6. 修复是否获得上游确认？怎样区分内部修复、已提 issue 与已合入贡献？
7. 服务器 GPU 上的排障和性能经验，迁移到手机端时哪些仍然有效？
8. 将约 4B 规模的模型部署到手机端，需要优先考虑哪些资源约束？
9. 在成熟计算库与 AI 编程工具已存在的情况下，开发者如何体现算子优化价值？
10. 如何衡量空间换时间是否值得，怎样证明方案适合实际负载？
11. 介绍线程、warp、block、SM 与存储层次，解释 shared memory 的使用边界。
12. 什么是 shared memory bank conflict？你会怎样构造验证实验？

三、整理补充：回答准备提纲

稳定性案例用“证据链”组织

先画等待方和写入方，再写出状态何时变化、用什么类型存储、由谁读取。将“现场出现超时”与“根因已经定位”分开陈述。准备开关对照、卡数对照、最小复现和修复后回归四类材料，不依赖一句“改完没再挂”结束说明。

转写中的位宽、负零与 FTZ 描述有混用，不能照抄成标准解释。复习时应回到对应版本源码，明确载荷类型、比较类型与实际位模式；没有代码证据时，保留为待核对项。

从服务端迁移到端侧

可用一张预算表组织思路：权重和运行时内存、KV Cache 与临时张量、量化与精度、算子支持与回退、延迟、功耗和持续运行温度。分别列“已知约束”“需要查设备文档的约束”“准备实际测量的指标”。不要只用模型参数量判断能否部署。

算子优化的个人贡献

按“识别异常 → 构造复现 → 提出假设 → 改动实现 → 正确性与性能验证 → 交付回归”说明本人动作。AI 可以参与生成代码和分析报告，但需要能够解释关键分支、失败方案和最终取舍。

四、模拟追问与练习

- 如果异常只在某种数据分布中出现，如何避免复现输入遗漏关键条件？
- 如果某方案单算子更快，却多占显存，如何比较整机能容纳的并发请求数？
- 给一个陌生移动端加速器，先读哪些接口、算子和内存文档？
- 画出 block 内数据复用范围，并说明跨 block 协作准备使用哪种机制。

练习产出：一张通信状态图、一页端侧资源预算、一次有基线和误差检查的简化算子实验。

五、复盘提醒与来源

不要把共享内存表述成任意 block 都可直接共享；不要把社区已有方案说成本人原创；不要把一次特定环境的收益写成普遍加速结论。基础概念校准见本目录《阅读说明与基础校准》。

来源：`OPPO 高性能计算_转写.txt`。已移除身份、学历、实习雇主、个人时间地点、流程沟通及原始问答措辞；未保留个人项目的性能数字。

OPPO HR：项目表达与职业选择

> HR 面复盘 · 工程价值 / 协作 / 压力处理 / 自我认知。根据个人转写改写为准备题纲，已删除薪酬、Offer 进度、家庭、关系、地点等个人信息，不提供他人的回答模板。

一、这一轮主要考什么

技术细节需要转化成非同岗位的人也能理解的价值：为什么做、难在哪里、本人具体做了什么、怎样与相关方协作。还会观察职业选择是否连贯、能否处理压力与反馈。

二、源记录中可确认的提问

1. 选一个最有代表性的项目，用非专业语言说明背景和价值。
2. 这个项目最大的挑战是什么？复现、定位和实施分别难在哪里？
3. 参与者分别承担什么工作？本人不可替代的贡献是什么？
4. 导师或协作方如何评价这项工作？有哪些具体行为可以佐证？
5. 选择实习或工作机会时，最看重哪些因素？
6. 举例说明一次比较艰难的决定，当时比较了哪些选择？
7. 面对同时到来的多个紧急任务，怎样安排优先级并沟通？
8. 如何解释一段经历结束及下一步选择之间的关系？
9. 如何设定阶段目标，怎样判断目标已经达成？
10. 收到负面评价时如何处理，怎样区分可行动反馈和情绪性评价？
11. 最近学习了什么？新技术是否改变了你的职业判断？
12. 如何评价自己的优势与差距？结论依据是什么？

三、整理补充：准备自己的材料

项目故事压缩成两种版本

准备 90 秒版本和 3 分钟版本。前者用一句话说背景，一句话说关键困难，两句话说本人行动，最后说明结果与局限。后者增加一次失败尝试、一次协作分歧和对应证据。面向 HR 时可用“减少等待”“缩短任务完成时间”“避免重复失败”等语言解释意义，再按追问补技术细节。

不要把团队成绩全部归于自己。把主导、协作、参考开源实现、由他人完成的整网验证分别说明；引用评价时使用可复核的交付结果，不编造称赞。

高压协作用具体动作说明

准备一次“需求冲突”的案例：列清任务、影响、时限和依赖，给负责人可选择的排序方案；明确调整了什么、通知了谁、最终按什么标准交付。只说“加班完成”难以说明计划与沟通能力。

职业选择写出自己的标准

把技术方向、职责范围、学习机会、协作方式和生活安排分别写成决策因素，说明哪些是长期标准、哪些允许权衡。回答只使用自己的真实经历；不要背诵来源记录中他人的选择或观点。

四、模拟追问与自查

- 如果项目结果没有预期好，是否仍能说明自己学到了什么、下次怎样改？
- 如果被指出技术深度不足，准备补哪项能力，用什么产出验证？
- 如果一个任务很紧急，却缺少数据或权限，如何提出可执行的替代方案？
- “学习能力强”“靠谱”“执行快”分别能对应哪件可复核的小事？

自查：故事中是否有明确的本人动作；是否承认信息边界；是否能给出未解决的问题；是否避免用负面评价代替对上一段经历的客观说明。

五、来源与使用范围

来源：`oppp HR 面_转写.txt`。公司标签按来源文件使用。本篇只保留可泛化的面试问题；原记录中的薪资数字、其他公司 Offer、评价对象、家庭与关系信息、入离职时间、地点和流程均未收录。文中的表达方法为整理补充，不是原面试中的标准答案。