小马智行一面：性能分析与归一化编码

> 技术面复盘 · Kernel 调度 / Profiling / Roofline / CUDA 编译 / 归约。基于个人转写改写；公司与轮次沿用来源文件标注，不代表官方题库。

一、这一轮主要考什么

项目讨论会落到具体执行方式：CPU 如何 launch、GPU 上哪些工作在等待、数据在哪里、证据来自哪份报告。后半段要求从零写归一化相关 CUDA Kernel，并讨论归约和访存优化。

二、源记录中可确认的提问

1. 讲一个最熟悉的训练算子优化案例，说明原来的瓶颈。
2. 所谓串行等待发生在 host launch、device 内循环，还是 block 之间？
3. 代码中是谁检查标志、谁更新标志？数据是否需要回传 CPU？
4. Nsight Systems 与 Nsight Compute 分别看什么？你实际看过哪些指标？
5. timeline 中的空隙如何分析？怎样确认是依赖、通信、搬运还是启动问题？
6. 介绍 Roofline，怎样把报告中的指标关联到优化假设？
7. 是否写过流水线？由 AI 辅助时如何确认执行依赖和同步正确？
8. 简述 NVCC 编译流程，以及 PTX 与 SASS 的区别。
9. 根据给定形状和归一化公式写 Kernel 与 launch 方式。
10. 在基础归约实现之后，怎样考虑 warp shuffle 与向量化访存？
11. 跨 warp 的部分结果如何汇总，哪些线程负责写共享内存？

三、代码题：能确认的约束与缺失信息

口述中给出输入、输出约为 `1 × 512`，并将若干参数简化为浮点常量。现场讨论涉及均值、方差、gamma、beta、epsilon 和归约；要求写 CUDA Kernel 与启动方式，后续追问 shuffle 优化。

原始公式通过截图呈现，本次 **TXT** 没有截图或代码。转写还出现“L2 norm”等称谓，与后续均值、方差描述存在歧义。因此不能据此完整还原为某一道确定的 L2Norm 或 LayerNorm 原题，也不能声称已有原题通过代码。

练习时先主动确认：是否减均值；分母是平方和、均方根还是方差；gamma/beta 是标量还是向量；epsilon 放在哪里；输出类型和误差标准是什么。之后再实现你已明确写出的算子契约。

四、整理补充：怎样准备这一类面试

先画执行图，再解释性能

画清 host、stream、kernel、block 和数据缓冲区。用两个不同的图分别描述“host 逐次发射”与“kernel 内等待”，不要用“激活计算单元”含糊代替真正的代码路径。准备能够对应源码的伪代码，以及改动前后同口径 timeline。

做一组可解释的归约练习

从单 block 单行的清晰实现开始，分别检查索引、边界、共享内存、同步和输出；然后仅改变一种方案，比较树形归约与 warp 级归约。补充非整 warp 宽度、极小值、全相同值和不同输入长度等用例。

讲优化时同时说明前提：向量化的对齐条件、尾部元素处理、跨 warp 汇总方式、寄存器占用，以及怎样测量性能。不要把记住一个 intrinsic 名称当成理解完整归约。

五、模拟追问与来源

- 为什么一个利用率数字不足以判定瓶颈？还需要什么对照或指标？
- 如果优化方案更快但改变了结果，先看归约顺序、类型转换还是索引？怎样安排检查？
- 能否指出一条源码语句，对应性能报告中的一个现象？

来源：`小马智行一面_转写_2.txt`。已删去个人履历、内部团队和流程信息；不保留个人项目收益数字。技术基础校准见本目录《阅读说明与基础校准》。

小马智行二面：算子工程与滑动窗口

> 技术面复盘 · 性能排查 / AI 辅助开发 / 迁移适配 / 双指针。基于个人转写提炼，问题已改写；公司与轮次沿用来源文件标注。

一、这一轮主要考什么

前半段从项目流程追问技术真实性，包括生产问题怎样缩小成本地用例、计算与通信如何相互影响、AI 生成的改动怎样审阅。后半段是带在线状态约束的区间问题。

二、源记录中可确认的提问

1. 怎样通过 profiling 发现训练中的异常算子？如何构建最小复现？
2. 如何从调用链定位到具体实现，而非停留在“某层比较慢”？
3. 计算算子为何会在部分执行中出现长尾？和通信重叠有什么关系？
4. 如何安排计算与通信资源，依据什么指标选择配置？
5. Agent 生成一个很大的 PR 时，怎样阅读、缩小改动并确认质量？
6. 推理 Router GEMM 的输入、执行路径和原实现的问题是什么？
7. 单算子收益与端到端收益有何区别，怎样说明差异？
8. 偶发 hang 如何复现和归因？最终修复的边界是什么？
9. 迁移到另一种 GPU 生态时，如何选择已有库实现和自写算子？
10. 类型注册缺失、错误分派和长跑失败之间怎样建立证据链？

三、代码题：在线区间与累计上传量

源记录能确认：按时间片记录在线状态和累计上传量；累计上传量单调不减；目标区间需满足全程在线，以及上传量、持续时间的阈值条件；面试要求讨论线性扫描思路。现场曾围绕双指针、断线后重置、输出区间和下标展开调试。

完整原题未随 **TXT** 提供。 阈值的严格/非严格比较、端点定义、返回一个区间还是全部区间等细节不够清晰。若要求输出所有区间，复杂度还需要计入结果规模；不能仅凭口述断言某个实现严格为 O(n)。

练习时先补齐契约：`upload[j] - upload[i]` 对应哪些时间片、持续长度如何计算、端点能否相等、断线点是否计入区间、结果是否允许重复。然后用小规模暴力枚举作为对照，再验证你的扫描方案。

四、整理补充：准备一个可以复查的工程故事

把性能异常拆成可检验假设

准备“同输入独立计算”“加入通信”“改变资源配置”几组对照，记录总完成时间、算子时间分布与通信重叠。原记录中的具体配置和收益属于个人口述，本篇不把它们作为通用推荐参数。

审阅 AI 生成的改动

要求每个关键分支都能回答：解决什么输入、为何要新增、失败时如何回退、是否有绕过一般逻辑的特判。先形成小而可解释的改动，再比较正确性和性能；对已有库的复用和自己写的实现分别归因。

区间题的边界清单

- 无在线片段、全部在线、连续断线、只在末尾满足条件。
- 累计上传量平台期、恰好达到阈值、持续时间恰好达到阈值。
- 下标和指针初始化；循环边界；差值是否溢出。
- 多个合法区间与输出规模；用暴力对照发现遗漏或重复。

五、来源与使用范围

来源：`小马智行2面_转写.txt`。删除自我介绍、雇主、个人时间地点、流程及反问。文中工程准备方法和边界清单为整理补充，代码题部分是可确认信息摘录，不是完整原题或官方答案。

小马智行三面：性能证据与工程闭环

> 技术深挖复盘 · 并行度 / 输入分布 / 正确性验证 / 偶发故障。源记录问题已改写，公司与轮次沿用文件标注，不代表官方题库。

一、这一轮主要考什么

这一轮不断将抽象描述压到可核实的事实：到底切了哪一维、为什么选这个阈值、实际走哪条后端、数据从哪里来、收益覆盖多少任务。仅记结论和术语很难应对连续追问。

二、源记录中可确认的提问

1. 训练反向算子的原始调度具体如何阻塞并行？改动了哪些逻辑？
2. 分块数量如何选择？给定输入时实际会开多少并行工作？
3. 为什么采用某个切分阈值？有实验依据，还是仅便于理解？
4. 怎样判断并行度足够，而不是只观察一个 SM 利用率数字？
5. 测试数据来自真实输入、dump 还是构造？它们各有哪些限制？
6. 如何解释“同样数据、不同 shape”？测试维度是否定义清楚？
7. 单算子、单层、整模型收益分别如何测量和统计？
8. 多后端与 fallback 各解决什么问题？真实请求分别走哪条路径？
9. 新 Kernel 的切分与调度怎样分别解决 padding 和确定性问题？
10. 开发阶段怎样保证正确？如何与发版前的整网评测衔接？
11. 能否复用一套通用正确性测试，而非每个算子重新写一套？
12. 偶发 hang 为什么归因到某条路径？如何逐步缩小实验范围？
13. 修复的影响面怎样量化，除了“没有再次失败”还能提供什么？
14. AI 写出的代码，开发者是否理解其组织方式和方案取舍？

三、整理补充：准备四份证据

证据一：输入与执行路径表

逐项记录 shape、dtype、layout、硬件、版本、开关、选中后端和 fallback 原因。说明阈值来自什么测试；对没有测过的输入明确留白。不要用一种 shape 的结果概括所有负载。

证据二：正确性矩阵

明确比较对象与误差标准，区分数学定义、容差一致、同实现重复运行一致和跨实现逐位一致。列出随机、极值、边界尺寸和不同布局的测试。原记录中的“都是确定性所以应该 bitwise”不能直接作为正确性证明。

证据三：性能统计与消融

每个改动独立记录基线、样本数、预热、计时范围和统计量，再记录组合效果。整网收益与单算子收益分别计算；还需要核对目标算子在总时长中所占比例，以及优化是否改变了其他部分。

证据四：故障影响与回归

列出触发条件、复现概率、任务损失、修复覆盖的版本与配置、仍未覆盖的情况。使用对照实验区分“同一症状”与“同一根因”。线上影响、内部监控和团队细节不应复制进公开面经，可用脱敏结构说明方法。

四、面试前的模拟检查

- 用一张图解释矩阵切分，标出实际代码中的循环和归约维度。
- 任选一个性能数字，回查它对应的实验和原始单位。
- 任选一条后端路径，说明触发条件、失败方式和回归用例。
- 对一个失败方案说明为什么没选它，避免只说“试过，效果不好”。

五、来源与范围

来源：`小马智行3面_转写.txt`。已移除个人身份、内部模型信息、职级体系、薪酬、团队流程与原始对话。原记录的收益口径存在反复，本篇只保留测量问题，不给出未经核实的加速结论。以上证据模板为整理补充。