INTERVIEW FIELD NOTES

曦望

AI 加速器 / 算子与推训优化

从语音转写到可复用的面试能力地图

面试把 AI 加速器、算子实现、推训优化和硬件基础串联，重视候选人能否从软硬件协同视角解释性能路径。

整理口径	1 份记录提炼。内容经语义去噪、合并与重写，不保留逐字稿。
隐私处理	已剔除候选人身份、教育/履历、地点、时间、个人选择、流程沟通与全部反问；不引用原始对话。
阅读方式	先看考察地图定位重点，再按题型练习“定义 - 原理 - 方案 - 验收 - 边界”的闭环表达。

通用高分闭环

任何技术或业务题，都不要直接跳到“方案”。先固定问题边界和度量方式，再展现分析过程、取舍和验收证据。

算子语义 › **编译/运行时** › **硬件执行** › **系统并行** › **业务指标**

小红书小鸿别贩卷

01 考察地图

下图为材料中反复出现的主题的相对覆盖度，用于决定复习优先级，而非量化评分。



面试官真正想验证什么？

能力交叉

既会问加速器/硬件基础，也会追问训练、推理和 RL 场景中的软件优化。关键是把硬件资源映射到实际执行行为。

算子主线

Kernel、融合、布局与调度题出现频繁。回答应先描述工作负载，再描述瓶颈和硬件资源，而不是从 API 名称开始。

系统主线

在大规模推训里，单卡优化仍需放在并行、通信和端到端吞吐中判断。

低精度主线

FP8 等话题要关注格式、scale、累加精度、数据分布和框架支持的完整闭环。

小红书小鸡别放弃

答题表达式

> 问题定义（场景、约束、指标） -> 机制拆解（数据流、资源、依赖） -> 方案选择（备选与取舍） -> 验证（正确性、性能、稳定性） -> 边界（何时无效、如何回退）。

02 高频题型与回答框架

以下不是原始问答转写，而是把多轮追问归纳为可迁移的答题骨架。练习时请替换为可公开、不可识别个人信息的案例。

题型 / 考察意图	可复用回答框架
硬件背景如何服务算子优化? 考察能否把知识转为方法。	从计算单元、片上存储、带宽与同步模型出发；将其映射到 tile、layout、流水和规约设计；用 profile 验证瓶颈是否真的对应假设。
训练和推理的 kernel 设计差异? 考察工作负载意识。	比较 batch、序列、形状稳定性、算子比例和延迟目标；指出训练偏吞吐/反向与通信，推理尤其 decode 关注小 batch、KV 与尾延迟。
FP8 落地时要检查什么? 考察精度工程。	说明格式选择、scale 策略、amax/离群值处理、累加精度和 fallback；以收敛/质量、吞吐、显存三类指标共同验收。
如何解释一次融合优化? 考察因果链。	按 baseline -> 瓶颈证据 -> 融合边界 -> 数据复用/访存减少 -> 资源副作用 -> 正确性和端到端结果回答，并说明未覆盖 shape 的退化策略。

项目题的五层追问

背景与目标 › 瓶颈证据 › 方案与取舍 › 结果与验证 › 复盘与边界

同一个项目至少准备三层深度：90 秒概览、3 分钟机制解释、10 分钟证据链。若缺少真实数据，宁可说明观测方法和待验证假设，也不要编造结论。

小红书小鸿别放弃

03 面试前 30 分钟清单

01	用一张图把硬件资源映射到 kernel 设计。
02	能对比训练/prefill/decode 的优化重点。
03	复习精度、scale、累加与回退的术语。
04	准备针对不同 shape 的性能与正确性回归表。

模拟练习规则

随机抽取一题，先用 20 秒复述问题与边界；再用 90 秒给出结构化答案；最后接受三轮“为什么 / 如何验证 / 何时失效”的追问。录音回听时，只检查逻辑、术语准确性和证据完整性，不保留个人信息。

本讲义只输出可复用的岗位知识与面试方法，不含个人隐私、逐字转写或反问内容。

小红书小鸿别放弃

曦望二面：推理引擎与整网优化

> 技术面复盘 · 插件适配 / TP 与 PP / GEMM 分块 / Attention / KV Cache / 投机解码。问题依据转写改写，公司与轮次沿用来源文件标注。

一、这一轮主要考什么

这一轮强调推理引擎的系统视角。面试不满足于“写过一个更快的 Kernel”，还要求说明并行方式、通信、调度、缓存和模型结构如何共同影响实际服务性能。

二、源记录中可确认的提问

1. 新硬件接入 vLLM 插件体系，需要替换或扩展哪些能力？
2. 相同卡数下，TP 与 TP+PP 的性能差异应怎样分析？
3. TP、PP 和 EP 各涉及哪些通信行为，不能混用哪些通信库概念？
4. batch 增大后，GEMM 反而更快，怎样继续追问 Kernel 层根因？
5. 分块策略为什么会造成不同 shape 下的性能差异？
6. FlashAttention 的主要优化是什么？与计算量、数据搬运分别有什么关系？
7. Online Softmax 如何逐块更新，为什么能够保持数学等价？
8. 对 GQA、MLA 和其他注意力变体了解多少？哪些只是看过名词？
9. TP、PP 等组合下，KV Cache 应怎样分配？
10. 如何理解 KV Cache 的多级缓存，和硬件缓存层级有什么区别？
11. 投机解码在不同负载或 batch 下是否一定有收益？怎样判断？
12. 推理引擎优化与基础算子优化，各需要补哪些能力？

三、整理补充：三道情景题怎样展开

情景 A：更换并行方式后性能下降

先固定模型、请求长度、并发、输出长度、精度和硬件拓扑，再列出层切分、通信、流水线气泡和调度差异。准备查看哪个 timeline、怎样测每阶段耗时，以及哪一个实验可以推翻当前假设。不要直接认定“通信多所以慢”。

情景 B：小 batch 的 GEMM 比大 batch 更慢

先区分整网延迟和已定位 Kernel 的时间。若问题已被限定在 Kernel 内，应继续检查具体选择的实现、tile、padding、有效工作量、访存与资源占用，而不是反复回到引擎级开关。每个候选原因都配一项验证方法。

情景 C：缓存和投机解码如何落到服务指标

先画请求路径，注明缓存驻留位置、传输路径、命中时与未命中时分别做什么。投机解码准备记录 draft 成本、验证成本、接受情况、并发以及延迟和吞吐。避免脱离负载条件判断某方案必然更快。

四、补课与练习清单

- 阅读目标版本插件文档，列出平台、worker、通信、Attention 和算子适配项。
- 手推一行 Softmax 分成两块后的统计量合并，解释已有结果如何重标定。
- 画出注意力部分与专家部分，分别标注其参数和缓存布局。
- 做一张“算子证据 → 单层证据 → 服务指标”的验证表。

这些是整理者提出的复习任务，不是原面试答案。公开技术校准与参考入口见本目录《阅读说明与基础校准》。

五、来源与保留边界

来源：`曦望AI INFRA2面_转写.txt`。已删去自我介绍、个人经历、岗位选择和流程沟通。原转写存在模型名、库名与术语误识，本篇仅按明确上下文统一常见术语；不照搬回答中不准确的技术断言，也不补写候选人当时没有回答出来的内容。