OPPO 高性能计算与端侧部署

> 技术面复盘 · 多卡稳定性 / 确定性 / GPU 基础 / 端侧迁移。根据个人语音转写提炼，问题均已改写；公司与轮次沿用来源文件标注，不代表官方题库。

一、这一轮主要考什么

主线是把服务器端算子优化经历讲成可验证的工程过程，再判断这些能力能否迁移到资源受限的端侧设备。面试会连续追问根因、方案边界、已有社区方案和本人实际贡献。

二、源记录中可确认的提问

1. 多卡通信等待与浮点标志值有什么关系？为何考虑用位级判断？
2. 使用的是自研通信机制，还是开源库？问题属于通用缺陷，还是特定配置才触发？
3. 推理与训练的 Top-k 专家选择为什么可能不一致？“非确定性归约”具体指什么？
4. 问题影响有多大？已有通用方案为什么不能直接满足需求？
5. 新方案与原有确定性方案相比，付出了什么时间、空间或工程成本？
6. 修复是否获得上游确认？怎样区分内部修复、已提 issue 与已合入贡献？
7. 服务器 GPU 上的排障和性能经验，迁移到手机端时哪些仍然有效？
8. 将约 4B 规模的模型部署到手机端，需要优先考虑哪些资源约束？
9. 在成熟计算库与 AI 编程工具已存在的情况下，开发者如何体现算子优化价值？
10. 如何衡量空间换时间是否值得，怎样证明方案适合实际负载？
11. 介绍线程、warp、block、SM 与存储层次，解释 shared memory 的使用边界。
12. 什么是 shared memory bank conflict？你会怎样构造验证实验？

三、整理补充：回答准备提纲

稳定性案例用“证据链”组织

先画等待方和写入方，再写出状态何时变化、用什么类型存储、由谁读取。将“现场出现超时”与“根因已经定位”分开陈述。准备开关对照、卡数对照、最小复现和修复后回归四类材料，不依赖一句“改完没再挂”结束说明。

转写中的位宽、负零与 FTZ 描述有混用，不能照抄成标准解释。复习时应回到对应版本源码，明确载荷类型、比较类型与实际位模式；没有代码证据时，保留为待核对项。

从服务端迁移到端侧

可用一张预算表组织思路：权重和运行时内存、KV Cache 与临时张量、量化与精度、算子支持与回退、延迟、功耗和持续运行温度。分别列“已知约束”“需要查设备文档的约束”“准备实际测量的指标”。不要只用模型参数量判断能否部署。

算子优化的个人贡献

按“识别异常 → 构造复现 → 提出假设 → 改动实现 → 正确性与性能验证 → 交付回归”说明本人动作。AI 可以参与生成代码和分析报告，但需要能够解释关键分支、失败方案和最终取舍。

四、模拟追问与练习

- 如果异常只在某种数据分布中出现，如何避免复现输入遗漏关键条件？
- 如果某方案单算子更快，却多占显存，如何比较整机能容纳的并发请求数？
- 给一个陌生移动端加速器，先读哪些接口、算子和内存文档？
- 画出 block 内数据复用范围，并说明跨 block 协作准备使用哪种机制。

练习产出：一张通信状态图、一页端侧资源预算、一次有基线和误差检查的简化算子实验。

五、复盘提醒与来源

不要把共享内存表述成任意 block 都可直接共享；不要把社区已有方案说成本人原创；不要把一次特定环境的收益写成普遍加速结论。基础概念校准见本目录《阅读说明与基础校准》。

来源：`OPPO 高性能计算_转写.txt`。已移除身份、学历、实习雇主、个人时间地点、流程沟通及原始问答措辞；未保留个人项目的性能数字。