小马智行二面：算子工程与滑动窗口

> 技术面复盘 · 性能排查 / AI 辅助开发 / 迁移适配 / 双指针。基于个人转写提炼，问题已改写；公司与轮次沿用来源文件标注。

一、这一轮主要考什么

前半段从项目流程追问技术真实性，包括生产问题怎样缩小成本地用例、计算与通信如何相互影响、AI 生成的改动怎样审阅。后半段是带在线状态约束的区间问题。

二、源记录中可确认的提问

1. 怎样通过 profiling 发现训练中的异常算子？如何构建最小复现？
2. 如何从调用链定位到具体实现，而非停留在“某层比较慢”？
3. 计算算子为何会在部分执行中出现长尾？和通信重叠有什么关系？
4. 如何安排计算与通信资源，依据什么指标选择配置？
5. Agent 生成一个很大的 PR 时，怎样阅读、缩小改动并确认质量？
6. 推理 Router GEMM 的输入、执行路径和原实现的问题是什么？
7. 单算子收益与端到端收益有何区别，怎样说明差异？
8. 偶发 hang 如何复现和归因？最终修复的边界是什么？
9. 迁移到另一种 GPU 生态时，如何选择已有库实现和自写算子？
10. 类型注册缺失、错误分派和长跑失败之间怎样建立证据链？

三、代码题：在线区间与累计上传量

源记录能确认：按时间片记录在线状态和累计上传量；累计上传量单调不减；目标区间需满足全程在线，以及上传量、持续时间的阈值条件；面试要求讨论线性扫描思路。现场曾围绕双指针、断线后重置、输出区间和下标展开调试。

完整原题未随 **TXT** 提供。 阈值的严格/非严格比较、端点定义、返回一个区间还是全部区间等细节不够清晰。若要求输出所有区间，复杂度还需要计入结果规模；不能仅凭口述断言某个实现严格为 O(n)。

练习时先补齐契约：`upload[j] - upload[i]` 对应哪些时间片、持续长度如何计算、端点能否相等、断线点是否计入区间、结果是否允许重复。然后用小规模暴力枚举作为对照，再验证你的扫描方案。

四、整理补充：准备一个可以复查的工程故事

把性能异常拆成可检验假设

准备“同输入独立计算”“加入通信”“改变资源配置”几组对照，记录总完成时间、算子时间分布与通信重叠。原记录中的具体配置和收益属于个人口述，本篇不把它们作为通用推荐参数。

审阅 AI 生成的改动

要求每个关键分支都能回答：解决什么输入、为何要新增、失败时如何回退、是否有绕过一般逻辑的特判。先形成小而可解释的改动，再比较正确性和性能；对已有库的复用和自己写的实现分别归因。

区间题的边界清单

- 无在线片段、全部在线、连续断线、只在末尾满足条件。
- 累计上传量平台期、恰好达到阈值、持续时间恰好达到阈值。
- 下标和指针初始化；循环边界；差值是否溢出。
- 多个合法区间与输出规模；用暴力对照发现遗漏或重复。

五、来源与使用范围

来源：`小马智行2面_转写.txt`。删除自我介绍、雇主、个人时间地点、流程及反问。文中工程准备方法和边界清单为整理补充，代码题部分是可确认信息摘录，不是完整原题或官方答案。