曦望三面：反量化与 RMSNorm 编码

> Coding 面复盘 · 行级归约 / 索引 / 线程映射 / 寄存器 / 同步。源文件名为“希望3面”，按上下文暂归入曦望系列，归属仍需文件所有者核对。

一、这一轮主要考什么

核心是把算子描述落实成可运行的 GPU 映射，并解释每个线程处理什么、临时结果存在哪里、归约何时完成。追问主要针对代码正确性和资源使用，而非只看是否知道某个优化名词。

二、源记录中可确认的任务与追问

1. 口述任务涉及 GPU 内存、行主序布局、按行 scale 反量化，以及 RMSNorm 相关融合实现。
2. 需要给出 C++/CUDA 接口实现，现场限制使用某些现成库；具体题面未保存在 TXT 中。
3. 怎样根据矩阵维度选择启动配置？配置怎样传入实现？
4. 一个 block 有多少线程、多少 warp？每一行由谁处理？
5. 如果列数比线程数大，单个线程负责哪些元素？
6. 若把较大临时数组放进线程局部变量，寄存器压力会怎样检查？
7. 每轮共享内存更新后，同步放置在哪里？现有位置是否正确？
8. 行号、列号、线程号与全局下标之间是什么关系？
9. 归约完成后，归一化因子如何被同一行需要它的线程使用？
10. 小列宽场景还能怎样改进？warp 级协作适合哪种任务映射？

三、题目完整性说明

原题通过聊天或屏幕展示，TXT 没有完整数据类型、量化公式、scale 的精确定义、函数签名、误差阈值或可编译代码。因此本篇是题型复盘，不能当作原题完整重建。

练习前先写清楚：输入存储类型、反量化公式、scale 广播维度、权重是否按列、epsilon 位置、累加类型、输出类型、是否连续存储。任何缺失项都应由练习者明确假设，而非冒充原题约束。

四、整理补充：从正确实现走到优化

第一步：用最小尺寸解释索引

先用两行、少量列手写每个输入输出位置。标出一个 block 对应一行还是多行，一个线程负责一个元素还是一串元素。将逻辑列数与 `blockDim.x` 分开，避免用同一个 `block_size` 同时表示数据规模和线程数量。

第二步：拆清归约阶段

按“加载并反量化 → 求局部统计量 → 行内归约 → 计算归一化因子 → 写输出”画阶段图。逐项检查中间值的可见范围和同步条件；对于可能含分支的同步，确认参与线程是否一致。

第三步：在有基线之后减少开销

候选实验包括 warp 级归约、多 warp 汇总、减少重复加载、按输入尺寸选择映射，以及调整每线程处理的元素数。它们只是待验证方向，不能预设一定加速。比较正确性、Kernel 时间、寄存器使用和访存，不仅看代码更短。

五、边界用例与来源

- 列数小于一个 warp、非二次幂列数、列数超过单 block 线程数量。
- 全零输入、不同正负值、极小值、不同 scale、非对齐尾部。
- 只读输入和输出别名问题；每一行使用自己的 scale；权重维度检查。

来源：`希望3面_转写.txt`。已移除自我介绍、个人情况和面试流程。未收录原记录中不完整的代码片段，未声称拥有“通过版原题答案”。基础术语参见本目录《阅读说明与基础校准》。